Գլուխ 1: Տեղեկատվական Տեխնոլոգիաների Մոդելների Տեսակները, Microsoft Azure-ի Գործիքները

Ներածություն

Ժամանակակից թվային աշխարհում տեղեկատվական տեխնոլոգիաները դարձել են տնտեսության, կառավարման, կրթության և բիզնեսի զարգացման հիմնարար բաղադրիչը: Կազմակերպությունները մշտապես ստեղծում և մշակում են մեծածավալ տվյալներ, օգտագործում են բազմատեսակ ծրագրային համակարգեր և ապահովում են առցանց ծառայություններ: Այս գործընթացները պահանջում են հուսալի, անվտանգ և մասշտաբելի տեխնոլոգիական միջավայր: Այդ անհրաժեշտության արդյունքում լայն տարածում են ստացել ամպային տեխնոլոգիաները, որոնք հիմնված են ինտերնետի միջոցով հաշվարկային և ծրագրային ռեսուրսների տրամադրման սկզբունքի վրա:

Ամպային հաշվարկը ծառայությունների մատուցման մոդել է, որի դեպքում սերվերները, պահեստային համակարգերը, ցանցային ենթակառուցվածքը, տվյալների բազաները և ծրագրային ապահովումը տրամադրվում են հեռակա տվյալների կենտրոններից: Օգտագործողը չունի ֆիզիկական սարքավորումներ ձեռք բերելու կամ սպասարկելու անհրաժեշտություն, քանի որ ամբողջ ենթակառուցվածքը կառավարում է ամպային ծառայություն մատուցող ընկերությունը: Վճարումը կատարվում է ըստ օգտագործված ռեսուրսների, ինչը թույլ է տալիս նվազեցնել նախնական ներդրումները և արդյունավետորեն պլանավորել բյուջեն:

Ամպային տեխնոլոգիաների զարգացումը պայմանավորված է վիրտուալացման տեխնոլոգիաների առաջընթացով, ինտերնետի արագության բարձրացմամբ և գլոբալ բիզնես միջավայրի ընդլայնմամբ: Այսօր ամպային ծառայությունները կիրառվում են տարբեր ոլորտներում՝ բանկային համակարգում, կրթական հաստատություններում, առողջապահությունում, պետական կառույցներում և մասնավոր բիզնեսում:

Ամպային համակարգերի հիմնական առավելություններից է մասշտաբելիությունը: Կազմակերպությունները կարող են արագ ավելացնել կամ նվազեցնել հաշվարկային հզորությունները՝ կախված բեռնվածությունից: Սա հատկապես կարևոր է սեզոնային բիզնեսների կամ արագ զարգացող ստարտափների համար: Բացի այդ, ամպային հարթակները ապահովում են բարձր հասանելիություն, քանի որ տվյալների կենտրոնները տեղակայված են տարբեր աշխարհագրական տարածաշրջաններում և աշխատում են կրկնօրինակման մեխանիզմներով: Անվտանգության առումով ամպային մատակարարները կիրառում են տվյալների կոդավորում, մշտական մոնիթորինգ և միջազգային ստանդարտներին համապատասխանող պաշտպանական մեխանիզմներ:

Ամպային ծառայությունները բաժանվում են մի քանի հիմնական մոդելների՝ On-Premise, IaaS, PaaS և SaaS: Յուրաքանչյուր մոդել ունի իր առանձնահատկությունները, առավելությունները և սահմանափակումները:

On-Premise Մոդել

On-Premise մոդելի դեպքում կազմակերպությունը սեփական տարածքում տեղադրում և կառավարում է ամբողջ տեղեկատվական ենթակառուցվածքը: Սերվերները, պահեստային սարքերը, ցանցային սարքավորումները և ծրագրային ապահովումը գտնվում են կազմակերպության ֆիզիկական վերահսկողության տակ: Այս մոտեցումը երկար ժամանակ հանդիսացել է տեղեկատվական համակարգերի կառուցման հիմնական եղանակը և համարվում է դասական IT ճարտարապետության հիմքը: Կազմակերպությունը ստեղծում է իր տվյալների կենտրոնը կամ սերվերային սենյակը, որտեղ տեղադրվում են հաշվարկային հզորությունները, պահեստային համակարգերը, ցանցային հանգույցները, անվտանգության սարքավորումները և էլեկտրասնուցման ու հովացման համակարգերը:

On-Premise ենթակառուցվածքը սովորաբար ներառում է ֆիզիկական սերվերներ, վիրտուալացման հարթակներ, պահեստային զանգվածներ (SAN/NAS համակարգեր), կրկնօրինակման և վերականգնման լուծումներ, ինչպես նաև ներքին և արտաքին ցանցային պաշտպանական մեխանիզմներ: Բացի տեխնիկական բաղադրիչներից, անհրաժեշտ է նաև կազմակերպել ֆիզիկական անվտանգություն՝ սահմանափակ մուտք սերվերային տարածք, հսկողության համակարգեր և հրդեհաշիջման միջոցներ:

On-Premise մոդելի հիմնական առավելությունը լիարժեք վերահսկողությունն է: Կազմակերպությունը ինքնուրույն է որոշում անվտանգության քաղաքականությունը, սարքավորումների կոնֆիգուրացիան, տվյալների պահպանման կանոնները և համակարգերի արդիականացման ժամանակացույցը: Սա հատկապես կարևոր է այն ոլորտների համար, որտեղ տվյալների գաղտնիությունն ու իրավական համապատասխանությունը առաջնահերթ են: Օրինակ՝ ֆինանսական կազմակերպությունները, պետական կառույցները և պաշտպանական ոլորտը հաճախ նախընտրում են տեղային լուծումներ՝ տվյալների ֆիզիկական տեղակայման հստակ վերահսկման պատճառով:

Բացի վերահսկողությունից, On-Premise լուծումը թույլ է տալիս իրականացնել խորը հարմարեցում: Կազմակերպությունը կարող է ընտրել հատուկ սարքավորումներ, կիրառել յուրահատուկ ցանցային ճարտարապետություն և ստեղծել անհատականացված անվտանգության համակարգ: Սա հնարավորություն է տալիս կառուցել բարձր կատարողականությամբ համակարգեր, որոնք օպտիմալացված են կոնկրետ բիզնես գործընթացների համար:

Սակայն այս մոդելը ունի նաև մի շարք նշանակալի թերություններ: Նախնական ներդրումները բավականին բարձր են, քանի որ անհրաժեշտ է ձեռք բերել սերվերներ, լիցենզիաներ, պահեստային համակարգեր և ցանցային սարքավորումներ: Բացի այդ, պահանջվում է համապատասխան ենթակառուցվածք՝ էլեկտրասնուցման կայուն աղբյուր, գեներատորներ, UPS համակարգեր և սառեցման սարքավորումներ: Այս ամենը մեծացնում է կապիտալ ծախսերը և բարդացնում նախագծի իրականացումը:

On-Premise մոդելը պահանջում է նաև մասնագիտացված IT անձնակազմ՝ համակարգերի տեղադրման, մոնիթորինգի, անվտանգության ապահովման և խնդիրների լուծման համար: Անձնակազմի պահպանման և վերապատրաստման

ծախսերը նույնպես ավելանում են, հատկապես երբ կիրառվում են նոր տեխնոլոգիաներ։ Սարքավորումները ժամանակի ընթացքում հնանում են և պահանջում են արդիականացում կամ փոխարինում, ինչը առաջացնում է լրացուցիչ ֆինանսական բեռ։

Մասշտաբելիությունը սահմանափակ է, քանի որ նոր ռեսուրսների ավելացումը պահանջում է ֆիզիկական սարքավորումների ձեռքբերում և տեղադրում։ Եթե կազմակերպությունը սխալ է գնահատում բեռնվածությունը, կարող է առաջանալ կամ ռեսուրսների պակաս, կամ ավելցուկ, ինչը հանգեցնում է անարդյունավետ ծախսերի։ Բացի այդ, համակարգերի ընդլայնումը կարող է պահանջել տարածքի ավելացում և լրացուցիչ ենթակառուցվածքային ներդրումներ։

Վերականգնման և աղետների դիմակայման հարցը նույնպես բարդ է On-Premise միջավայրում։ Անհրաժեշտ է ստեղծել պահուստային տվյալների կենտրոն կամ իրականացնել տվյալների արտաքին կրկնօրինակում, ինչը կրկին պահանջում է լրացուցիչ ծախսեր և տեխնիկական բարդ լուծումներ։ Բնական աղետները, էլեկտրական խափանումները կամ տեխնիկական անսարքությունները կարող են ազդել ամբողջ համակարգի աշխատանքի վրա, եթե պատշաճ կրկնօրինակման ռազմավարություն չի մշակվել։

Այսպիսով, On-Premise մոդելը ապահովում է առավելագույն վերահսկողություն և հարմարեցում, սակայն պահանջում է զգալի ֆինանսական ներդրումներ, տեխնիկական փորձառություն և երկարաժամկետ ռազմավարական պլանավորում։ Այն առավել նպատակահարմար է այն կազմակերպությունների համար, որոնք ունեն բավարար ռեսուրսներ և խիստ անվտանգության կամ կարգավորիչ պահանջներ։

IaaS Մոդել

IaaS, կամ Infrastructure as a Service, մոդելը ենթադրում է ենթակառուցվածքի տրամադրում որպես ծառայություն։ Այս դեպքում ամպային մատակարարը տրամադրում է վիրտուալ սերվերներ, պահեստային ռեսուրսներ, ցանցային գործիքներ և հիմքային հաշվարկային հզորություններ, իսկ հաճախորդը կառավարում է օպերացիոն համակարգերը, միջին ծրագրային շերտը և տեղադրված կիրառական ծրագրերը։ Ֆիզիկական սարքավորումները, տվյալների կենտրոնները, էլեկտրասնուցման համակարգերը և հիմնական ցանցային ենթակառուցվածքը գտնվում են մատակարարի պատասխանատվության ներքո։

IaaS մոդելը հիմնված է վիրտուալացման տեխնոլոգիայի վրա, որի միջոցով մեկ ֆիզիկական սերվերը կարող է բաժանվել մի քանի վիրտուալ մեքենաների։ Յուրաքանչյուր վիրտուալ մեքենա գործում է որպես առանձին համակարգ՝ սեփական օպերացիոն համակարգով և ծրագրերով։ Սա թույլ է տալիս արդյունավետ օգտագործել ֆիզիկական ռեսուրսները և ապահովել բարձր ճկունություն։ Օգտագործողը կարող է ընտրել սերվերի հզորությունը, պրոցեսորի քանակը, հիշողության ծավալը, պահեստային տարածքը և ցանցային պարամետրերը՝ ըստ իր պահանջների։

Այս մոդելի առավելություններից է ցածր նախնական ծախսը։ Կազմակերպությունը չունի սարքավորումներ գնելու և տեղադրելու անհրաժեշտություն, ինչը նվազեցնում է կապիտալ ներդրումները։ Նոր վիրտուալ սերվեր ստեղծելու գործընթացը կարող է իրականացվել ընդամենը մի քանի րոպեի ընթացքում՝ առանց ֆիզիկական միջամտության։ Սա հատկապես կարևոր է արագ զարգացող նախագծերի և ստարտափների համար, որտեղ անհրաժեշտ է արագ արձագանքել շուկայի փոփոխություններին։

Մասշտաբելիությունը IaaS մոդելի կարևորագույն առավելություններից է։ Ռեսուրսների ավելացումը կամ նվազեցումը իրականացվում է գրեթե ակնթարթորեն։ Եթե համակարգի բեռնվածությունը աճում է, հնարավոր է ավելացնել պրոցեսորային հզորությունը կամ ստեղծել լրացուցիչ վիրտուալ մեքենաներ։ Նույն կերպ, բեռնվածության նվազման դեպքում կարելի է կրճատել օգտագործվող ռեսուրսները և օպտիմալացնել ծախսերը։ Այս մոտեցումը թույլ է տալիս արդյունավետ կառավարել ֆինանսական ռեսուրսները և խուսափել ավելորդ ծախսերից։

Գլոբալ հասանելիությունը ևս կարևոր առավելություն է։ Ամպային մատակարարները ունեն տվյալների կենտրոններ աշխարհի տարբեր տարածաշրջաններում, ինչը թույլ է տալիս տեղակայել ծառայությունները այն տարածաշրջանում, որը առավել մոտ է վերջնական օգտագործողին։ Սա բարելավում է աշխատանքի արագությունը, նվազեցնում է ուշացումները և բարձրացնում է համակարգի հասանելիությունը։

IaaS մոդելը նաև նպաստում է փորձարարական և թեստային միջավայրերի արագ ստեղծմանը։ Ծրագրավորողները կարող են ստեղծել փորձնական սերվերներ, իրականացնել թեստավորում և անհրաժեշտության դեպքում արագ հեռացնել դրանք՝ առանց երկարաժամկետ պարտավորությունների։ Սա մեծացնում է զարգացման գործընթացի արդյունավետությունը և նվազեցնում ռիսկերը։

Սակայն IaaS մոդելը ունի նաև որոշակի սահմանափակումներ։ Չնայած ենթակառուցվածքը կառավարվում է մատակարարի կողմից, օպերացիոն համակարգերի, տվյալների անվտանգության և կիրառական ծրագրերի պատասխանատվությունը մնում է հաճախորդի վրա։ Սա նշանակում է, որ կազմակերպությունը պետք է ունենա համապատասխան տեխնիկական գիտելիքներ և փորձառություն՝ ապահովելու համակարգերի անվտանգությունը և կայուն աշխատանքը։

Կախվածությունը ինտերնետ կապից ևս կարևոր գործոն է։ Քանի որ բոլոր ռեսուրսները հասանելի են ինտերնետի միջոցով, կապի խափանումները կարող են ժամանակավորապես դադարեցնել ծառայությունների հասանելիությունը։ Բացի այդ, տվյալների փոխանցման արագությունը և որակը կարող են ազդել համակարգի աշխատանքի արդյունավետության վրա։

Երկարաժամկետ օգտագործման դեպքում ծախսերը կարող են աճել, եթե ռեսուրսների օգտագործումը ճիշտ չի պլանավորվում։ Անարդյունավետ կոնֆիգուրացիաները, ավելորդ ակտիվ սերվերները կամ սխալ ընտրված պահեստային լուծումները կարող են առաջացնել ֆինանսական բեռ։ Հետևաբար կարևոր է մշտական մոնիթորինգ և ծախսերի օպտիմալացում իրականացնել։

Բացի այդ, IaaS մոդելում առկա է մատակարարից կախվածության գործոնը։ Եթե կազմակերպությունը կառուցում է իր ամբողջ համակարգը մեկ ամպային հարթակի վրա, ապագայում այլ մատակարարի անցումը կարող է լինել բարդ և ժամանակատար։ Սա պահանջում է ռազմավարական պլանավորում և ճարտարապետական ճկունություն։

Ընդհանուր առմամբ, IaaS մոդելը համարվում է արդյունավետ լուծում այն կազմակերպությունների համար, որոնք ցանկանում են պահպանել վերահսկողությունը ծրագրային միջավայրի վրա, սակայն միաժամանակ խուսափել ֆիզիկական ենթակառուցվածքի ստեղծման և սպասարկման բարդություններից։ Այն ապահովում է ճկունություն, մասշտաբելիություն և գլոբալ հասանելիություն՝ դարձնելով այն ժամանակակից բիզնես միջավայրի կարևորագույն բաղադրիչներից մեկը։

PaaS Մոդել

PaaS, կամ Platform as a Service, մոդելը տրամադրում է պատրաստի տեխնոլոգիական միջավայր ծրագրերի մշակման, փորձարկման, տեղակայման և կառավարման համար: Այս մոդելի դեպքում ամպային մատակարարը կառավարում է ոչ միայն ֆիզիկական ենթակառուցվածքը, այլ նաև վիրտուալացման շերտը, օպերացիոն համակարգերը, միջին ծրագրային ապահովումը (middleware), տվյալների բազաների կառավարման համակարգերը և զարգացման հիմնական գործիքները: Օգտագործողը հիմնականում կենտրոնանում է կիրառական ծրագրերի մշակման և բիզնես տրամաբանության իրականացման վրա՝ առանց ենթակառուցվածքային բարդ խնդիրների լուծման անհրաժեշտության:

PaaS մոդելը ձևավորվել է ծրագրային ապահովման արագ զարգացման պահանջից: Ժամանակակից կազմակերպությունները հաճախ աշխատում են դինամիկ միջավայրում, որտեղ անհրաժեշտ է կարճ ժամանակահատվածում ստեղծել և թողարկել նոր ֆունկցիոնալություն: PaaS-ը հնարավորություն է տալիս ծրագրավորողներին անմիջապես սկսել աշխատանքը՝ առանց սերվերների տեղադրման, օպերացիոն համակարգերի կարգաբերման կամ անվտանգության հիմքային կոնֆիգուրացիաների իրականացման:

Այս մոդելում տրամադրվում են պատրաստի զարգացման հարթակներ, ծրագրավորման լեզուների աջակցություն, տվյալների բազաների ինտեգրում, API-ների կառավարում և մոնիթորինգի գործիքներ: Շատ դեպքերում PaaS հարթակները ներառում են ավտոմատ մասշտաբելիության մեխանիզմներ, որոնց միջոցով համակարգը ինքնուրույն ավելացնում կամ նվազեցնում է ռեսուրսները՝ կախված բեռնվածությունից: Սա ապահովում է կայուն աշխատանք նույնիսկ մեծ օգտագործման պայմաններում:

PaaS մոդելի առավելություններից է ծրագրային մշակման արագացումը: Քանի որ ենթակառուցվածքային հարցերը լուծված են մատակարարի կողմից, ծրագրավորողները կարող են ամբողջ ուշադրությունը դարձնել կոդի որակին, ֆունկցիոնալությանը և նորարարական լուծումների մշակմանը: Սա կրճատում է նախագծի իրականացման ժամանակը և բարձրացնում թիմի արտադրողականությունը:

Ավտոմատ թարմացումները ևս կարևոր առավելություն են: Օպերացիոն համակարգերը, տվյալների բազաների համակարգերը և անվտանգության բաղադրիչները թարմացվում են ավտոմատ կերպով՝ առանց օգտագործողի միջամտության: Սա նվազեցնում է տեխնիկական ռիսկերը և ապահովում համակարգի համապատասխանությունը անվտանգության ժամանակակից պահանջներին:

PaaS հարթակները սովորաբար ունեն բարձր ինտեգրում DevOps գործիքների հետ: Դրանք աջակցում են CI/CD գործընթացներին, ինչը թույլ է տալիս ավտոմատացնել կոդի կառուցումը, թեստավորումը և տեղակայումը: Ծրագրի նոր տարբերակները կարող են արագ և անվտանգ տեղակայվել արտադրական միջավայրում՝ նվազեցնելով մարդկային սխալների հավանականությունը: Բացի այդ, տրամադրվում են մոնիթորինգի և լոգավորման գործիքներ, որոնք թույլ են տալիս հետևել համակարգի աշխատանքին և արագ արձագանքել խնդիրներին:

Այնուամենայնիվ, PaaS մոդելը ունի նաև որոշ սահմանափակումներ։ Քանի որ ենթակառուցվածքի և միջավայրի կառավարումը իրականացվում է մատակարարի կողմից, կազմակերպությունը չունի լիարժեք վերահսկողություն համակարգի բոլոր շերտերի նկատմամբ։ Հնարավոր չէ կատարել խորքային կոնֆիգուրացիաներ կամ կիրառել հատուկ համակարգային լուծումներ, որոնք դուրս են մատակարարի առաջարկած հնարավորություններից։

Բացի այդ, առկա է մատակարարից կախվածության գործոնը։ Եթե կազմակերպությունը ամբողջությամբ կառուցում է իր ծրագրային ճարտարապետությունը կոնկրետ PaaS հարթակի առանձնահատկությունների վրա, ապագայում այլ հարթակի անցումը կարող է պահանջել զգալի վերամշակում և տեխնիկական ռեսուրսներ։ Սա կարող է սահմանափակել տեխնոլոգիական անկախությունը և բարձրացնել ռազմավարական ռիսկերը։

Մեկ այլ կարևոր հանգամանք է ծախսերի կառավարումը։ Չնայած PaaS-ը հաճախ նվազեցնում է ենթակառուցվածքային ծախսերը, ինտենսիվ օգտագործման դեպքում ծառայությունների արժեքը կարող է աճել։ Հետևաբար անհրաժեշտ է պարբերաբար վերլուծել օգտագործման տվյալները և օպտիմալացնել ռեսուրսների բաշխումը։

Ընդհանուր առմամբ, PaaS մոդելը հանդիսանում է արդյունավետ լուծում այն կազմակերպությունների համար, որոնք առաջնահերթություն են տալիս արագ զարգացմանը, ավտոմատացմանը և ժամանակակից ծրագրային ճարտարապետությանը։ Այն ապահովում է ճկուն և կայուն միջավայր, որը թույլ է տալիս կենտրոնանալ բիզնես արժեք ստեղծելու վրա՝ նվազեցնելով տեխնիկական բարդությունները և ենթակառուցվածքային ռիսկերը։

SaaS Մոդել

SaaS, կամ Software as a Service, մոդելում օգտագործողը ստանում է ամբողջությամբ պատրաստի ծրագրային լուծում, որը գործում է ամպային միջավայրում և հասանելի է ինտերնետի միջոցով: Օգտագործողը պարզապես մուտք է գործում համակարգ՝ օգտագործելով վեբ դիտարկիչ կամ համապատասխան հավելված, և անմիջապես սկսում է աշխատել ծառայության հետ՝ առանց սերվերների տեղադրման, օպերացիոն համակարգերի կարգաբերման կամ տեխնիկական ենթակառուցվածքի կառավարման անհրաժեշտության: Ծրագրային ապահովման ամբողջ տեխնիկական հատվածը, ներառյալ սերվերները, տվյալների բազաները, անվտանգության մեխանիզմները և թարմացումները, կառավարվում են ծառայություն մատուցող ընկերության կողմից:

SaaS մոդելը լայն տարածում է ստացել հատկապես այն կազմակերպությունների շրջանում, որոնք ցանկանում են արագ ներդնել թվային գործիքներ առանց մեծ ֆինանսական և տեխնիկական ներդրումների: Այս մոդելի դեպքում ծրագրային ապահովումը սովորաբար տրամադրվում է բաժանորդագրության սկզբունքով, որտեղ կազմակերպությունը վճարում է ամսական կամ տարեկան վճար՝ կախված օգտագործողների քանակից կամ ծառայության ծավալից:

SaaS մոդելի հիմնական առավելությունն օգտագործման պարզությունն է: Չկա տեղադրման կամ բարդ կարգաբերման անհրաժեշտություն, քանի որ համակարգը պատրաստ է օգտագործման հենց գրանցումից հետո: Թարմացումները կատարվում են ավտոմատ կերպով՝ առանց օգտվողի միջամտության, ինչը նշանակում է, որ ծրագրային ապահովումը միշտ աշխատում է վերջին տարբերակով և համապատասխանում է անվտանգության արդիական պահանջներին:

Մեկ այլ կարևոր առավելություն հասանելիությունն է: Քանի որ SaaS լուծումները աշխատում են ամպային միջավայրում, օգտվողները կարող են մուտք գործել համակարգ աշխարհի ցանկացած կետից՝ օգտագործելով համակարգիչ, պլանշետ կամ բջջային սարք: Սա հատկապես կարևոր է հեռավար աշխատանքի, միջազգային թիմերի և բազմաճյուղ կազմակերպությունների համար:

SaaS մոդելը նաև ապահովում է արագ մասշտաբելիություն: Եթե կազմակերպությունում ավելանում է օգտվողների քանակը, հնարավոր է հեշտությամբ ավելացնել նոր հաշիվներ՝ առանց լրացուցիչ տեխնիկական միջամտության: Նույն կերպ, անհրաժեշտության դեպքում կարելի է նվազեցնել օգտագործողների թիվը և համապատասխանաբար նվազեցնել ծախսերը:

Բացի այդ, SaaS համակարգերը հաճախ ներառում են ինտեգրման հնարավորություններ այլ ծառայությունների և հարթակների հետ: Դրանք կարող են միացվել հաշվապահական համակարգերին, հաճախորդների կառավարման հարթակներին կամ վերլուծական գործիքներին, ինչը բարձրացնում է բիզնես գործընթացների արդյունավետությունը:

Այնուամենայնիվ, SaaS մոդելը ունի նաև որոշ սահմանափակումներ: Հարմարեցման հնարավորությունները սովորաբար սահմանափակ են այն ֆունկցիոնալությամբ, որը տրամադրում է մատակարարը: Եթե կազմակերպությունը ունի հատուկ կամ եզակի պահանջներ, հնարավոր է, որ SaaS լուծումը չկարողանա լիովին բավարարել դրանք:

Տվյալների վերահսկողությունը ևս կարևոր հարց է։ Քանի որ տվյալները պահվում են մատակարարի տվյալների կենտրոններում, կազմակերպությունը չի ունենում ֆիզիկական վերահսկողություն դրանց նկատմամբ։ Սա կարող է առաջացնել անվտանգության կամ իրավական մտահոգություններ, հատկապես այն ոլորտներում, որտեղ տվյալների գաղտնիությունը և պահպանման կանոնները խիստ կարգավորվում են։

Բացի այդ, SaaS մոդելը կախված է ինտերնետ կապից։ Առանց կայուն կապի հնարավոր չէ օգտվել ծառայությունից, ինչը կարող է սահմանափակում լինել որոշ իրավիճակներում։ Երկարաժամկետ հեռանկարում բաժանորդագրության վճարները կարող են դառնալ զգալի ծախս, հատկապես մեծ կազմակերպությունների համար, որտեղ օգտագործողների թիվը բարձր է։

Ընդհանուր առմամբ, SaaS մոդելը հանդիսանում է ժամանակակից և արդյունավետ լուծում այն կազմակերպությունների համար, որոնք ցանկանում են արագ, պարզ և նվազագույն տեխնիկական բարդությամբ ներդնել ծրագրային համակարգեր։ Այն ապահովում է հասանելիություն, ավտոմատացում և մասշտաբելիություն, սակայն պահանջում է վստահություն մատակարարի նկատմամբ և ռազմավարական մոտեցում տվյալների կառավարման հարցում։

Microsoft Azure

Microsoft Azure-ը Microsoft ընկերության ստեղծած լայնածավալ և բազմաֆունկցիոնալ ամպային հարթակն է, որը առաջարկում է ավելի քան 200 ծառայություն և համապատասխանում է ինչպես փոքր ընկերությունների, այնպես էլ մեծ ձեռնարկությունների պահանջներին: Azure-ը հնարավորություն է տալիս կառուցել, փորձարկել, տեղակայել և կառավարել ծրագրեր՝ առանց ֆիզիկական ենթակառուցվածքներ ունենալու անհրաժեշտության:

Azure-ի հիմնական ծառայությունները ներառում են հաշվողական հզորություն, ինչպիսիք են Virtual Machines (VMs), որոնք տրամադրում են տարբեր օպերացիոն համակարգերով վիրտուալ սերվերներ, Azure Functions՝ առանձ սերվերների հաշվարկ, որտեղ կոդը աշխատում է իրադարձությունների հիման վրա, և App Services՝ վեբ ծրագրերի հոստինգի համար: Տվյալների պահեստավորման ոլորտում Azure-ն առաջարկում է Blob Storage, որը նախատեսված է մեծ չստրուկտուրավորված տվյալների պահպանման համար, Azure Files՝ կիսվող ֆայլային համակարգ, ինչպես նաև Data Lake Storage՝ մեծ չափի պահեստ տարբեր տիպի տվյալների համար:

Տվյալների բազաների ոլորտում ծառայությունների շարքում են Azure SQL Database, որը հանդիսանում է կառավարվող տվյալների բազա, Cosmos DB՝ գլոբալ բաշխված և բարձր աշխատանքային կարողություններով NoSQL տիպի տվյալների բազա, և PostgreSQL/MySQL ծառայություններ: Մեքենայական ուսուցման և արհեստական բանականության համար Azure-ը տրամադրում է Azure Machine Learning ծառայությունը՝ մեքենայական ուսուցման մոդելների մշակման, ուսուցման և տեղակայման ամբողջական միջավայր, ինչպես նաև Cognitive Services՝ տեսողության, խոսքի, լեզվի, որոնման և այլ տիպերի API-ների համախումբ:

Տվյալների պրոցեսավորման և ինտեգրման ոլորտում Azure-ի ծառայությունները ներառում են Azure Data Factory-ն՝ տվյալների տեղափոխման և փոխակերպման համար, և Azure Synapse Analytics՝ մեծածավալ տվյալների վերլուծության և բիզնես ինտելեկտի ապահովման համար: Ցանցային ծառայությունների շարքում ընդգրկված են Virtual Network, Load Balancer, VPN Gateway, Firewall, ինչպես նաև CDN, DDoS հարձակումներից պաշտպանություն և այլ ցանցային գործիքներ:

Azure-ի հիմնական առավելությունն այն է, որ այն ապահովում է ճկունություն, գլոբալ հասանելիություն և անվտանգություն, միաժամանակ նվազեցնելով կազմակերպությունների տեխնիկական և ֆինանսական բեռնվածությունը:

ETL/ELT տվյալների ինտեգրման եղանակները

ETL-ը տվյալների ինտեգրման դասական եղանակ է, որի նպատակը տարբեր աղբյուրներից ստացված տվյալները մաքրելն, փոխակերպելն ու պահպանելն է տվյալների պահեստում: ETL-ի գործընթացը բաղկացած է երեք փուլից՝ Extract, Transform և Load:

Առաջին փուլը՝ Extract, որի ընթացքում տվյալները վերցվում են տարբեր աղբյուրներից, օրինակ՝ տվյալների բազաներից, ինչպիսիք են SQL database կամ Oracle, API-ներից և վեբ ծառայություններից, CSV, JSON, Excel ֆայլերից, ինչպես նաև օպերացիոն համակարգերից կամ լոգ ֆայլերից: Այս փուլում տվյալները հիմնականում վերցվում են իրենց սկզբնական վիճակում (raw):

Երկրորդ փուլը՝ Transform, որտեղ տվյալները ձևափոխվում են միջանկյալ պրոցեսավորման միջավայրերում, օրինակ՝ ETL սերվերի վրա կամ հատուկ ETL գործիքի միջոցով: Ձևափոխումը ընդգրկում է տվյալների մաքրում, ֆորմատների փոխակերպում, աղյուսակների միավորում, ագրեգացիաների և հաշվարկների ընդգրկում:

Վերջնին փուլը՝ Load, որը ապահովում է ձևափոխված տվյալների պահպանումը նպատակային տվյալների պահեստում, սովորաբար Data Warehouse-ում, ինչպիսիք են Azure SQL Data Warehouse կամ Teradata: ETL ինտեգրման եղանակը արդյունավետ է, երբ անհրաժեշտ է ապահովել ծանր և բարդ հաշվարկներ ձևափոխման փուլում, և երբ նպատակային պահեստը չունի մեծ հաշվարկային հզորություն, երբ անհրաժեշտ է նախապես մաքրել և հետո միայն պահել վավերացված տվյալներ, ինչպես նաև երբ տվյալները անկանոն կառուցվածքով են:

ELT-ն (Extract - Load - Transform) մոտեցումը տարբերվում է ETL-ից նրանով, որ գործընթացի փուլերի հերթականությունը փոխված է, և վերափոխումները կատարվում են հենց նպատակային տվյալների պահեստում: Սա դարձել է հնարավոր ժամանակակից ամպային տվյալների պահեստների մեծ հաշվարկային հզորության շնորհիվ: ELT-ում առաջին փուլը Extract է, որի ընթացքում աղբյուրներից ստացվում են տվյալները՝ առանց մեծ վերափոխումների: Երկրորդ փուլը՝ Load, ենթադրում է raw ֆորմատի տվյալների անմիջական պահպանումը տվյալների պահեստում, օրինակ՝ Azure Synapse Analytics, Snowflake, BigQuery կամ Databricks Delta Lake: Երրորդ փուլը՝ Transform, իրականացվում է հենց պահեստի ներսում՝ օգտագործելով SQL-ի, Spark-ի կամ MPP (Massively Parallel Processing) հաշվարկային մեխանիզմները:

ELT մոտեցման առավելությունն այն է, որ ժամանակակից պահեստներն ունեն մեծ հաշվարկային հզորություն և կարող են արագ մշակել հսկայական ծավալի տվյալներ: ELT-ն հատկապես օգտակար է, երբ աշխատում ենք մեծ ծավալի տվյալների հետ, երբ պահեստը ունի բարձր հաշվարկային հզորություն, երբ վերափոխումները կարելի է իրականացնել SQL կամ Spark պահեստի ներսում, ինչպես նաև երբ անհրաժեշտ է արագ բեռնել տվյալները և միայն հետո մշակել դրանք: Դրանց համեմատության աղյուսակը բերված է Աղյուսակ 1-ում:

Աղյուսակ 1

Բնութագիր	ETL	ELT
Վերափոխման տեղը	Միջանկյալ համակարգ	Տվյալների պահեստում
Առավել հարմար է	Փոքր և միջին տվյալների համակարգերի համար	Մեծ տվյալների, ամպային պահեստների համար
Հաշվարկային ծանրաբեռնվածություն	ETL սերվերի վրա	Cloud/Data Warehouse -ի վրա
Տվյալների պահպանում	Պահպանվում են միայն վերափոխված տվյալները	Պահպանվում են raw տվյալները և վերափոխված տվյալները
Գործիքներ	SSIS, Informatica, Talend	Azure Synapse, Snowflake, BigQuery, Databricks
Սկզբնական ճկունություն	Ավելի կոշտ գործընթացներ	Շատ ճկուն՝ մոդելավորման և SQL transform-ի համար

«Մեդալիոն» Ճարտարապետություն

Վերջին տարիներին տվյալային համակարգերի զարգացման մեջ լայնորեն կիրառվող մեդալիոնային ճարտարապետությունը ներկայացվում է որպես հստակ կառուցվածք, որի նպատակն է ստեղծել հասկանալի, վերահսկելի և երկարաժամկետ վստահելի տվյալային միջավայր։ Այդ մոտեցումը հիմնված է այն գաղափարի վրա, որ տվյալները պետք է անցնեն հաջորդական փուլերով, որտեղ յուրաքանչյուր փուլ ապահովում է ավելի բարձր որակ և մաքրություն։ Այս պատճառով էլ ամբողջ գործընթացը իրենց անվանումը ստացել է «մեդալիոն»՝ շերտերով կառուցված համակարգի գաղափարով։

Տվյալների առաջին կանգառը համարվում է բրոնզե շերտը, որտեղ դրանք պահվում են հում տեսքով՝ այնպես, ինչպես ստացվում են տարբեր աղբյուրներից։ Այստեղ կարող են գտնվել տարբեր ձևաչափերով տվյալներ՝ լոգեր, սենսորների հոսքեր, բազաների արտահանումներ կամ այլ չմշակված ֆայլեր։ Այս փուլում տվյալների վրա որևէ փոփոխություն չի կատարվում, քանի որ նպատակն է պահպանել դրանց ամբողջականությունը և ապահովել հետագա քայլերի համար անհրաժեշտ հուսալի հիմք։ Բրոնզե շերտը նաև պահպանում է տվյալների ծագումնաբանությունը, ինչը կարևոր է հետագա վերլուծությունների և աուդիտի համար։

Հաջորդ փուլը արծաթե շերտն է, որտեղ տվյալները ենթարկվում են մաքրումի և կառուցվածքային ընդհանրացման։ Այս փուլում վերացվում են կրկնօրինակները, շտկվում են սխալ կամ անհամապատասխան ձևաչափերը, լրացվում են բացակայող արժեքները, և տարբեր աղբյուրներից ստացված տվյալները համադրվում են միմյանց հետ։ Արծաթե շերտը դարձնում է տվյալները կանոնավոր, միատեսակ և տրամաբանորեն կապված։ Սա այն միջին մակարդակն է, որտեղ արդեն կարող է կիրառվել բիզնես տրամաբանության մի մասը, սակայն տվյալները դեռ չեն հասել իրենց վերջնական մոդելին։

Ճարտարապետության ամենավերջին և ամենահաստատուն փուլը ոսկե շերտն է։ Այստեղ տվյալները դառնում են առավել որակյալ, ամբողջապես մաքրված և պատրաստ բիզնես վերլուծության համար։ Այս փուլում դրանք խմբագրվում և ագրեգացվում են՝ համապատասխանեցված կազմակերպության պահանջներին։ Ոսկե շերտից առաջացած տվյալները օգտագործվում են հաշվետվությունների, վերլուծական մոդելների, ցուցանիշների հաշվարկների և կառավարման որոշումների համար։ Շատ կազմակերպություններ այս շերտը դիտարկում են որպես իրենց միավորային ճշմարտության աղբյուր, քանի որ այստեղ գտնվող տվյալները ունեն առավելագույն վստահելիություն։

Մեդալիոնային ճարտարապետությունը գնահատվում է իր պարզությամբ և բարձր արդյունավետությամբ։ Այն թույլ է տալիս կազմակերպություններին ունենալ պատշաճ տվյալային համակարգ, որտեղ տվյալների որակը բարձրանում է

աստիճանաբար, իսկ ամբողջ գործընթացը դառնում է կանխատեսելի և թափանցիկ։ Այս մոտեցումը դարձնում է տվյալների կառավարումն ավելի հեշտ և ապահովում է, որ տարբեր բաժիններ ու թիմեր օգտվեն նույն հուսալի տվյալներից՝ իրենց որոշումների և վերլուծությունների համար։

OLTP/OLAP համակարգեր

OLTP (Online Transaction Processing) համակարգերը նախատեսված են օպերացիոն աշխատանքների համար, որտեղ առաջնահերթ են արագությունն ու կայունությունը, ինչպես նաև տվյալների մանրամասն վերահսկումը: Դրանք զբաղվում են առօրյա գործարքներով, որոնք փոքր ծավալով են, բայց տեղի են ունենում հաճախակի: Այս համակարգերը կարող են միաժամանակ սպասարկել հազարավոր կամ միլիոնավոր կարճ տևողությամբ տրանզակցիաներ՝ ապահովելով բարձր արագությունը և տվյալների ամբողջականությունը՝ պահպանելով ACID սկզբունքները, որոնցում ընդգրկված են Atomicity, Consistency, Isolation և Durability: Տվյալները սովորաբար պահվում են նորմալիզացված բազաներում՝ բազմաթիվ աղյուսակների բաժանված, որպեսզի նվազեցնեն կրկնօրինակումները և բարձրացնեն ամբողջականությունը: Օրինակների շարքում կարելի է նշել բանկային համակարգերը, որոնք ապահովում են հաշվիների միջև փոխանցումները և քարտային վճարումները, առցանց խանութները, որոնք իրականացնում են պատվերների գրանցում, վճարումներ և պահեստային փոփոխություններ, ինչպես նաև CRM համակարգերը, որոնք թույլ են տալիս օպերացիոն կառավարում հաճախորդների տվյալների:

OLAP (Online Analytical Processing) համակարգերը նախատեսված են վերլուծական և բիզնես-վերլուծական խնդիրների համար, երբ անհրաժեշտ է աշխատել մեծ ծավալի պատմական տվյալների հետ, կատարել բարդ հարցումներ և ստանալ խորքային վերլուծություն: Այս համակարգերը ապահովում են բարդ վերլուծական հարցումներ, որոնք կարող են ներառել խմբավորումներ, ագրեգացիաներ և բազմաչափ վերլուծություններ: Տրանզակցիոն հաճախականությունը սովորաբար ցածր է, և հարցումները կարող են տևել վայրկյաններ կամ նույնիսկ րոպեներ: Տվյալները պահվում են դենորմալիզացված կառուցվածքով՝ օգտագործելով Star կամ Snowflake Schema, ինչը ապահովում է վերլուծական հաշվարկների արագագործությունը: Այս համակարգերը հաճախ օգտագործվում են BI և Dashboard-ների ստեղծման համար, օրինակ՝ Power BI, Tableau և reporting համակարգերում: Օրինակներ են հանդիսանում Azure Synapse Analytics՝ ամպային մեծ տվյալների և վերլուծության հարթակը, ինչպես նաև Data Warehouse համակարգերը, ինչպիսիք են Snowflake, Google BigQuery և Amazon Redshift:

Տվյալային խողովակաշարեր (Data Pipelines)

Տվյալային խողովակաշարերը տվյալների ավտոմատացված հոսքերի համակարգված հավաքածու է, որի միջոցով տվյալները վերցվում են տարբեր աղբյուրներից, մաքրվում, ձևափոխվում, մշակում և տեղափոխվում են նպատակային համակարգեր: Այն ապահովում է, որ տվյալները հոսեն շարունակաբար, կանխատեսելի և հուսալի ձևով՝ առանց մարդկային միջամտության: Data Pipeline-ը կարող է ներառել ինչպես պարզ գործողություններ, օրինակ՝ ֆայլի պատճենում, տեղափոխում, այնպես էլ բարդ գործընթացներ, ինչպիսիք են մեծ ծավալնով տվյալների վերլուծությունը, real-time տվյալների մշակումն կամ մեքենայական ուսուցման մոդելների թարմացումը:

Տվյալային խողովակաշարի հիմնական քայլերը սկսվում են տվյալների հավաքագրումով, որի ընթացքում տվյալները ստացվում են տարբեր աղբյուրներից, ինչպիսիք են տվյալների բազաները (SQL/NoSQL), API-ներն ու web services-ը, ֆայլային համակարգերը (CSV, JSON, Parquet) և IoT սարքերը: Այս փուլում տվյալները հիմնականում հավաքվում են իրենց raw տեսքով:

Մյուս փուլը ձևափոխումն է (ETL/ELT), որտեղ տվյալները անցնում են մաքրման, սխալների ուղղման, ֆորմատների ստանդարտացման, ֆիլտրավորման կամ բարդ վերափոխումների միջով: ETL-ի դեպքում վերափոխումները կատարվում են միջանկյալ համակարգում, իսկ ELT-ի դեպքում դրանք իրականացվում են տվյալների պահեստում՝ օգտագործելով SQL կամ Spark:

Վերջնական փուլը տվյալների տեղափոխումն է տարբեր պահեստներ. մշակված տվյալները տեղափոխվում են Data Warehouse՝ վերլուծության համար, Data Lake՝ մեծ չմշակված տվյալների պահպանման համար, կամ Operational Store և analytics engine: Տեղափոխումն կարող է կատարվել batch, near-real-time կամ real-time ձևաչափով:

Մոնիթորինգն ու սխալների կառավարումը ապահովում են, որ pipeline-ը աշխատի առանց ընդհատման: Այս փուլը ներառում է workflow-ի վերահսկում, սխալների ավտոմատ հայտնաբերում և վերագործարկում, ինչպես նաև լոգավորում և ծանուցումների հավաքագրում (alerting):

Վերջնական օգտագործման փուլում pipeline-ի միջոցով ստացված տվյալները օգտագործվում են վերլուծական հաշվետվությունների (BI dashboards) ստեղծման, մեքենայական ուսուցման մոդելների ուսուցման և թարմացման, օպերացիոն համակարգերի որոշումների կայացման, ինչպես նաև real-time համակարգերի ավտոմատացման համար:

Data Pipeline-ների կարևորությունն այն է, որ դրանք ապահովում են տվյալների հուսալի շրջանառություն՝ անկախ ծավալից կամ աղբյուրների բազմազանությունից, կրկնության դիմացկուն են՝ կարող են ինքնաշխատ վերագործարկվել կամ շարունակել սխալի դեպքում, ավտոմատացված են և նվազեցնում են ձեռքով միջամտության անհրաժեշտությունը, ինչպես նաև ապահովում են, որ տվյալները հասանելի լինեն ճիշտ պահին, ինչը կարևոր է վերլուծության, որոշումների կայացման և AI/ML համակարգերի համար: Pipeline-ների միջոցով համակարգերը դառնում են ճկուն, քանի որ տվյալները կարող են հոսել մեծածավալ և արագ աճող համակարգերի միջև:

Microsoft Azure Data Factory

Azure Data Factory-ն Microsoft Azure-ի ամպային տվյալների ինտեգրման ծառայությունն է, որը թույլ է տալիս կառուցել ամբողջական տվյալային հոսքեր՝ սկսած տվյալների հավաքագրումից մինչև դրանց մշակում, փոխակերպում և պահպանում տարբեր նպատակային համակարգեր: Այն հանդիսանում է որպես կապող օղակ տարբեր տվյալների աղբյուրների միջև՝ ապահովելով ավտոմատացված, վերահսկվող և մասշտաբավորվող տվյալային գործընթացներ: Azure Data Factory-ն լայնորեն կիրառվում է ETL և ELT գործընթացների իրականացման, Data Pipeline-ների ստեղծման ու կառավարման, բազմաթիվ աղբյուրներից տվյալների տեղափոխելը դեպի պահեստներ, ինչպես նաև տարբեր քայլերի հաջորդական կառավարման, ժամանակացույցի և սխալների մշակման համար: Ծառայությունը հնարավորություն է տալիս աշխատել ինչպես Azure-ի ներքին, այնպես էլ արտաքին կամ տեղային տվյալների աղբյուրների հետ, ապահովելով ճկուն ինտեգրում:

Azure Data Factory-ի հիմնական բաղադրիչներն են Pipelines, Activities, Linked Services, Datasets և Integration Runtime: Pipelines-ը ADF-ի հիմնական կառուցվածքային միավորն է, որը ներկայացնում է գործողությունների տրամաբանական հավաքածու՝ միաժամանակ կատարելով գործընթացներ տվյալների հետ, օրինակ՝ տվյալների ստացում, մաքրում և պահեստավորում: Pipeline-ները կարող են աշխատել ժամանակացույցով, արձագանքել տրիգերներին, պարունակել կախվածություններ և լինել մասշտաբավորվող ու վերահսկվող:

Activities-ը Pipeline-ի մեջ գործող քայլերն են, որտեղ ամեն activity կատարում է կոնկրետ առաջադրանք, ինչպիսիք են տվյալների պատճենումը, SQL սքրիպտի գործարկումը կամ API կանչը: Հիմնական activity-ներն են Copy Activity, որը իրականացնում է տվյալների փոխանցում աղբյուրից դեպի նպատակային պահեստ, Data Flow, որը ապահովում է տվյալների գրաֆիկական ձևափոխում Spark-ին նման parallel engines-ի վրա, Stored Procedure Activity, որը գործարկում է SQL stored procedure տվյալների բազայում, Web/HTTP Activity, որը կատարում է վեբ API-ների կանչ տվյալներ ստանալու կամ գործողություն անելու համար, և Execute Pipeline, որը թույլ է տալիս մեկ pipeline-ի կանչը մյուսից՝ բարդ workflows կառուցելու ժամանակ:

Linked Services-ը կապ է, որը սահմանում է, թե ինչպես է ստեղծվում կապը տվյալների աղբյուրի և նպատակային սերվիսի հետ: Այն պարունակում է connection string, authentication տվյալներ և endpoint հասցե: Օրինակներ են Azure Blob Storage, Azure SQL Database, On-premises SQL Server, Amazon S3, Salesforce և Oracle: Linked Services-ը ADF-ի օբյեկտների միջև կապերի հաստատման գործիքն է:

Dataset-ը ներկայացնում է այն տվյալային օբյեկտը, որի վրա աշխատում են activity-ները: Այն նկարագրում է տվյալների տեսակը, սխեման, ֆայլի ձևաչափը (CSV, JSON, Parquet): Dataset-ը տվյալներն ինքնին չեն, այլ դրանց ներկայացումն է:

Integration Runtime-ը ADF-ի հաշվարկային ենթակառուցվածքն է, որը իրականացնում է տվյալների փոխանցումն ու ձևափոխումը: Այն է engine-ը, որը ֆիզիկապես կատարում է Copy Activity-ը, Data Flow-ը և այլ transform-ներ: IR-ի տեսակներն են Azure IR, որը ամբողջությամբ կառավարվում է Azure-ի կողմից և օգտագործվում է cloud-to-cloud տվյալների շարժի համար, աշխատելով առանձ

սերվեր, Self-hosted IR, որը տեղակայվում է օգտագործողի սեփական on-premises կամ VM միջավայրում և թույլ է տալիս աշխատել firewalled միջավայրերում On-premises ↔ Cloud տվյալների շարժի համար, և Azure SSIS IR, որը նախատեսված է SSIS (SQL Server Integration Services) packages-ները փոխադրել Azure և աշխատում է որպես լիարժեք SSIS կատարման միջավայր ամպում:

Azure Synapse և Azure Databricks

Ժամանակակից թվային դարաշրջանում տվյալները դարձել են կազմակերպությունների, պետական կառույցների և նույնիսկ անհատների գործունեության կենտրոնական բաղադրիչը: Տվյալների քանակը տարեցտարի աճում է երկրաչափական պրոգրեսիայով, և եթե մի քանի տասնամյակ առաջ հիմնականում աշխատում էինք մեգաբայթների կամ գիգաբայթների ծավալի տվյալների հետ, ապա այսօր խոսքը հաճախ գնում է տերաբայթների, պետաբայթների և նույնիսկ էկսաբայթների մասին: Այս փոփոխությունը պայմանավորված է ինտերնետի տարածմամբ, սմարթֆոնների լայն կիրառմամբ, սոցիալական ցանցերի ակտիվ օգտագործմամբ, ինչպես նաև արդյունաբերական IoT սարքերի և սենսորների զանգվածային ներմուծմամբ: Այս պայմաններում առաջացել է մեծ տվյալների կառավարման և իրական ժամանակի վերլուծության անհրաժեշտություն, ինչի համար ամպային տեխնոլոգիաները դարձել են առանցքային լուծում:

Microsoft ընկերության ամպային հարթակը՝ Microsoft Azure, հանդիսանում է աշխարհի առաջատար ամպային ենթակառուցվածքներից մեկը: Այն տրամադրում է հաշվարկային, պահեստային, ցանցային և անալիտիկ ծառայությունների լայն շրջանակ: Տվյալների վերլուծության ոլորտում առանձնահատուկ կարևորություն ունեն Azure Databricks և Azure Synapse Analytics հարթակները, որոնք թեև ծառայում են տարբեր նպատակների, սակայն հաճախ օգտագործվում են նույն ժամանակակից տվյալային ճարտարապետության շրջանակներում:

Մեծ տվյալների գաղափարը սովորաբար նկարագրվում է ծավալի, արագության և բազմազանության երեք հիմնական բնութագրիչներով: Ծավալը վերաբերում է տվյալների մեծ քանակին, արագությունը՝ դրանց ստեղծման և փոխանցման բարձր տեմպին, իսկ բազմազանությունը՝ տվյալների տարբեր ձևաչափերին: Ժամանակակից կազմակերպությունները մշակում են ոչ միայն աղյուսակային տվյալներ, այլ նաև տեքստային փաստաթղթեր, պատկերներ, վիդեոներ, լոգ-ֆայլեր և սենսորային հոսքեր: Իրական ժամանակի անալիտիկան նշանակում է, որ այդ տվյալները պետք է մշակվեն գրեթե անմիջապես՝ առանց երկար սպասման: Օրինակ, առցանց վճարումների համակարգը պետք է վայրկյանների ընթացքում որոշի՝ արդյոք գործարքը կասկածելի է, թե ոչ: Նույն կերպ, արտադրական ձեռնարկությունում սենսորային տվյալների մշակումն անհրաժեշտ է սարքավորումների անսարքությունները կանխատեսելու համար:

Azure Databricks-ը ստեղծվել է որպես համատեղ լուծում Microsoft-ի և Databricks ընկերության միջև: Այն հիմնված է Apache Spark տեխնոլոգիայի վրա, որը բաշխված հաշվարկային հարթակ է մեծ տվյալների մշակման համար: Spark-ը թույլ է տալիս տվյալները բաժանել փոքր հատվածների և մշակել դրանք զուգահեռ տարբեր հաշվարկային հանգույցներում: Այս մոտեցումը զգալիորեն բարձրացնում է կատարողականությունը և նվազեցնում մշակման ժամանակը: Databricks-ը Spark-ի վրա կառուցելով՝ առաջարկում է օպտիմիզացված, կառավարվող միջավայր Azure ամպում, որտեղ օգտատերերը կարող են ստեղծել կլաստերներ, աշխատել notebook միջավայրում և կատարել բարդ տվյալային փոխակերպումներ:

Databricks-ի հիմնական կիրառման ոլորտներից մեկը տվյալների ինժեներիան է: Տվյալների ինժեներները պատասխանատու են տվյալների ներմուծման, մաքրման,

փոխակերպման և պահպանման գործընթացների համար: Databricks-ում հնարավոր է իրականացնել ինչպես batch, այնպես էլ streaming մշակում: Batch մշակումն օգտագործվում է, երբ տվյալները կուտակվում են որոշակի ժամանակահատվածում և հետո մշակվում միասնական փաթեթով: Streaming մշակումն օգտագործվում է, երբ տվյալները մշտապես հոսում են համակարգ և պահանջում են անմիջական արձագանք: Spark Structured Streaming տեխնոլոգիան թույլ է տալիս մշակել հոսքային տվյալները նույն ծրագրավորման մոդելով, ինչ batch տվյալները, ինչը մեծապես պարզեցնում է ծրագրավորման գործընթացը:

Databricks-ի կարևոր բաղադրիչ է Delta Lake տեխնոլոգիան, որը ներդնում է տվյալների լճում տրանզակցիոն հատկություններ: Ավանդաբար տվյալների լիճը պարզապես ֆայլային պահեստ է, որտեղ տվյալները պահվում են տարբեր ձևաչափերով: Սակայն առանց տրանզակցիոն մեխանիզմների կարող են առաջանալ տվյալների անհամապատասխանություններ: Delta Lake-ը ապահովում է ACID հատկություններ, տվյալների վերսիանավորում և schema enforcement: Սա հատկապես կարևոր է մեծ կազմակերպություններում, որտեղ տվյալների որակը և հուսալիությունը առաջնային նշանակություն ունեն:

Մեքենայական ուսուցումը ևս կարևոր ուղղություն է Databricks-ի համար: Տվյալագիտության թիմերը կարող են օգտագործել Python և ML գրադարաններ, օրինակ՝ TensorFlow կամ PyTorch, մոդելների ուսուցման համար: Spark-ի բաշխված բնույթը թույլ է տալիս մոդելները ուսուցանել մեծ ծավալի տվյալների վրա: Բացի այդ, Databricks-ը աջակցում է ML lifecycle կառավարմանը, ներառյալ մոդելների փորձարկումը, վերսիանավորումը և տեղակայումը:

Azure Synapse Analytics-ը, մյուս կողմից, ավելի լայնածավալ անալիտիկ հարթակ է, որը համատեղում է տվյալների պահեստավորումը և մեծ տվյալների մշակումը: Այն նախատեսված է enterprise մակարդակի կազմակերպությունների համար, որոնք ունեն մեծ քանակի կառուցվածքային տվյալներ և օգտագործում են SQL հարցումներ բիզնես վերլուծությունների համար: Synapse-ում կարելի է ստեղծել dedicated SQL pool, որը տրամադրում է բարձր կատարողականությամբ բաշխված տվյալների պահեստ: Այս լուծումը հատկապես հարմար է մեծ հաշվետվությունների և բարդ հարցումների համար:

Synapse-ը նաև տրամադրում է serverless SQL հնարավորություններ, որոնք թույլ են տալիս ուղղակիորեն հարցումներ կատարել տվյալների լճում պահվող ֆայլերի վրա՝ առանց դրանք նախապես բեռնելու տվյալների պահեստ: Սա ապահովում է ճկունություն և ծախսերի օպտիմալացում, քանի որ օգտատերը վճարում է միայն կատարված հարցումների համար: Բացի այդ, Synapse-ում առկա է Spark pool, ինչը նշանակում է, որ այն կարող է իրականացնել նաև բաշխված տվյալների մշակում՝ նման Databricks-ին, սակայն ավելի ինտեգրված միջավայրում:

Synapse-ի առավելություններից մեկն այն է, որ այն ինտեգրված է Azure-ի մյուս ծառայությունների հետ: Տվյալների ներմուծման համար կարելի է օգտագործել Azure Data Factory կամ Synapse Pipelines, տվյալների պահեստավորման համար՝ Azure Data Lake Storage, իսկ վիզուալիզացիայի համար՝ Power BI: Այս ամբողջական էկոհամակարգը թույլ է տալիս կառուցել վերջից վերջ տվյալային լուծումներ մեկ ամպային հարթակի շրջանակներում:

Եթե համեմատենք երկու հարթակները, կարելի է ասել, որ Databricks-ը ավելի շատ ուղղված է ծրագրավորողներին և տվյալագետներին, իսկ Synapse-ը՝ տվյալների ճարտարապետներին և բիզնես վերլուծաբաններին: Databricks-ը առանձնանում է իր ճկունությամբ և բաց էկոհամակարգով, մինչդեռ Synapse-ը առաջարկում է ավելի կառավարվող և կենտրոնացված միջավայր: Այնուամենայնիվ, դրանք մրցակիցներ չեն, այլ փոխլրացնող լուծումներ: Շատ կազմակերպություններ ընտրում են հիբրիդային մոտեցում, որտեղ Databricks-ը օգտագործվում է տվյալների նախնական մշակման և մեքենայական ուսուցման համար, իսկ Synapse-ը՝ վերջնական վերլուծությունների և հաշվետվությունների համար:

Իրական ժամանակի տվյալների անալիտիկայի ամբողջական ճարտարապետությունը սովորաբար ներառում է տվյալների ներմուծման շերտ, մշակման շերտ, պահպանման շերտ և վիզուալիզացիայի շերտ: Տվյալները կարող են մուտք գործել համակարգ Azure Event Hub-ի կամ IoT Hub-ի միջոցով, այնուհետև մշակվել Databricks-ում կամ Synapse Spark pool-ում, պահպանվել Data Lake-ում կամ SQL pool-ում և վերջում ներկայացվել Power BI-ի միջոցով: Այսպիսի ճարտարապետությունը ապահովում է բարձր մասշտաբելիություն, ճկունություն և հուսալիություն:

Ժամանակակից կազմակերպությունների համար կարևոր է ոչ միայն տվյալների հավաքումը, այլ նաև դրանցից արժեք ստեղծելը: Իրական ժամանակի անալիտիկան թույլ է տալիս արագ արձագանքել շուկայական փոփոխություններին, կանխատեսել հաճախորդների վարքագիծը և օպտիմալացնել ներքին գործընթացները: Azure Databricks և Azure Synapse Analytics ծառայությունները հանդիսանում են այս նպատակին հասնելու հզոր գործիքներ: Դրանք հնարավորություն են տալիս կառուցել ժամանակակից տվյալային հարթակներ, որոնք միավորում են մեծ տվյալների մշակումը, մեքենայական ուսուցումը և բիզնես վերլուծությունը մեկ միասնական էկոհամակարգում:

Այսպիսով, կարելի է եզրակացնել, որ Azure-ի տվյալային ծառայությունները կարևոր դեր ունեն թվային փոխակերպման գործընթացում: Դրանք ապահովում են մասշտաբելի, ճկուն և բարձր արդյունավետությամբ միջավայր, որը կարող է հարմարվել ինչպես փոքր կազմակերպությունների, այնպես էլ գլոբալ ձեռնարկությունների պահանջներին: Իրական ժամանակի անալիտիկան այլևս ապագայի տեխնոլոգիա չէ, այլ ներկայի անհրաժեշտություն, և Azure-ի հարթակները հնարավորություն են տալիս արդյունավետորեն իրականացնել այդ պահանջները:

Գլխի ամփոփում

Azure-ը ապահովում է միասնական միջավայր, որտեղ տվյալների հավաքագրումը, փոխանցումը, պահպանումը և վերլուծությունը իրականացվում են նույն հարթակի վրա՝ բարձր արդյունավետության և ավտոմատացման մակարդակով: Այս մոդելը թույլ է տալիս կազմակերպություններին արագ կառուցել տեխնոլոգիական լուծումներ՝ առանց բարդ ենթակառուցվածք կազմակերպելու:

Տվյալների շարժի և կառավարման միասնական մոտեցումը ապահովվում է Azure Data Factory-ի միջոցով, որը կարգավորում է տվյալների հոսքերի ամբողջական ցիկլը՝ թույլ տալով կապել տարբեր բիզնես համակարգեր, ավտոմատացնել ժամանակացույցով գործընթացներ և ապահովել տվյալների մշտական թարմացում: Սա դարձնում է տվյալային ճարտարապետությունը կանխատեսելի, վերահսկվող և ճկուն:

Azure-ի տվյալային ծառայությունները համակցված աշխատելով ապահովում են տվյալների ճշգրտությունը, վերահսկվող շարժ, բռնկումների և սխալների ավտոմատ մշակելիություն, ինչպես նաև տվյալների հասանելիություն տարբեր թիմերի և գործիքների համար:

Վերլուծության և որոշումների արագացման համար Azure-ի վերլուծական ծառայությունները անմիջապես օգտագործում են Data Factory-ի միջոցով բեռնված և մշակված տվյալները, ինչը թույլ է տալիս ստեղծել իրական ժամանակի dashboard-ներ, կատարել պատմական տվյալների խորքային վերլուծություն, արագ պատրաստել մեքենայական ուսուցման մոդելներ և ընդունել բիզնես որոշումներ:

Բիզնեսի պահանջներին համապատասխան Azure-ը ապահովում է ճկունություն՝ թույլ տալով տարբեր աշխատանքաներ տեղափոխել ամպ, ընդլայնել կամ նվազեցնել ռեսուրսները ըստ պահանջի: Սա հատկապես կարևոր է այն կազմակերպությունների համար, որոնք աշխատում են մեծ տվյալների ծավալներով կամ ունեն փոփոխական բեռնվածություն:

Գլուխ 2: ECL-ի Նշանակությունը և Հաշվարկելու Եղանակը

Ներածություն

Վարկային ռիսկի կառավարման ժամանակակից համակարգում Expected Credit Loss-ը (ECL) հանդիսանում է ոչ միայն հաշվարկային ցուցանիշ, այլ ամբողջական մեթոդաբանական մոտեցում, որը վերափոխել է ֆինանսական ակտիվների արժեզրկման տրամաբանությունը: Եթե նախկինում բանկային համակարգում գերակշռում էր «իրականացած կորուստների» մոդելը, այսինքն՝ պահուստները ձևավորվում էին այն պահին, երբ արդեն առկա էր օբյեկտիվ ապացույց, որ վարկառուն չի կատարելու իր պարտավորությունները, ապա ECL մոտեցումը հիմնված է առաջատեսական (forward-looking) գնահատման վրա: Սա նշանակում է, որ ֆինանսական հաստատությունը պարտավոր է դեռևս վարկի տրամադրման կամ հաշվետու ժամանակահատվածի ընթացքում գնահատել այն ռիսկը, որ ապագայում կարող է առաջանալ կորուստ, նույնիսկ եթե տվյալ պահին որևէ դեֆոլտ կամ ուշացում դեռևս չի գրանցվել:

ECL-ի գաղափարախոսությունը հատկապես կարևոր դարձավ International Financial Reporting Standards շրջանակում հրապարակված ՖՀՄՍ 9 ստանդարտի ներդրումից հետո: ՖՀՄՍ 9-ը փոխարինեց նախկին IAS 39 ստանդարտին և արմատապես փոխեց արժեզրկման հաշվառման մոտեցումը: Եթե IAS 39-ը հիմնված էր incurred loss model-ի վրա, ապա ՖՀՄՍ 9-ը ներդրեց expected credit loss model-ը, որը պահանջում է հաշվարկել սպասվող կորուստները նույնիսկ այն դեպքում, երբ դեֆոլտի օբյեկտիվ ապացույց չկա: Սա մեծ ազդեցություն ունեցավ ինչպես հաշվապահական հաշվառման, այնպես էլ ռիսկերի կառավարման գործընթացների վրա:

ՖՀՄՍ 9-ի շրջանակում սահմանվում է երեք փուլանոց մոդել, ըստ որի ֆինանսական ակտիվները դասակարգվում են՝ կախված վարկային ռիսկի փոփոխությունից: Առաջին փուլում ներառվում են այն ակտիվները, որոնց վարկային ռիսկը էականորեն չի աճել սկզբնական ճանաչումից հետո, և դրանց համար հաշվարկվում է 12-ամսյա ECL: Երկրորդ փուլում ներառվում են ակտիվները, որոնց վարկային ռիսկը էականորեն աճել է, սակայն դեֆոլտ չի արձանագրվել, և այստեղ հաշվարկվում է ամբողջ ժամկետային ECL: Երրորդ փուլում ներառվում են դեֆոլտային ակտիվները, որոնց համար նույնպես հաշվարկվում է lifetime ECL, սակայն տոկոսային եկամուտը հաշվարկվում է զուտ հաշվեկշռային արժեքից: Այս փուլային մոտեցումը ապահովում է, որ ռիսկի աճը ժամանակին արտացոլվի ֆինանսական հաշվետվություններում:

ECL-ի կիրառումը միայն հաշվապահական պահանջ չէ. այն դարձել է ռազմավարական գործիք վարկային պորտֆելի կառավարման համար: Բանկերը ECL հաշվարկների միջոցով գնահատում են, թե որ հատվածներում է ռիսկը կենտրոնացված, ինչպիսի դինամիկա ունի պորտֆելը մակրոտնտեսական փոփոխությունների պայմաններում, և ինչպես պետք է օպտիմալացվի վարկային քաղաքականությունը: Օրինակ, եթե մակրոտնտեսական կանխատեսումները ցույց են տալիս գործազրկության աճ կամ ՀՆԱ-ի անկում, ապա ECL մոդելները պետք է ներառեն այդ տեղեկատվությունը և վերագնահատեն դեֆոլտի հավանականությունները: Սա նշանակում է, որ ECL-ը

սերտորեն կապված է սցենարային վերլուծության և սթրես-թեստավորման գործընթացների հետ:

Ֆինանսական հաշվետվությունների պատրաստման տեսանկյունից ECL-ը ուղղակիորեն ազդում է շահույթի և վնասի հաշվետվության, ինչպես նաև հաշվեկշռի վրա: Սպասվող կորուստների աճը հանգեցնում է ավելի մեծ պահուստների ձևավորմանը, ինչը նվազեցնում է հաշվետու շահույթը և ակտիվների հաշվեկշռային արժեքը: Հետևաբար, ECL-ի գնահատումը դառնում է ոչ միայն տեխնիկական խնդիր, այլ նաև կառավարման և վերահսկողության կարևոր գործիք, քանի որ այն կարող է էական ազդեցություն ունենալ կազմակերպության ֆինանսական ցուցանիշների վրա:

Ռիսկերի մոնիթորինգի գործընթացում ECL-ը ծառայում է որպես վաղ ազդանշանային մեխանիզմ: Քանի որ այն հիմնված է առաջատեսական տեղեկատվության վրա, նույնիսկ փոքր փոփոխությունները վարկառուների վարքագծում կամ տնտեսական միջավայրում կարող են արտացոլվել ECL հաշվարկներում: Սա հնարավորություն է տալիս բանկերին ժամանակին վերանայել վարկային սահմանաչափերը, խստացնել կամ մեղմացնել վարկավորման չափանիշները և վերակառուցել պորտֆելը՝ նվազեցնելով համակարգային ռիսկերը:

Կապիտալի բավարարության գնահատման տեսանկյունից ECL-ը նույնպես ունի կարևոր դեր: Թեև կարգավորող կապիտալի հաշվարկը իրականացվում է Բազելյան համաձայնագրերի շրջանակում, nevertheless հաշվապահական պահուստների մակարդակը կարող է ազդել սեփական կապիտալի չափի վրա: Բարձր ECL պահուստները նվազեցնում են զուտ ակտիվները և կարող են ազդել կապիտալի համարժեքության ցուցանիշների վրա: Այդ պատճառով բանկերը ձգտում են կառուցել ճշգրիտ, վիճակագրորեն հիմնավորված մոդելներ, որոնք հավասարակշռում են պահպանողականությունն ու ռեալիզմը:

ECL-ը կիրառվում է տարբեր տեսակի ֆինանսական գործիքների համար՝ ներառյալ դասական սպառողական վարկերը, հիպոթեքային վարկերը, կորպորատիվ վարկային գծերը, օվերդրաֆտները և վարկային քարտերը: Յուրաքանչյուր գործիքի համար մոդելավորման առանձնահատկությունները կարող են տարբեր լինել: Օրինակ, վարկային քարտերի դեպքում կարևոր է ոչ միայն ընթացիկ պարտքի չափը, այլ նաև ապագա օգտագործման հնարավորությունը, ինչը բարդացնում է Exposure at Default-ի գնահատումը: Հիպոթեքային վարկերի դեպքում էական դեր է խաղում գրավի արժեքը և դրա փոփոխականությունը շուկայում: Կորպորատիվ վարկերի դեպքում հաճախ օգտագործվում են ֆինանսական ցուցանիշներ, ինչպիսիք են պարտք/եկամուտ հարաբերակցությունը կամ դրամական հոսքերի կայունությունը:

Բացի այդ, ECL մոդելները պետք է համապատասխանեն մի շարք որակական պահանջների: Դրանք պետք է լինեն վիճակագրորեն հիմնավորված, վերարտադրելի, թափանցիկ և վավերացված անկախ ստորաբաժանումների կողմից: Մոդելների վալիդացիան ներառում է հետադարձ փորձարկում (backtesting), սենսիտիվության վերլուծություն և կանխատեսումների ճշգրտության գնահատում: Սա ապահովում է, որ հաշվարկված ECL ցուցանիշը լինի վստահելի և համապատասխանի իրական ռիսկային պրոֆիլին:

Այսպիսով, Expected Credit Loss-ը հանդիսանում է ժամանակակից ֆինանսական կառավարման առանցքային բաղադրիչ, որը միավորում է հաշվապահական ստանդարտները, վիճակագրական մոդելավորումը, մակրոտնտեսական

կանխատեսումները և ռազմավարական որոշումների կայացումը։ Այն փոխել է վարկային ռիսկի գնահատման մշակույթը՝ դարձնելով այն ավելի առաջատեսական, տվյալահեն և ինտեգրված ֆինանսական կառավարման համակարգի մեջ։

ECL-ի Հաշվարկելու Եղանակը

ECL-ի հիմնական բաղադրիչներն են Probability of Default (PD), Loss Given Default (LGD) և Exposure at Default (EAD)։ Ընդհանուր բանաձևը կարելի է ներկայացնել հետևյալ կերպ.

$$ECL = PD \times EAD \times LGD$$

Եթե հաշվի ենք առնում ժամանակային դիսկոնտավորումը, ապա բազմափուլ մոդելի դեպքում ընդհանուր ձևը կլինի

$$ECL = \sum_{t=0}^{T} PD_t \times EAD_t \times LGD_t$$

որտեղ $DF_t = \frac{1}{(1+\mathrm{r})^t}$ դիսկոնտավորման գործակիցն է, r-ը՝ արդյունավետ տոկոսադրույքը, իսկ T-ը՝ դիտարկվող ժամանակահատվածը։

PD Գործակիցը, Մեքենայական Ուսուցումը և Լոգիստիկ Ռեգրեսիան

PD գործակիցը (Probability of Default) հանդիսանում է առանցքային ցուցանիշներից մեկը, որը արտացոլում է տվյալ վարկառուի կամ պարտապանի դեֆոլտի հավանականությունը որոշակի ժամանակահատվածում: Դեֆոլտ ասելով սովորաբար հասկանում են այն իրավիճակը, երբ վարկառուն չի կարողանում կատարել իր պարտավորությունները՝ համաձայն պայմանագրի, օրինակ՝ չի կատարում վճարումները սահմանված ժամկետներում: PD-ն արտահայտվում է հավանականության տեսքով և ցույց է տալիս, թե ինչ տոկոս հավանականությամբ է սպասվում, որ տվյալ սուբյեկտը կդառնա դեֆոլտային մեկ տարվա կամ այլ կանխորոշված հորիզոնի ընթացքում:

PD գործակիցը կարևոր դեր է խաղում վարկային պորտֆելի գնահատման, գնագոյացման և կապիտալի պահանջների հաշվարկման գործընթացներում: Այն օգտագործվում է ինչպես առանձին վարկերի ռիսկայնությունը գնահատելու, այնպես էլ ամբողջ պորտֆելի ռիսկային կառուցվածքը հասկանալու համար: Որքան բարձր է PD-ն, այնքան բարձր է տվյալ վարկառուի ռիսկայնությունը և, համապատասխանաբար, բանկը կարող է կիրառել ավելի խիստ պայմաններ կամ բարձր տոկոսադրույք՝ ռիսկը փոխհատուցելու նպատակով: PD-ն նաև հանդիսանում է Expected Credit Loss մոտեցման կարևոր բաղադրիչներից մեկը, քանի որ սպասվող վարկային կորուստների գնահատման համար անհրաժեշտ է իմանալ դեֆոլտի հավանականությունը:

Ժամանակակից ֆինանսական կազմակերպություններում PD-ի գնահատումը հաճախ իրականացվում է մեքենայական ուսուցման մոդելների միջոցով: Մեքենայական ուսուցումը հնարավորություն է տալիս մեծ ծավալի պատմական տվյալների հիման վրա հայտնաբերել օրինաչափություններ և կապեր, որոնք կարող են կանխատեսել վարկառուի վարքագիծը: Տվյալների շարքում կարող են ներառվել ֆինանսական ցուցանիշներ, եկամուտներ, ծախսեր, վարկային պատմություն, սոցիալ-դեմոգրաֆիկ հատկանիշներ և այլ գործոններ: Մոդելները սովորում են պատմական դեպքերից՝ տարբերակելով դեֆոլտային և ոչ դեֆոլտային հաճախորդներին, և արդյունքում յուրաքանչյուր նոր հաճախորդի համար հաշվարկում են դեֆոլտի հավանականություն:

Մեքենայական ուսուցման ոլորտում կիրառվում են ինչպես դասական վիճակագրական մեթոդներ, այնպես էլ ավելի բարդ ալգորիթմներ, օրինակ՝ որոշման ծառեր, անտառային մեթոդներ, նեյրոնային ցանցեր և գրաֆային մոդելներ: Այս մոդելների առավելությունն այն է, որ կարողանում են հաշվի առնել ոչ գծային կապեր և փոխազդեցություններ տարբեր հատկանիշների միջև: Սակայն ֆինանսական ոլորտում կարևոր է նաև մոդելի թափանցիկությունն ու բացատրելիությունը, քանի որ կարգավորող մարմինները պահանջում են հասկանալ, թե ինչու է մոդելը տվյալ հաճախորդին գնահատել բարձր կամ ցածր ռիսկային:

PD-ի գնահատման համար առավել լայնորեն կիրառվող մեթոդներից մեկը լոգիստիկ ռեգրեսիան է։ Լոգիստիկ ռեգրեսիան դասակարգման մոդել է, որը նախատեսված է երկու հնարավոր արդյունք ունեցող խնդիրների համար, օրինակ՝ դեֆոլտ և ոչ դեֆոլտ։ Այն գնահատում է, թե ինչպես են տարբեր անկախ փոփոխականները ազդում դեֆոլտի հավանականության վրա։ Մոդելը յուրաքանչյուր հաճախորդի համար վերադարձնում է հավանականություն, որը գտնվում է զրոյից մեկ միջակայքում, և այդ արժեքը մեկնաբանվում է որպես PD։

Լոգիստիկ ռեգրեսիայի կարևոր առավելություններից մեկը դրա պարզությունն ու մեկնաբանելիությունն է։ Յուրաքանչյուր փոփոխականի ազդեցությունը կարելի է առանձին գնահատել և հասկանալ՝ արդյոք տվյալ գործոնը մեծացնում է, թե նվազեցնում դեֆոլտի հավանականությունը։ Սա հատկապես կարևոր է բանկային միջավայրում, որտեղ անհրաժեշտ է հիմնավորել վարկային որոշումները։ Բացի այդ, լոգիստիկ ռեգրեսիան համեմատաբար կայուն է, արագ է ուսուցանվում և լավ է աշխատում, երբ տվյալների միջև հարաբերությունները մոտավորապես գծային են լոգ-հավանականության տարածքում։

Միևնույն ժամանակ, եթե տվյալներում առկա են բարդ, ոչ գծային կախվածություններ, լոգիստիկ ռեգրեսիան կարող է զիջել ավելի բարդ մեքենայական ուսուցման մեթոդներին։ Այդ պատճառով հաճախ կիրառվում է համակցված մոտեցում, երբ լոգիստիկ ռեգրեսիան օգտագործվում է որպես բազային մոդել կամ բենչմարկ, իսկ ավելի առաջադեմ ալգորիթմները՝ որպես համեմատական կամ լրացուցիչ գործիք։

Ընդհանուր առմամբ, PD գործակիցը վարկային ռիսկի կառավարման հիմնարար ցուցանիշ է, որի ճշգրիտ գնահատումը կարևոր է ինչպես ֆինանսական կայունության, այնպես էլ շահութաբերության տեսանկյունից։ Մեքենայական ուսուցման մեթոդները, հատկապես լոգիստիկ ռեգրեսիան, ապահովում են արդյունավետ և գործնական գործիքակազմ՝ դեֆոլտի հավանականության գնահատման և ռիսկերի կանխատեսման համար ժամանակակից ֆինանսական համակարգում։

Լոգիստիկ ռեգրեսիան հիմնվում է լոգիստիկ (կամ սիգմոիդային) ֆունկցիայի վրա՝ դիտարկվող օբյեկտի որևէ դասին պատկանելու հավանականությունը մոդելավորելու համար։ Այդ ֆունկցիան ունի հետևյալ տեսքը.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

որտեղ z-ը մուտքային փոփոխականների գծային կոմբինացիա է։ Սիգմոիդային ֆունկցիան ընդունում է ցանկացած իրական թիվ, բայց այն փոխակերպում է 0–1 տիրույթի արժեքների, ինչը հարմար է արդյունքը հավանականության տեսանկյունից մեկնաբանելու համար։ Բինար դասակարգման դեպքում թիրախային փոփոխականը y ընդունում է 0 կամ 1 արժեքներ, և խնդիրն է կանխատեսել հավանականությունը՝

$$P(y = 1|X)$$

որտեղ X-ը հատկանիշների վեկտորն է:

Լոգիստիկ ռեգրեսիայի մոդելը՝

$$P(y = 1|X) = \sigma(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n)$$

որտեղ β_0-ը ազատ անդամն է, իսկ $\beta_1 \ldots \beta_n$-ը՝ մոդելի պարամետրերը, որոնք որոշում են անկախ փոփոխականների ներդրումը արդյունքի կանխատեսման գործում:

Հավանականության առավելագույնացում (Maximum Likelihood Estimation)

Լոգիստիկ ռեգրեսիայի պարամետրերը գնահատվում են առավելագույն հավանականության մեթոդով: Ընտրվում են այնպիսի β արժեքներ, որոնք առավելագույնի են հասցնում դիտարկված տվյալների ստացման հավանականությունը:

Հավանականության ֆունկցիան ներկայացվում է այսպես՝

$$L(\beta) = \prod_{i=1}^{m} P(y_i|X_i;\beta)^{y_i}(1 - P(y_i|X_i;\beta))^{1-y_i}$$

որտեղ m-ը դիտարկումների քանակն է:

Հաճախ օգտագործում են նաև լոգ-հավանականությունը՝ հաշվարկները պարզեցնելու համար.

$$LogL(\beta) = \sum_{i=1}^{m} [y_i log P(y_i|X_i;\beta) + (1 - y_i) log(1 - P(y_i|X_i;\beta))]$$

Լոգ-հավանականության առավելագույնացումը թույլ է տալիս գտնել β-ի օպտիմալ արժեքները՝ օգտագործելով թվային մեթոդներ, օրինակ՝ գրադիենտային իջեցում կամ Նյուտոն–Ռաֆսոնի մեթոդ:

Լոգիստիկ ռեգրեսիայի համակցությունների մեկնաբանություն

Գծային ռեգրեսիայի դեպքում համակցությունները ցույց են տալիս, թե որքանով է փոխվում ելքային արժեքը անկախ փոփոխականի մեկ միավորով փոփոխման դեպքում: Սակայն լոգիստիկ ռեգրեսիայում β_i–ի մեկնաբանությունն այլ է:

Լոգիստիկ ռեգրեսիայի համակցությունները ցույց են տալիս, թե ինչպես է փոփոխականը ազդում շանսերի լոգարիթմի վրա.

$$log\left(\frac{P(y = 1|X)}{1 - P(y = 1|X)}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

Այսպիսով, β_i-ն ցույց է տալիս՝ որքանով է փոխվում շանսերի լոգարիթմը x_i-ի մեկ միավորով փոփոխման դեպքում։ Սա հնարավորություն է տալիս գնահատել հատկանիշների կարևորությունը մոդելի մեջ։

Մոդելի որակի գնահատում

Քանի որ լոգիստիկ ռեգրեսիան կանխատեսում է հավանականություն, այլ ոչ թե կոնկրետ արժեք, դրա որակի գնահատման համար օգտագործվում են հատուկ մետրիկաներ.

Խառնումների մատրիցա (Confusion Matrix) — ցույց է տալիս ճիշտ և սխալ կանխատեսումների քանակը։

$$\text{ճշտություն } (Accuracy): \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Լրիվություն } (Recall): \frac{TP}{TP + TN}$$

$$\text{ճշգրտություն } (Precision): \frac{TP}{TP + FP}$$

$$F_1 - \text{մետրիկա}: \frac{2 \times Precision \times Recall}{Precision + Recall}$$

ROC կոր և AUC — մոդելի արդյունավետության գնահատում տարբեր շեմերի դեպքում։

Բազմադասային լոգիստիկ ռեգրեսիա

Լոգիստիկ ռեգրեսիան կարող է ընդլայնվել բազմադասային խնդրի համար։ Ամենատարածված մոտեցումները հետևյալն են՝ One-vs-Rest (OvR) — յուրաքանչյուր դասի համար կառուցվում է առանձին դասակարգիչ, One-vs-One (OvO) — դասակարգիչ ամեն զույգ դասերի համար, ապա ընտրություն՝ քվեարկությամբ։

Այս մոտեցումը օգտակար է, օրինակ, պատկերների կատեգորիաների կամ ձեռագիր թվանշանների ճանաչման խնդիրներում։

Լոգիստիկ ռեգրեսիայի կիրառումը

Լոգիստիկ ռեգրեսիան լայնորեն կիրառվում է ինչպես բինար, այնպես էլ բազմադասային խնդիրներում, բժշկություն — հիվանդության առկայության հավանականության գնահատում, մարկետինգ — հաճախորդի արձագանքի հավանականության կանխատեսում, ֆինանսներ — վարկի չվճարման կամ այլ ռիսկային իրադարձությունների կանխատեսում, հասարակագիտություն —

սոցիալական խմբերին կամ վարքագծային կատեգորիաներին պատկանելու հավանականություն:

Լոգիստիկ ռեգրեսիայի սահմանափակումները

Չնայած իր լայն կիրառությանը՝ լոգիստիկ ռեգրեսիան ունի մի շարք սահմանափակումներ՝ գծայնության ենթադրություն — ենթադրում է գծային կապ անկախ փոփոխականների և շանսերի լոգարիթմի միջև, ինչը միշտ չէ, որ համապատասխանում է իրականությանը, զգայունություն արտախմբային արժեքների նկատմամբ — տվյալների արտառոց կետերը կարող են էապես խաթարել արդյունքները, բազմակոլլինեարության խնդիրներ — բարձրորեն փոխկապակցված հատկանիշները հանգեցնում են անկայուն և դժվար մեկնաբանվող համակցությունների[1]:

[1]https://zhanibekov.edu.kz/media/university/faculties/materials/%D0%9B%D0%B5%D0%BA%D1%86%D0%B8%D1%8F_4_1.pdf

EAD Գործակիցը

EAD գործակիցը (Exposure at Default) վարկային ռիսկի կառավարման կարևորագույն ցուցանիշներից մեկն է, որը ցույց է տալիս, թե դեֆոլտի պահին ինչ չափի պարտավորություն է առկա վարկատուի նկատմամբ։ Այլ կերպ ասած՝ EAD-ն արտացոլում է այն ընդհանուր գումարը, որի նկատմամբ ֆինանսական կազմակերպությունը կրում է ռիսկ այն պահին, երբ վարկառուն դառնում է դեֆոլտային։ Եթե PD-ն ցույց է տալիս դեֆոլտի հավանականությունը, իսկ LGD-ն՝ դեֆոլտի դեպքում կորուստների մասնաբաժինը, ապա EAD-ն սահմանում է այն բազային գումարը, որի վրա այդ կորուստը կիրառվում է։

EAD-ի էությունը կայանում է նրանում, որ վարկային ռիսկը չի սահմանափակվում միայն տվյալ պահին հաշվեկշռում առկա մնացորդով։ Շատ վարկային գործիքներ ունեն չօգտագործված լիմիտներ կամ պայմանական պարտավորություններ, որոնք կարող են ակտիվացվել մինչև դեֆոլտի պահը։ Օրինակ՝ վարկային քարտերի, օվերդրաֆտների կամ վերականգնվող վարկային գծերի դեպքում հաճախորդը կարող է ունենալ հաստատված, բայց դեռ չօգտագործված սահմանաչափ։ Դեֆոլտին նախորդող փուլում հաճախորդը կարող է ամբողջությամբ կամ մասնակիորեն օգտագործել այդ սահմանաչափը, ինչի հետևանքով իրական ռիսկային ազդեցությունը մեծանում է։ EAD-ն հենց այս ամբողջ ազդեցությունն է ներառում իր մեջ։

Տարբեր վարկային պրոդուկտների դեպքում EAD-ի վարքագիծը տարբեր է։ Սպառողական կամ հիփոթեքային դասական վարկերի դեպքում EAD-ն սովորաբար մոտ է դեֆոլտի պահին առկա հիմնական պարտքի մնացորդին, քանի որ այդպիսի վարկերում լրացուցիչ չօգտագործված լիմիտներ սովորաբար չկան։ Սակայն վարկային գծերի, կորպորատիվ ֆինանսավորման պայմանական պարտավորությունների, բանկային երաշխիքների կամ ակրեդիտիվների դեպքում EAD-ն կարող է զգալիորեն տարբերվել հաշվեկշռային մնացորդից։ Այս դեպքում անհրաժեշտ է գնահատել, թե դեֆոլտից առաջ ինչ չափով կարող է աճել պարտավորությունը։

EAD-ի գնահատումը կարևոր է, որովհետև այն անմիջական ազդեցություն ունի ռիսկի ընդհանուր չափի վրա։ Նույն PD և LGD մակարդակների դեպքում ավելի բարձր EAD ունեցող վարկը կնշանակի ավելի մեծ ակնկալվող կորուստ։ Այդ պատճառով ֆինանսական կազմակերպությունները մեծ ուշադրություն են դարձնում ոչ միայն վարկառուի վարքագծին, այլ նաև վարկային պրոդուկտի կառուցվածքին և պայմաններին։ Վարկային քաղաքականության ձևավորման ժամանակ սահմանվում են լիմիտներ և պայմաններ, որոնք նպատակ ունեն վերահսկելու հնարավոր ռիսկային ազդեցությունը դեֆոլտի պահին։

EAD-ի վրա ազդում են ինչպես պայմանագրային, այնպես էլ վարքագծային գործոններ։ Պայմանագրային գործոնների շարքում են վարկի տեսակը, մարման գրաֆիկը, տոկոսադրույքը, լիմիտների առկայությունը և դրանց փոփոխման մեխանիզմները։ Վարքագծային գործոնները կապված են հաճախորդի ֆինանսական

վարքագծի հետ՝ օրինակ՝ արդյոք հաճախորդը հակված է ամբողջությամբ օգտագործել իր վարկային սահմանաչափը ֆինանսական դժվարությունների ժամանակ: Պատմական տվյալների վերլուծությունը ցույց է տալիս, որ որոշ հաճախորդներ դեֆոլտին նախորդող ժամանակահատվածում արագորեն ավելացնում են իրենց պարտավորությունները, ինչը մեծացնում է բանկի ռիսկային ազդեցությունը:

Կորպորատիվ հատվածում EAD-ի գնահատումը կարող է ավելի բարդ լինել, քանի որ ընկերությունները հաճախ ունենում են բազմատեսակ ֆինանսական գործիքներ՝ վարկային գծեր, երաշխիքներ, դերիատիվներ և այլ պայմանական պարտավորություններ: Այդպիսի դեպքերում անհրաժեշտ է համապարփակ գնահատել բոլոր հնարավոր պարտավորությունները, որոնք կարող են իրական դառնալ դեֆոլտի պահին: Սա պահանջում է խորքային վերլուծություն և հաճախ կիրառվում են վիճակագրական կամ սցենարային մեթոդներ՝ տարբեր հնարավոր զարգացումները գնահատելու համար:

Տնտեսական միջավայրն ևս կարող է ազդել EAD-ի վրա: Տնտեսական անկման պայմաններում ընկերությունները կարող են ավելի ակտիվորեն օգտագործել իրենց վարկային գծերը՝ ֆինանսական ճնշումները հաղթահարելու նպատակով: Նման իրավիճակներում դեֆոլտի պահին պարտավորության չափը կարող է լինել ավելի բարձր, քան կայուն տնտեսական պայմաններում: Հետևաբար, ռիսկի կառավարման ժամանակ անհրաժեշտ է հաշվի առնել ոչ միայն պատմական միջին ցուցանիշները, այլ նաև հնարավոր սթրեսային սցենարները:

EAD-ն կարևոր դեր է խաղում նաև կապիտալի պահանջների և ռեզերվների հաշվարկման գործընթացում: Քանի որ այն սահմանում է ռիսկի տակ գտնվող գումարի չափը, դրա փոփոխությունը կարող է զգալիորեն ազդել ֆինանսական հաստատության հաշվեկշռի վրա: Ավելի բարձր EAD-ն նշանակում է ավելի մեծ ռիսկային ակտիվներ և, համապատասխանաբար, ավելի բարձր կապիտալի պահանջներ կարգավորող մարմինների պահանջների համաձայն: Այդ պատճառով EAD-ի ճշգրիտ գնահատումը ռազմավարական նշանակություն ունի ֆինանսական կայունության տեսանկյունից:

Ժամանակակից վարկային ռիսկի կառավարման համակարգերում EAD-ի գնահատման համար օգտագործվում են ինչպես պատմական տվյալների վերլուծություն, այնպես էլ վարքագծային մոդելներ: Վերլուծվում են նախկին դեֆոլտային դեպքերը՝ հասկանալու համար, թե ինչ չափով է աճել պարտավորությունը դեֆոլտից առաջ: Այդ տեղեկատվությունը կիրառվում է ապագա ռիսկերի կանխատեսման համար: Որոշ դեպքերում կիրառվում են մեքենայական ուսուցման մեթոդներ՝ հաճախորդների վարքագծի օրինաչափությունները բացահայտելու նպատակով:

Ընդհանուր առմամբ, EAD գործակիցը ներկայացնում է դեֆոլտի պահին առկա ընդհանուր ռիսկային ազդեցությունը և հանդիսանում է վարկային ռիսկի գնահատման հիմնարար տարրերից մեկը: Այն լրացնում է PD և LGD ցուցանիշներին՝ ապահովելով ամբողջական պատկերացում այն մասին, թե որքան գումար է գտնվում ռիսկի տակ և

ինչ չափի կորուստ կարող է կրել ֆինանսական կազմակերպությունը: Առանց EAD-ի գնահատման հնարավոր չէ իրական և ամբողջական կերպով հասկանալ վարկային ռիսկի ծավալը և արդյունավետորեն կառավարել ֆինանսական հաստատության պորտֆելը: EAD գործակցի բանաձևը.

$$EAD = Drawn\ Amount + (CCF \times Undrawn\ Amount)$$

Որտեղ՝ Drawn Amount-ը ընթացիկ չմարված մնացորդը, CCF (Credit Conversion Factor)-ը չօգտագործված սահմանաչափի տոկոսը, որը սպասվում է, որ կօգտագործվի մինչև դեֆոլտը, Undrawn Amount-ը վարկային սահմանաչափի չօգտագործված մասը: :

LGD Գործակիցը

LGD գործակիցը (Loss Given Default) վարկային ռիսկի կառավարման կարևորագույն ցուցանիշներից մեկն է, որը ցույց է տալիս, թե որքան կորուստ է կրում ֆինանսական կազմակերպությունը այն դեպքում, երբ վարկառուն դառնում է դեֆոլտային։ Այլ կերպ ասած՝ LGD-ն արտացոլում է դեֆոլտի պայմաններում կորցվող գումարի մասնաբաժինը ընդհանուր պարտավորությունից։ Եթե դեֆոլտը տեղի է ունեցել, LGD-ն գնահատում է, թե տվյալ վարկից որքան մասն է հնարավոր վերականգնել և որքանն է փաստացի կորուստ դառնում բանկի կամ վարկատուի համար։

LGD-ի էությունը կապված է վերականգնման գործընթացի հետ։ Երբ վարկառուն չի կատարում իր պարտավորությունները, ֆինանսական կազմակերպությունը սկսում է վերականգնման քայլեր՝ ապահովագրական մեխանիզմների, գրավի իրացման, երաշխավորների ներգրավման կամ իրավական գործընթացների միջոցով։ Սակայն շատ դեպքերում ամբողջ պարտքը հնարավոր չէ վերադարձնել։ LGD-ն հենց այդ բացը բնութագրող ցուցանիշն է։ Այն ցույց է տալիս, թե դեֆոլտից հետո մնացած պարտքի որ մասն է վերջնականապես կորուստ դառնում՝ հաշվի առնելով վերականգնված գումարները։

LGD-ն մեծապես կախված է վարկի տեսակից և ապահովվածության մակարդակից։ Օրինակ՝ գրավով ապահովված վարկերի դեպքում կորուստները սովորաբար ավելի ցածր են, քանի որ բանկը կարող է իրացնել գրավը և վերադարձնել պարտքի մի մասը։ Ի տարբերություն դրա, չապահովված սպառողական վարկերի դեպքում LGD-ն սովորաբար ավելի բարձր է, քանի որ վերականգնման հնարավորությունները սահմանափակ են։ Հետևաբար, նույն վարկառուի դեպքում անգամ տարբեր վարկային պրոդուկտների համար LGD-ն կարող է զգալիորեն տարբերվել։

LGD-ի վրա ազդում են նաև տնտեսական պայմանները։ Տնտեսական անկման ժամանակաշրջաններում ակտիվների շուկայական արժեքը կարող է նվազել, ինչի հետևանքով գրավի իրացումից ստացվող գումարները պակասում են։ Այդպիսի պայմաններում LGD-ն հակված է աճելու։ Ընդհակառակը, տնտեսական աճի պայմաններում վերականգնման մակարդակները կարող են լինել ավելի բարձր, և LGD-ն՝ ավելի ցածր։ Այս պատճառով ֆինանսական հաստատությունները հաճախ գնահատում են LGD-ն ոչ միայն միջին պատմական մակարդակով, այլ նաև սթրեսային սցենարներով։

LGD-ն կարևոր բաղադրիչ է սպասվող վարկային կորուստների գնահատման գործընթացում։ Դեֆոլտի հավանականությունը միայն ցույց է տալիս, թե որքան հավանական է պարտավորության չկատարումը, սակայն չի ասում, թե որքան մեծ կլինի իրական ֆինանսական վնասը։ LGD-ն լրացնում է այդ բացը՝ թույլ տալով հաշվարկել, թե դեֆոլտի դեպքում որքան կորուստ է սպասվում։ Այսպիսով, այն հանդիսանում է ռիսկի քանակականացման հիմնական գործիքներից մեկը և անմիջական ազդեցություն ունի

կապիտալի պահանջների, ռեզերվների ձևավորման և գնագոյացման քաղաքականության վրա։

Վարկային պորտֆելի կառավարման տեսանկյունից LGD-ն օգտագործվում է ռիսկերի տարբերակման նպատակով։ Բանկերը կարող են ունենալ երկու վարկային պորտֆել՝ նույն PD մակարդակով, սակայն տարբեր LGD ցուցանիշներով։ Այդ դեպքում պորտֆելը, որի LGD-ն բարձր է, կհամարվի ավելի ռիսկային, քանի որ դեֆոլտի դեպքում սպասվող կորուստները կլինեն ավելի մեծ։ Հետևաբար, ռիսկի գնահատման ժամանակ անհրաժեշտ է համադրել ինչպես դեֆոլտի հավանականությունը, այնպես էլ դեֆոլտի պայմաններում կորուստների չափը։

LGD-ի գնահատումը բարդ գործընթաց է, քանի որ այն կախված է բազմաթիվ գործոններից՝ իրավական միջավայրից, սնանկության ընթացակարգերի արդյունավետությունից, գրավի իրացման ժամկետներից, ծախսերից և նույնիսկ տարածաշրջանային առանձնահատկություններից։ Օրինակ՝ երկրներում, որտեղ իրավական համակարգը արագ և արդյունավետ է, վերականգնման մակարդակները կարող են լինել ավելի բարձր, հետևաբար LGD-ն՝ ավելի ցածր։ Իսկ այն երկրներում, որտեղ դատական գործընթացները երկարատև են և ծախսատար, կորուստները կարող են մեծանալ։

Կարևոր է նաև ժամանակային գործոնը։ Դեֆոլտից հետո վերականգնումը հաճախ տեղի է ունենում երկար ժամանակահատվածում, և այդ ընթացքում գումարների արժեքը կարող է փոփոխվել։ Բանկերը հաշվի են առնում ոչ միայն վերականգնված գումարի չափը, այլ նաև վերականգնման ժամկետը և ծախսերը։ Վերականգնման գործընթացում կարող են առաջանալ իրավաբանական, վարչական և գործառնական ծախսեր, որոնք ևս նվազեցնում են վերջնական վերականգնվող գումարը և մեծացնում իրական կորուստը։

Ժամանակակից վարկային ռիսկի կառավարման համակարգերում LGD-ն գնահատվում է պատմական տվյալների հիման վրա՝ վերլուծելով նախորդ դեֆոլտային դեպքերը և դրանց վերականգնման արդյունքները։ Որոշ դեպքերում կիրառվում են նաև վիճակագրական և մեքենայական ուսուցման մեթոդներ՝ վերականգնման մակարդակները կանխատեսելու համար՝ կախված վարկառուի հատկանիշներից, վարկի կառուցվածքից և տնտեսական միջավայրից։ Սակայն անկախ կիրառվող մեթոդից, LGD-ի հիմնական իմաստը մնում է նույնը՝ այն ցույց է տալիս դեֆոլտի պայմաններում կրած ֆինանսական վնասի չափը։

Ընդհանուր առմամբ, LGD գործակիցը հանդիսանում է վարկային ռիսկի գնահատման հիմնարար տարրերից մեկը։ Այն ապահովում է պատկերացում ոչ միայն այն մասին, թե արդյոք վարկառուն կարող է չկատարել իր պարտավորությունները, այլ նաև այն մասին, թե այդ իրավիճակում որքան մեծ կլինի իրական կորուստը։ Առանց LGD-ի գնահատման հնարավոր չէ ամբողջական պատկերացում կազմել վարկային ռիսկի մասին, քանի որ ռիսկը ձևավորվում է ինչպես դեֆոլտի հավանականությամբ, այնպես էլ դեֆոլտի պայմաններում կորուստների ծավալով։

Այսպիսով, ECL հաշվարկը հանդիսանում է ինտեգրված վիճակագրական և ֆինանսական մոդել, որտեղ լոգիստիկ ռեգրեսիան գնահատում է դեֆոլտի հավանականությունը, գծային կամ ոչ գծային ռեգրեսիան գնահատում է պարտավորության չափը և կորուստի մակարդակը, իսկ վերջնական արդյունքը ներկայացնում է սպասվող կորուստը: Ձեր տրամադրած տվյալների հիման վրա հնարավոր է կառուցել ամբողջական, ինքնաբավ մաթեմատիկական համակարգ, որը չի պահանջում արտաքին փոփոխականներ՝ բացառությամբ գլոբալ գնահատվող գործակիցների և դիսկոնտավորման տոկոսադրույքի: LGD-ի բանաձը.

$$LGD = EAD * (1 - RR)$$

Որտեղ RR–ն (Recovery Rate) սպասվող տոկոսային եկամտաբերությունն է:

Գլուխ 3: ECL Գործակցի Հաշվման Ալգորիթմը Microsoft Azure Ամպային Տեխնոլոգիաների Միջոցով

Սպասվող վարկային կորուստների (Expected Credit Loss, ECL) հաշվարկը ժամանակակից բանկային և ֆինանսական համակարգերում իրականացվում է տվյալահեն մոտեցմամբ, որտեղ կիրառվում են վարկային ռիսկի հիմնական բաղադրիչները՝ PD, LGD և EAD: Microsoft Azure ամպային միջավայրը հնարավորություն է տալիս կառուցել ամբողջական ավտոմատացված գործընթաց՝ սկսած տվյալների հավաքագրումից մինչև վերջնական ECL-ի հաշվարկ և հաշվետվություն: ECL-ի հաշվման ալգորիթմը հիմնված է հետևյալ քայլերի վրա՝

- Staging
- CCF
- MPD – PD
- EAD-ի ստացում
- LGD-Econ ստացում
- LGD-Stat-ի ստացում
- ECL-ի ստացում

Առաջին փուլը staging-ն է: ՖՀՍՄ 9 մոտեցման շրջանակում վարկերը դասակարգվում են տարբեր փուլերի՝ կախված վարկային ռիսկի փոփոխությունից: Առաջին փուլում ընդգրկվում են այն ակտիվները, որոնց ռիսկը էականորեն չի աճել սկզբնական ճանաչումից հետո: Երկրորդ փուլում ներառվում են այն ակտիվները, որոնց դեպքում գրանցվել է էական աճ վարկային ռիսկում: Երրորդ փուլում ընդգրկվում են դեֆոլտային ակտիվները: Azure միջավայրում staging-ի իրականացումը կարող է կատարվել տվյալների մշակման հարթակների միջոցով՝ օրինակ տվյալների պահոցում (Data Lake) պահպանված պատմական տվյալների հիման վրա, կիրառելով բիզնես կանոններ կամ մեքենայական ուսուցման մոդելներ: Այս փուլում որոշվում է, թե յուրաքանչյուր վարկի համար պետք է կիրառվի 12-ամսյա, թե ամբողջ կյանքի հորիզոնով ECL հաշվարկ:

Հաջորդ կարևոր քայլը CCF-ն է՝ Credit Conversion Factor: Այն կիրառվում է հատկապես օֆ-բալանսային պարտավորությունների դեպքում՝ օրինակ վարկային գծերի կամ երաշխիքների համար: CCF-ն գնահատում է, թե չօգտագործված լիմիտի ինչ մասն է հավանական, որ կօգտագործվի մինչև դեֆոլտի պահը: Azure-ում այս գործակիցը կարող է հաշվարկվել պատմական տվյալների հիման վրա՝ օգտագործելով տվյալների վերլուծական ծառայություններ և վարքագծային մոդելներ: Ստացված արդյունքը օգտագործվում է հետագայում EAD-ի հաշվարկում:

MPD-ն՝ Marginal Probability of Default, ներկայացնում է յուրաքանչյուր ժամանակային միջակայքի համար դեֆոլտի սահմանային հավանականությունը: Եթե կիրառվում է ամբողջ կյանքի հորիզոնով գնահատում, ապա անհրաժեշտ է կառուցել ժամանակային պրոֆիլ, որը ցույց է տալիս, թե յուրաքանչյուր տարվա կամ եռամսյակի ընթացքում ինչ հավանականությամբ կարող է տեղի ունենալ դեֆոլտ: Azure Machine Learning ծառայության միջոցով հնարավոր է կառուցել ժամանակային շարքերի կամ դասակարգման մոդելներ, որոնք գնահատում են այս սահմանային հավանականությունները՝ հիմնվելով պատմական վարքագծի վրա:

MPD-ների ագրեգացման արդյունքում ձևավորվում է PD-ն տվյալ ժամանակային հորիզոնի համար: PD-ն կարող է հաշվարկվել որպես 12-ամսյա կամ lifetime ցուցանիշ՝ կախված staging-ի արդյունքից: Azure-ում PD-ի մոդելավորումը հաճախ իրականացվում է լոգիստիկ ռեգրեսիայի, որոշման ծառերի կամ այլ ալգորիթմների միջոցով: Մոդելները ուսուցանվում են պատմական տվյալների վրա, իսկ արդյունքները պահպանվում են տվյալների բազաներում՝ հետագա օգտագործման համար:

EAD-ի հաշվարկը հաջորդ քայլն է: Այն ներառում է հաշվեկշռային մնացորդը և, անհրաժեշտության դեպքում, չօգտագործված լիմիտի այն մասը, որը գնահատվել է CCF-ի միջոցով: Azure-ում EAD-ի հաշվարկը կարող է իրականացվել տվյալների ինտեգրման և հաշվարկային pipeline-ների միջոցով, որտեղ միավորվում են վարկի մնացորդային տվյալները և վարքագծային գործակիցները: Այս փուլում ձևավորվում է դեֆոլտի պահին ակնկալվող ընդհանուր ռիսկային ազդեցությունը:

LGD-ի գնահատման համար հաճախ կիրառվում են երկու մոտեցումներ՝ LGD-Stat և LGD-Econ: LGD-Stat-ը հիմնված է պատմական վիճակագրական տվյալների վրա և արտացոլում է նախորդ դեֆոլտային դեպքերի միջին վերականգնման մակարդակները: Azure-ի վերլուծական գործիքներով հնարավոր է մշակել պատմական վերականգնման տվյալները և ստանալ միջին կամ սեգմենտացված LGD արժեքներ: LGD-Econ-ը ներառում է մակրոտնտեսական գործոնների ազդեցությունը՝ օրինակ ՀՆԱ-ի աճ, գործազրկություն, անշարժ գույքի գների ինդեքսներ: Azure-ում կարելի է ինտեգրել արտաքին մակրոտնտեսական տվյալներ և կառուցել սցենարային մոդելներ, որոնք կկարգավորեն LGD-ն տնտեսական կանխատեսումների հիման վրա: Այսպիսով ստացվում է առաջադեմ, forward-looking LGD գնահատում:

Վերջնական փուլում հաշվարկվում է ECL-ը: Այս ցուցանիշը միավորում է PD, LGD և EAD բաղադրիչները և արտացոլում է սպասվող վարկային կորուստը տվյալ ակտիվի համար: Եթե ակտիվը գտնվում է առաջին փուլում, հաշվարկվում է 12-ամսյա ECL, իսկ երկրորդ և երրորդ փուլերում՝ ամբողջ կյանքի հորիզոնով ECL: Azure-ում այս հաշվարկը կարող է իրականացվել ավտոմատացված հաշվարկային միջավայրում՝ օգտագործելով մեծ տվյալների մշակման ծառայություններ, ինչը թույլ է տալիս միաժամանակ հաշվարկել հազարավոր կամ միլիոնավոր վարկերի համար սպասվող կորուստները:

Արդյունքում, Microsoft Azure ամպային հարթակի միջոցով հնարավոր է կառուցել ամբողջական, մասշտաբային և ավտոմատացված ECL հաշվարկման համակարգ: Այն ապահովում է տվյալների պահպանում, մոդելավորում, սցենարային վերլուծություն և հաշվետվությունների գեներացում մեկ միասնական միջավայրում: Staging-ից սկսած մինչև վերջնական ECL հաշվարկ, յուրաքանչյուր քայլ կարող է իրականացվել տվյալահեն, վերահսկելի և կարգավորող պահանջներին համապատասխան մեխանիզմներով՝ ապահովելով վարկային ռիսկի ճշգրիտ և թափանցիկ գնահատում:

Եզրակացություն

Եզրափակելով կարելի է նշել, որ վարկային ռիսկի գնահատման ժամանակակից համակարգը հանդիսանում է բազմաշերտ և փոխկապակցված մոդուլներից կազմված ամբողջական ինֆորմացիոն միջավայր, որտեղ յուրաքանչյուր բաղադրիչ ունի հստակ գործառույթ և ռազմավարական նշանակություն: Համակարգի մոդուլային կառուցվածքը թույլ է տալիս տարանջատել տվյալների հավաքագրման, նախնական մշակման, մոդելավորման, սցենարային վերլուծության, հաշվարկային և հաշվետվությունների ձևավորման գործընթացները՝ ապահովելով ճկունություն, վերահսկելիություն և ընդլայնման հնարավորություն: Այսպիսի ճարտարապետությունը հատկապես կարևոր է ՖՀՄՍ 9 պահանջներին համապատասխան ECL հաշվարկի համար, որտեղ անհրաժեշտ է միաժամանակ ապահովել ճշգրտություն, թափանցիկություն և կրկնելիություն:

Microsoft Azure ամպային հարթակը այս համատեքստում հանդես է գալիս որպես տեխնոլոգիական հիմք, որը միավորում է տվյալների պահպանումը, հաշվարկային հզորությունները և մեքենայական ուսուցման գործիքակազմը մեկ միասնական միջավայրում: Azure-ի օգտագործումը հնարավորություն է տալիս կառուցել մասշտաբավորվող համակարգ, որը կարող է մշակել մեծ ծավալի պատմական և ընթացիկ տվյալներ՝ առանց ենթակառուցվածքային սահմանափակումների: Ամպային ճարտարապետությունը նաև ապահովում է բարձր հասանելիություն, անվտանգություն և տվյալների պաշտպանության մեխանիզմներ, ինչը հատկապես կարևոր է ֆինանսական ոլորտում: Բացի այդ, Azure միջավայրում հնարավոր է իրականացնել ավտոմատացված տվյալահոսքեր, մոդելների պարբերական վերաուսուցում և սցենարային հաշվարկներ՝ նվազեցնելով մարդկային գործոնի ազդեցությունը և բարձրացնելով հաշվարկների օպերատիվությունը:

ECL հաշվարկի գործընթացը, հիմնված PD, LGD և EAD բաղադրիչների վրա, համակարգում իրականացվում է փուլային և տրամաբանական հաջորդականությամբ: Staging մոդուլը ապահովում է ակտիվների ճիշտ դասակարգում՝ ըստ վարկային ռիսկի փոփոխության աստիճանի, ինչը որոշում է հաշվարկի հորիզոնը: PD մոդուլը գնահատում է դեֆոլտի հավանականությունը՝ օգտագործելով պատմական տվյալներ և վարքագծային օրինաչափություններ: EAD մոդուլը սահմանում է դեֆոլտի պահին ակնկալվող ռիսկային ազդեցությունը՝ ներառելով ինչպես հաշվեկշռային, այնպես էլ օֆ-բալանսային պարտավորությունները: LGD մոդուլը գնահատում է դեֆոլտի դեպքում հնարավոր կորուստների չափը՝ համադրելով վիճակագրական և մակրոտնտեսական գործոնները: Այս բոլոր մոդուլների ինտեգրման արդյունքում ձևավորվում է վերջնական ECL ցուցանիշը, որը ներկայացնում է սպասվող վարկային կորուստը և հանդիսանում է ռեզերվների ձևավորման հիմք:

Ձեր մշակած ալգորիթմը, որը կառուցված է staging, CCF, MPD, PD, EAD, LGD-Stat, LGD-Econ և վերջնական ECL փուլերի տրամաբանական հաջորդականության վրա, կարելի է գնահատել որպես համակարգային և ամբողջական մոտեցում: Այն ապահովում է ռիսկի գնահատման ոչ միայն մեխանիկական, այլև վերլուծական խորություն՝ հաշվի առնելով ինչպես վարքագծային, այնպես էլ մակրոտնտեսական ազդեցությունները: Ալգորիթմի ուժեղ կողմերից է փուլային կառուցվածքը, որը թույլ է տալիս յուրաքանչյուր բաղադրիչ առանձին վավերացնել, թեստավորել և բարելավել՝ առանց ամբողջ համակարգը վերակառուցելու անհրաժեշտության: Սա բարձրացնում է

մոդելի կայունությունն ու վերահսկելիությունը, ինչպես նաև հեշտացնում է կարգավորող պահանջներին համապատասխանության ապահովումը:

Ընդհանուր առմամբ, համակարգի մոդուլային ճարտարապետությունը, Microsoft Azure ամպային միջավայրի տեխնոլոգիական հնարավորությունները և ձեր կողմից մշակված փուլային ալգորիթմը միասին ձևավորում են արդյունավետ, մասշտաբավորվող և ժամանակակից ECL հաշվարկման լուծում: Այս մոտեցումը հնարավորություն է տալիս ապահովել ճշգրիտ ռիսկի գնահատում, օպերատիվ հաշվարկներ և ռազմավարական որոշումների ընդունման համար անհրաժեշտ տեղեկատվություն: Արդյունքում ձևավորվում է կայուն վարկային ռիսկի կառավարման համակարգ, որը համատեղում է տեսական հիմքերը, տեխնոլոգիական նորարարությունը և գործնական կիրառելիությունը՝ ապահովելով ֆինանսական կազմակերպության երկարաժամկետ կայունությունն ու մրցունակությունը:

Օգտագործված Գրականություն

1. Bank for International Settlements. Credit Risk Modelling and Validation Publications.
2. Basel Committee on Banking Supervision. Basel II: International Convergence of Capital Measurement and Capital Standards.
3. Basel Committee on Banking Supervision. Basel III: A Global Regulatory Framework for More Resilient Banks and Banking Systems.
4. Basel Committee on Banking Supervision. Guidance on Credit Risk and Accounting for Expected Credit Losses.
19. Christopher M. Bishop. Pattern Recognition and Machine Learning.
20. Coursera – Machine Learning and Financial Engineering Courses.
11. Darrell Duffie. Credit Risk: Pricing, Measurement, and Management.
12. David Lando. Credit Risk Modeling: Theory and Applications.
5. European Banking Authority. Guidelines on Credit Risk Management Practices and Accounting for Expected Credit Losses.
6. European Central Bank. Guidance to Banks on Non-Performing Loans.
13. Fitch Ratings. Recovery Rate and Default Studies.
21. Gareth James և համահեղինակներ. An Introduction to Statistical Learning.
7. IFRS Foundation. IFRS 9 Implementation Guidance and Basis for Conclusions.
8. International Accounting Standards Board. International Financial Reporting Standard 9 (IFRS 9) – Financial Instruments.
9. International Monetary Fund. Financial Sector Assessment Program (FSAP) Technical Notes.
14. John C. Hull. Risk Management and Financial Institutions.
22. Kevin P. Murphy. Machine Learning: A Probabilistic Perspective.
15. Linda Allen. Credit Risk Measurement: New Approaches to Value at Risk and Other Paradigms.
24. Microsoft Azure. Azure Data Lake and Synapse Analytics Documentation.
25. Microsoft Azure. Azure Machine Learning Documentation.
26. Microsoft Azure. Security and Compliance Documentation for Financial Services.
27. Microsoft Learn. Cloud Solutions for Financial Risk Management.
28. Microsoft. Azure Architecture Center Documentation.
16. Moody's Analytics. Credit Risk Modeling Methodologies and IFRS 9 Publications.
17. Paul Glasserman. Monte Carlo Methods in Financial Engineering.
18. Standard & Poor's. Credit Risk and Recovery Studies.
23. Trevor Hastie, Robert Tibshirani, Jerome Friedman. The Elements of Statistical Learning.
10. World Bank. Credit Risk Management in Banking Sector Reports.

Բովանդակություն

- Գլուխ 1: Տեղեկատվական Տեխնոլոգիաների Մոդելների Տեսակները, Microsoft Azure-ի Գործիքները
  - Ներածություն
  - On-Premise Մոդել
  - IaaS Մոդել
  - PaaS Մոդել
  - SaaS Մոդել
  - Microsoft Azure
  - ETL/ELT տվյալների ինտեգրման եղանակները
  - On-Premise Մոդել
  - «Մեդալիոն» Ճարտարապետություն
  - OLTP/OLAP համակարգեր
  - Տվյալային խողովակաշարեր (Data Pipelines)
  - Microsoft Azure Data Factory
  - Azure Synapse և Azure Databricks
  - Գլխի ամփոփում
- Գլուխ 2: ECL-ի Նշանակությունը և Հաշվարկելու Եղանակը
  - Ներածություն
  - ECL-ի Հաշվարկելու Եղանակը
  - PD Գործակիցը, Մեքենայական Ուսուցումը և Լոգիստիկ Ռեգրեսիան
  - EAD Գործակիցը
  - LGD Գործակիցը
- Գլուխ 3: ECL Գործակցի Հաշվման Ալգորիթմը Microsoft Azure Ամպային Տեխնոլոգիաների Միջոցով
- Եզրակացություն