# Բովանդակություն


- Ներածություն
- ԳԼՈՒԽ 1: ԵՆԹԱԿԱՌՈՒՑՎԱԾՔՆԵՐԻ ՏԵՍԱԿՆԵՐԸ ԱՄՊԱՅԻՆ ՏԵԽՆՈԼՈԳԻԱՆԵՐՈՒՄ
    - 1.1: On-Premise (Տեղային Տեղակայում) Մոդելը
    - 1.2: IaaS (Ենթակառուցվածքը Որպես Ծառայություն) Մոդելը
    - 1.3: PaaS (Հարթակը Որպես Ծառայություն) Մոդելը
    - 1.4: SaaS (Ծրագրային Ապահովումը Որպես Ծառայություն) Մոդելը
    - 1.5: Ամպային Տեխնոլոգիաների Մատակարարները
    - 1.6: Microsoft Azure
- ԳԼՈՒԽ 2: ՕԳՏԱԳՈՐԾՎԱԾ ՏՎՅԱԼՆԵՐԻ ՃԱՐՏԱՐԱՊԵՏՈՒԹՅՈՒՆ
    - 2.1: ETL/ELT Տվյալային Խողովակաշարեր (Data Pipelines)
    - 2.2: «Մեդալիոն» Ճարտարապետություն
    - 2.3: OLTP/OLAP համակարգեր
- ԳԼՈՒԽ 3: ՏՎՅԱԼՆԵՐԻ ՃԱՐՏԱՐԱՊԵՏՈՒԹՅԱՆ ԳՈՐԾԻՔԱԿԱՑՄԵՐԸ MICROSOFT AZURE-ՈՒՄ
    - 3.1: Microsoft Azure Data Factory Տվյալների Ինտեգրման Գործիքակազմ
    - 3.2: Azure Databricks Վերլուծական Համակարգ
    - 3.3: Azure Synapse Վերլուծական Համակարգ
    - 3.4: Գործիքների Տարբերությունները
    - 3.5: Գլխի ամփոփում
- ԳԼՈՒԽ 4: ECL ԳՈՐԾԱԿՑԻ ՀԱՇՎՈՒՄԸ
    - 4.1: PD Գործակցի Հաշվումը, Մեքենայական Ուսուցումը և Լոգիստիկ Ռեգրեսիան
    - 4.2: LGD Գործակցի Հաշվումը
    - 4.3: EAD Գործակցի Հաշվումը և ECL Գործակցի Բանաձևը
- ԳԼՈՒԽ 5: ECL ԳՈՐԾԱԿՑԻ ՀԱՇՎՄԱՆ ԱԼԳՈՐԻԹՄԸ MICROSOFT AZURE ԱՄՊԱՅԻՆ ՏԵԽՆՈԼՈԳԻԱՆԵՐԻ ՄԻՋՈՑՈՎ
- Եզրակացություն

# Ներածություն

Վարկային ռիսկի արդյունավետ կառավարումը ժամանակակից ֆինանսական համակարգի հիմնարար տարրերից է: Ֆինանսական կազմակերպությունները, մասնավորապես բանկերը և վարկային ընկերությունները, պարտավոր են գնահատել ոչ միայն արդեն կրած կորուստները, այլև ապագայում հնարավոր վարկային կորուստները: Այս մոտեցումը ամրագրված է International Accounting Standards Board-ի կողմից հրապարակված ՖՀՄՍ 9 ստանդարտում, որի շրջանակում կիրառվում է Expected Credit Loss (ECL) մեթոդաբանությունը:

Expected Credit Loss-ը ներկայացնում է այն ակնկալվող ֆինանսական կորուստների ներկա արժեքը, որոնք կարող են առաջանալ վարկառուների կողմից պարտավորությունների չկատարման հետևանքով: Ի տարբերություն նախկին «կրած կորուստների» մոտեցման, ECL համակարգը հիմնված է կանխատեսվող և առաջ նայող տեղեկատվության վրա: Այն պահանջում է ոչ միայն պատմական տվյալների վերլուծություն, այլև ընթացիկ և կանխատեսվող մակրոտնտեսական գործոնների ներառում հաշվարկներում: Այս հանգամանքը էապես մեծացնում է հաշվարկների բարդությունն ու տվյալների ծավալը:

ECL-ի հաշվարկը հիմնված է երեք հիմնական պարամետրերի վրա՝ դեֆոլտի հավանականություն (Probability of Default – PD), դեֆոլտի դեպքում կորուստ (Loss Given Default – LGD) և դեֆոլտի պահին ազդեցության չափ (Exposure at Default – EAD): Այս բաղադրիչների համադրությամբ գնահատվում է յուրաքանչյուր վարկային գործարքի և ամբողջ վարկային պորտֆելի ակնկալվող կորուստը: Հաշվարկի ընթացքում անհրաժեշտ է հաշվի առնել վարկերի փուլային դասակարգումը, ռիսկայնության փոփոխությունը ժամանակի ընթացքում, ինչպես նաև տարբեր մակրոտնտեսական սցենարներ:

Խնդրի էությունն այն է, որ ECL-ի հաշվարկը պահանջում է մեծածավալ տվյալների մշակում, բարդ վիճակագրական և մաթեմատիկական մոդելների կիրառում, ինչպես նաև սցենարային վերլուծություն: Տվյալները հավաքագրվում են տարբեր տեղեկատվական համակարգերից՝ վարկային հաշվառման համակարգերից, հաճախորդների վարկունակության գնահատման մոդուլներից, գրավների կառավարման համակարգերից և արտաքին մակրոտնտեսական աղբյուրներից: Այս տվյալների ինտեգրումը, մաքրումը և կառուցվածքային վերամշակումը հանդիսանում են հաշվարկի նախնական և կարևոր փուլեր:

Ավանդական ենթակառուցվածքները հաճախ սահմանափակ են նման ծավալի տվյալների արագ և արդյունավետ մշակման տեսանկյունից: Հաշվարկային հզորության պահանջները կարող են զգալիորեն աճել հատկապես այն դեպքերում, երբ կիրառվում են բազմասցենար կանխատեսումներ կամ մեքենայական ուսուցման մեթոդներ: Բացի այդ, անհրաժեշտ է ապահովել տվյալների անվտանգություն, հասանելիություն և համակարգի անխափան աշխատանք:

Այս պայմաններում ամպային տեխնոլոգիաները հանդես են գալիս որպես արդյունավետ լուծում։ Ամպային միջավայրերը հնարավորություն են տալիս ապահովել մասշտաբելի հաշվարկային ռեսուրսներ, որոնք կարող են դինամիկ կերպով ավելացվել կամ նվազեցվել՝ կախված հաշվարկային բեռնվածությունից։ Տվյալների կենտրոնացված պահպանումը, բարձր հասանելիությունը և ավտոմատացված գործընթացների իրականացումը նպաստում են ECL հաշվարկի արագությանը և ճշգրտությանը։ Բացի այդ, ամպային հարթակները հնարավորություն են տալիս կիրառել առաջադեմ վերլուծական գործիքներ և մեքենայական ուսուցման ալգորիթմներ՝ բարելավելով PD, LGD և EAD պարամետրերի գնահատման որակը։

# ԳԼՈՒԽ 1: ԵՆԹԱԿԱՌՈՒՑՎԱԾՔՆԵՐԻ ՏԵՍԱԿՆԵՐԸ ԱՄՊԱՅԻՆ ՏԵԽՆՈԼՈԳԻԱՆԵՐՈՒՄ

Ժամանակակից թվային աշխարհում տեղեկատվական տեխնոլոգիաները դարձել են տնտեսության, կառավարման, կրթության և բիզնեսի զարգացման հիմնարար բաղադրիչը: Կազմակերպությունները մշտապես ստեղծում և մշակում են մեծածավալ տվյալներ, օգտագործում են բազմատեսակ ծրագրային համակարգեր և ապահովում են առցանց ծառայություններ: Այս գործընթացները պահանջում են հուսալի, անվտանգ և մասշտաբելի տեխնոլոգիական միջավայր: Այդ անհրաժեշտության արդյունքում լայն տարածում են ստացել ամպային տեխնոլոգիաները, որոնք հիմնված են ինտերնետի միջոցով հաշվարկային և ծրագրային ռեսուրսների տրամադրման սկզբունքի վրա:

Ամպային հաշվարկը ծառայությունների մատուցման մոդել է, որի դեպքում սերվերները, պահեստային համակարգերը, ցանցային ենթակառուցվածքը, տվյալների բազաները և ծրագրային ապահովումը տրամադրվում են հեռակա տվյալների կենտրոններից: Օգտագործողը չունի ֆիզիկական սարքավորումներ ձեռք բերելու կամ սպասարկելու անհրաժեշտություն, քանի որ ամբողջ ենթակառուցվածքը կառավարում է ամպային ծառայություն մատուցող ընկերությունը: Վճարումը կատարվում է ըստ օգտագործված ռեսուրսների, ինչը թույլ է տալիս նվազեցնել նախնական ներդրումները և արդյունավետորեն պլանավորել բյուջեն:

Ամպային տեխնոլոգիաների զարգացումը պայմանավորված է վիրտուալացման տեխնոլոգիաների առաջընթացով, ինտերնետի արագության բարձրացմամբ և գլոբալ բիզնես միջավայրի ընդլայնմամբ: Այսօր ամպային ծառայությունները կիրառվում են տարբեր ոլորտներում՝ բանկային համակարգում, կրթական հաստատություններում, առողջապահությունում, պետական կառույցներում և մասնավոր բիզնեսում:

Ամպային համակարգերի հիմնական առավելություններից է մասշտաբելիությունը: Կազմակերպությունները կարող են արագ ավելացնել կամ նվազեցնել հաշվարկային հզորությունները՝ կախված բեռնվածությունից: Սա հատկապես կարևոր է սեզոնային բիզնեսների կամ արագ զարգացող ստարտափների համար: Բացի այդ, ամպային հարթակները ապահովում են բարձր հասանելիություն, քանի որ տվյալների կենտրոնները տեղակայված են տարբեր աշխարհագրական տարածաշրջաններում և աշխատում են կրկնօրինակման մեխանիզմներով: Անվտանգության առումով ամպային մատակարարները կիրառում են տվյալների կոդավորում, մշտական մոնիթորինգ և միջազգային ստանդարտներին համապատասխանող պաշտպանական մեխանիզմներ:

Ամպային ծառայությունները բաժանվում են մի քանի հիմնական մոդելների՝ On-Premise, IaaS, PaaS և SaaS: Յուրաքանչյուր մոդել ունի իր առանձնահատկությունները, առավելությունները և սահմանափակումները:

## 1.1: On-Premise (Տեղային Տեղակայում) Մոդելը

On-Premise մոդելի դեպքում կազմակերպությունը սեփական տարածքում տեղադրում և կառավարում է ամբողջ տեղեկատվական ենթակառուցվածքը: Սերվերները, պահեստային սարքերը, ցանցային սարքավորումները և ծրագրային ապահովումը գտնվում են կազմակերպության ֆիզիկական վերահսկողության տակ: Այս մոտեցումը երկար ժամանակ հանդիսացել է տեղեկատվական համակարգերի կառուցման հիմնական եղանակը և համարվում է դասական IT ճարտարապետության հիմքը: Կազմակերպությունը ստեղծում է իր տվյալների կենտրոնը կամ սերվերային սենյակը, որտեղ տեղադրվում են հաշվարկային հզորությունները, պահեստային համակարգերը, ցանցային հանգույցները, անվտանգության սարքավորումները և էլեկտրասնուցման ու հովացման համակարգերը:

Տեղային տեղակայում ենթակառուցվածքը սովորաբար ներառում է ֆիզիկական սերվերներ, վիրտուալացման հարթակներ, պահեստային զանգվածներ (SAN/NAS համակարգեր), կրկնօրինակման և վերականգնման լուծումներ, ինչպես նաև ներքին և արտաքին ցանցային պաշտպանական մեխանիզմներ: Բացի տեխնիկական բաղադրիչներից, անհրաժեշտ է նաև կազմակերպել ֆիզիկական անվտանգություն՝ սահմանափակ մուտք սերվերային տարածք, հսկողության համակարգեր և հրդեհաշիջման միջոցներ:

Տեղային տեղակայում մոդելի հիմնական առավելությունը լիարժեք վերահսկողությունն է: Կազմակերպությունը ինքնուրույն է որոշում անվտանգության քաղաքականությունը, սարքավորումների կոնֆիգուրացիան, տվյալների պահպանման կանոնները և համակարգերի արդիականացման ժամանակացույցը: Սա հատկապես կարևոր է այն ոլորտների համար, որտեղ տվյալների գաղտնիությունն ու իրավական համապատասխանությունը առաջնահերթ են: Օրինակ՝ ֆինանսական կազմակերպությունները, պետական կառույցները և պաշտպանական ոլորտը հաճախ նախընտրում են տեղային լուծումներ՝ տվյալների ֆիզիկական տեղակայման հստակ վերահսկման պատճառով:

Բացի վերահսկողությունից, տեղային տեղակայում լուծումը թույլ է տալիս իրականացնել խորը հարմարեցում: Կազմակերպությունը կարող է ընտրել հատուկ սարքավորումներ, կիրառել յուրահատուկ ցանցային ճարտարապետություն և ստեղծել անհատականացված անվտանգության համակարգ: Սա հնարավորություն է տալիս կառուցել բարձր կատարողականությամբ համակարգեր, որոնք օպտիմալացված են կոնկրետ բիզնես գործընթացների համար:

Սակայն այս մոդելը ունի նաև մի շարք նշանակալի թերություններ: Նախնական ներդրումները բավականին բարձր են, քանի որ անհրաժեշտ է ձեռք բերել սերվերներ, լիցենզիաներ, պահեստային համակարգեր և ցանցային սարքավորումներ: Բացի այդ, պահանջվում է համապատասխան ենթակառուցվածք՝ էլեկտրասնուցման կայուն աղբյուր, գեներատորներ, UPS համակարգեր և սառեցման սարքավորումներ: Այս ամենը մեծացնում է կապիտալ ծախսերը և բարդացնում նախագծի իրականացումը:

Տեղային տեղակայում մոդելը պահանջում է նաև մասնագիտացված IT անձնակազմ՝ համակարգերի տեղադրման, մոնիթորինգի, անվտանգության ապահովման և խնդիրների լուծման համար: Անձնակազմի պահպանման և վերապատրաստման ծախսերը նույնպես ավելանում են, հատկապես երբ կիրառվում են նոր տեխնոլոգիաներ:

Սարքավորումները ժամանակի ընթացքում հնանում են և պահանջում են արդիականացում կամ փոխարինում, ինչը առաջացնում է լրացուցիչ ֆինանսական բեռ:

Մասշտաբելիությունը սահմանափակ է, քանի որ նոր ռեսուրսների ավելացումը պահանջում է ֆիզիկական սարքավորումների ձեռքբերում և տեղադրում: Եթե կազմակերպությունը սխալ է գնահատում բեռնվածությունը, կարող է առաջանալ կամ ռեսուրսների պակաս, կամ ավելցուկ, ինչը հանգեցնում է անարդյունավետ ծախսերի: Բացի այդ, համակարգերի ընդլայնումը կարող է պահանջել տարածքի ավելացում և լրացուցիչ ենթակառուցվածքային ներդրումներ:

Վերականգնման և աղետների դիմակայման հարցը նույնպես բարդ է տեղային տեղակայում միջավայրում: Անհրաժեշտ է ստեղծել պահուստային տվյալների կենտրոն կամ իրականացնել տվյալների արտաքին կրկնօրինակում, ինչը կրկին պահանջում է լրացուցիչ ծախսեր և տեխնիկական բարդ լուծումներ: Բնական աղետները, էլեկտրական խափանումները կամ տեխնիկական անսարքությունները կարող են ազդել ամբողջ համակարգի աշխատանքի վրա, եթե պատշաճ կրկնօրինակման ռազմավարություն չի մշակվել:

Այսպիսով, տեղային տեղակայում մոդելը ապահովում է առավելագույն վերահսկողություն և հարմարեցում, սակայն պահանջում է զգալի ֆինանսական ներդրումներ, տեխնիկական փորձառություն և երկարաժամկետ ռազմավարական պլանավորում: Այն առավել նպատակահարմար է այն կազմակերպությունների համար, որոնք ունեն բավարար ռեսուրսներ և խիստ անվտանգության կամ կարգավորիչ պահանջներ:

## 1.2: IaaS (Ենթակառուցվածքը Որպես Ծառայություն) Մոդելը

IaaS, կամ Infrastructure as a Service, մոդելը ենթադրում է ենթակառուցվածքի տրամադրում որպես ծառայություն: Այս դեպքում ամպային մատակարարը տրամադրում է վիրտուալ սերվերներ, պահեստային ռեսուրսներ, ցանցային գործիքներ և հիմքային հաշվարկային հզորություններ, իսկ հաճախորդը կառավարում է օպերացիոն համակարգերը, միջին ծրագրային շերտը և տեղադրված կիրառական ծրագրերը: Ֆիզիկական սարքավորումները, տվյալների կենտրոնները, էլեկտրասնուցման համակարգերը և հիմնական ցանցային ենթակառուցվածքը գտնվում են մատակարարի պատասխանատվության ներքո:

IaaS մոդելը հիմնված է վիրտուալացման տեխնոլոգիայի վրա, որի միջոցով մեկ ֆիզիկական սերվերը կարող է բաժանվել մի քանի վիրտուալ մեքենաների: Յուրաքանչյուր վիրտուալ մեքենա գործում է որպես առանձին համակարգ՝ սեփական օպերացիոն համակարգով և ծրագրերով: Սա թույլ է տալիս արդյունավետ օգտագործել ֆիզիկական ռեսուրսները և ապահովել բարձր ճկունություն: Օգտագործողը կարող է ընտրել սերվերի հզորությունը, պրոցեսորի քանակը, հիշողության ծավալը, պահեստային տարածքը և ցանցային պարամետրերը՝ ըստ իր պահանջների:

Այս մոդելի առավելություններից է ցածր նախնական ծախսը: Կազմակերպությունը չունի սարքավորումներ գնելու և տեղադրելու անհրաժեշտություն, ինչը նվազեցնում է կապիտալ ներդրումները: Նոր վիրտուալ սերվեր ստեղծելու գործընթացը կարող է իրականացվել ընդամենը մի քանի րոպեի ընթացքում՝ առանց ֆիզիկական միջամտության: Սա հատկապես կարևոր է արագ զարգացող նախագծերի և ստարտափների համար, որտեղ անհրաժեշտ է արագ արձագանքել շուկայի փոփոխություններին:

Մասշտաբելիությունը IaaS մոդելի կարևորագույն առավելություններից է: Ռեսուրսների ավելացումը կամ նվազեցումը իրականացվում է գրեթե ակնթարթորեն: Եթե համակարգի բեռնվածությունը աճում է, հնարավոր է ավելացնել պրոցեսորային հզորությունը կամ ստեղծել լրացուցիչ վիրտուալ մեքենաներ: Նույն կերպ, բեռնվածության նվազման դեպքում կարելի է կրճատել օգտագործվող ռեսուրսները և օպտիմալացնել ծախսերը: Այս մոտեցումը թույլ է տալիս արդյունավետ կառավարել ֆինանսական ռեսուրսները և խուսափել ավելորդ ծախսերից:

Գլոբալ հասանելիությունը ևս կարևոր առավելություն է: Ամպային մատակարարները ունեն տվյալների կենտրոններ աշխարհի տարբեր տարածաշրջաններում, ինչը թույլ է տալիս տեղակայել ծառայությունները այն տարածաշրջանում, որը առավել մոտ է վերջնական օգտագործողին: Սա բարելավում է աշխատանքի արագությունը, նվազեցնում է ուշացումները և բարձրացնում է համակարգի հասանելիությունը:

IaaS մոդելը նաև նպաստում է փորձարարական և թեստային միջավայրերի արագ ստեղծմանը: Ծրագրավորողները կարող են ստեղծել փորձնական սերվերներ, իրականացնել թեստավորում և անհրաժեշտության դեպքում արագ հեռացնել դրանք՝ առանց երկարաժամկետ պարտավորությունների: Սա մեծացնում է զարգացման գործընթացի արդյունավետությունը և նվազեցնում ռիսկերը:

Սակայն IaaS մոդելը ունի նաև որոշակի սահմանափակումներ: Չնայած ենթակառուցվածքը կառավարվում է մատակարարի կողմից, օպերացիոն

համակարգերի, տվյալների անվտանգության և կիրառական ծրագրերի պատասխանատվությունը մնում է հաճախորդի վրա: Սա նշանակում է, որ կազմակերպությունը պետք է ունենա համապատասխան տեխնիկական գիտելիքներ և փորձառություն՝ ապահովելու համակարգերի անվտանգությունը և կայուն աշխատանքը:

Կախվածությունը ինտերնետ կապից ևս կարևոր գործոն է: Քանի որ բոլոր ռեսուրսները հասանելի են ինտերնետի միջոցով, կապի խափանումները կարող են ժամանակավորապես դադարեցնել ծառայությունների հասանելիությունը: Բացի այդ, տվյալների փոխանցման արագությունը և որակը կարող են ազդել համակարգի աշխատանքի արդյունավետության վրա:

Երկարաժամկետ օգտագործման դեպքում ծախսերը կարող են աճել, եթե ռեսուրսների օգտագործումը ճիշտ չի պլանավորվում: Անարդյունավետ կոնֆիգուրացիաները, ավելորդ ակտիվ սերվերները կամ սխալ ընտրված պահեստային լուծումները կարող են առաջացնել ֆինանսական բեռ: Հետևաբար կարևոր է մշտական մոնիթորինգ և ծախսերի օպտիմալացում իրականացնել:

Բացի այդ, IaaS մոդելում առկա է մատակարարից կախվածության գործոնը: Եթե կազմակերպությունը կառուցում է իր ամբողջ համակարգը մեկ ամպային հարթակի վրա, ապագայում այլ մատակարարի անցումը կարող է լինել բարդ և ժամանակատար: Սա պահանջում է ռազմավարական պլանավորում և ճարտարապետական ճկունություն:

Ընդհանուր առմամբ, IaaS մոդելը համարվում է արդյունավետ լուծում այն կազմակերպությունների համար, որոնք ցանկանում են պահպանել վերահսկողությունը ծրագրային միջավայրի վրա, սակայն միաժամանակ խուսափել ֆիզիկական ենթակառուցվածքի ստեղծման և սպասարկման բարդություններից: Այն ապահովում է ճկունություն, մասշտաբելիություն և գլոբալ հասանելիություն՝ դարձնելով այն ժամանակակից բիզնես միջավայրի կարևորագույն բաղադրիչներից մեկը:

## 1.3: PaaS (Հարթակը Որպես Ծառայություն) Մոդելը

PaaS, կամ Platform as a Service, մոդելը տրամադրում է պատրաստի տեխնոլոգիական միջավայր ծրագրերի մշակման, փորձարկման, տեղակայման և կառավարման համար: Այս մոդելի դեպքում ամպային մատակարարը կառավարում է ոչ միայն ֆիզիկական ենթակառուցվածքը, այլ նաև վիրտուալացման շերտը, օպերացիոն համակարգերը, միջին ծրագրային ապահովումը (middleware), տվյալների բազաների կառավարման համակարգերը և զարգացման հիմնական գործիքները: Օգտագործողը հիմնականում կենտրոնանում է կիրառական ծրագրերի մշակման և բիզնես տրամաբանության իրականացման վրա՝ առանց ենթակառուցվածքային բարդ խնդիրների լուծման անհրաժեշտության:

PaaS մոդելը ձևավորվել է ծրագրային ապահովման արագ զարգացման պահանջից: Ժամանակակից կազմակերպությունները հաճախ աշխատում են դինամիկ միջավայրում, որտեղ անհրաժեշտ է կարճ ժամանակահատվածում ստեղծել և թողարկել նոր ֆունկցիոնալություն: PaaS-ը հնարավորություն է տալիս ծրագրավորողներին անմիջապես սկսել աշխատանքը՝ առանց սերվերների տեղադրման, օպերացիոն համակարգերի կարգաբերման կամ անվտանգության հիմքային կոնֆիգուրացիաների իրականացման:

Այս մոդելում տրամադրվում են պատրաստի զարգացման հարթակներ, ծրագրավորման լեզուների աջակցություն, տվյալների բազաների ինտեգրում, API-ների կառավարում և մոնիթորինգի գործիքներ: Շատ դեպքերում PaaS հարթակները ներառում են ավտոմատ մասշտաբելիության մեխանիզմներ, որոնց միջոցով համակարգը ինքնուրույն ավելացնում կամ նվազեցնում է ռեսուրսները՝ կախված բեռնվածությունից: Սա ապահովում է կայուն աշխատանք նույնիսկ մեծ օգտագործման պայմաններում:

PaaS մոդելի առավելություններից է ծրագրային մշակման արագացումը: Քանի որ ենթակառուցվածքային հարցերը լուծված են մատակարարի կողմից, ծրագրավորողները կարող են ամբողջ ուշադրությունը դարձնել կոդի որակին, ֆունկցիոնալությանը և նորարարական լուծումների մշակմանը: Սա կրճատում է նախագծի իրականացման ժամանակը և բարձրացնում թիմի արտադրողականությունը:

Ավտոմատ թարմացումները ևս կարևոր առավելություն են: Օպերացիոն համակարգերը, տվյալների բազաների համակարգերը և անվտանգության բաղադրիչները թարմացվում են ավտոմատ կերպով՝ առանց օգտագործողի միջամտության: Սա նվազեցնում է տեխնիկական ռիսկերը և ապահովում համակարգի համապատասխանությունը անվտանգության ժամանակակից պահանջներին:

PaaS հարթակները սովորաբար ունեն բարձր ինտեգրում DevOps գործիքների հետ: Դրանք աջակցում են CI/CD գործընթացներին, ինչը թույլ է տալիս ավտոմատացնել կոդի կառուցումը, թեստավորումը և տեղակայումը: Ծրագրի նոր տարբերակները կարող են արագ և անվտանգ տեղակայվել արտադրական միջավայրում՝ նվազեցնելով մարդկային սխալների հավանականությունը: Բացի այդ, տրամադրվում են մոնիթորինգի և լոգավորման գործիքներ, որոնք թույլ են տալիս հետևել համակարգի աշխատանքին և արագ արձագանքել խնդիրներին:

Այնուամենայնիվ, PaaS մոդելը ունի նաև որոշ սահմանափակումներ: Քանի որ ենթակառուցվածքի և միջավայրի կառավարումը իրականացվում է մատակարարի կողմից, կազմակերպությունը չունի լիարժեք վերահսկողություն համակարգի բոլոր

շերտերի նկատմամբ։ Հնարավոր չէ կատարել խորքային կոնֆիգուրացիաներ կամ կիրառել հատուկ համակարգային լուծումներ, որոնք դուրս են մատակարարի առաջարկած հնարավորություններից։

Բացի այդ, առկա է մատակարարից կախվածության գործոնը։ Եթե կազմակերպությունը ամբողջությամբ կառուցում է իր ծրագրային ճարտարապետությունը կոնկրետ PaaS հարթակի առանձնահատկությունների վրա, ապագայում այլ հարթակի անցումը կարող է պահանջել զգալի վերամշակում և տեխնիկական ռեսուրսներ։ Սա կարող է սահմանափակել տեխնոլոգիական անկախությունը և բարձրացնել ռազմավարական ռիսկերը։

Մեկ այլ կարևոր հանգամանք է ծախսերի կառավարումը։ Չնայած PaaS-ը հաճախ նվազեցնում է ենթակառուցվածքային ծախսերը, ինտենսիվ օգտագործման դեպքում ծառայությունների արժեքը կարող է աճել։ Հետևաբար անհրաժեշտ է պարբերաբար վերլուծել օգտագործման տվյալները և օպտիմալացնել ռեսուրսների բաշխումը։

Ընդհանուր առմամբ, PaaS մոդելը հանդիսանում է արդյունավետ լուծում այն կազմակերպությունների համար, որոնք առաջնահերթություն են տալիս արագ զարգացմանը, ավտոմատացմանը և ժամանակակից ծրագրային ճարտարապետությանը։ Այն ապահովում է ճկուն և կայուն միջավայր, որը թույլ է տալիս կենտրոնանալ բիզնես արժեք ստեղծելու վրա՝ նվազեցնելով տեխնիկական բարդությունները և ենթակառուցվածքային ռիսկերը։

## 1.4: SaaS (Ծրագրային Ապահովումը Որպես Ծառայություն) Մոդելը

SaaS, կամ Software as a Service, մոդելում օգտագործողը ստանում է ամբողջությամբ պատրաստի ծրագրային լուծում, որը գործում է ամպային միջավայրում և հասանելի է ինտերնետի միջոցով: Օգտագործողը պարզապես մուտք է գործում համակարգ՝ օգտագործելով վեբ դիտարկիչ կամ համապատասխան հավելված, և անմիջապես սկսում է աշխատել ծառայության հետ՝ առանց սերվերների տեղադրման, օպերացիոն համակարգերի կարգաբերման կամ տեխնիկական ենթակառուցվածքի կառավարման անհրաժեշտության: Ծրագրային ապահովման ամբողջ տեխնիկական հատվածը, ներառյալ սերվերները, տվյալների բազաները, անվտանգության մեխանիզմները և թարմացումները, կառավարվում են ծառայություն մատուցող ընկերության կողմից:

SaaS մոդելը լայն տարածում է ստացել հատկապես այն կազմակերպությունների շրջանում, որոնք ցանկանում են արագ ներդնել թվային գործիքներ առանց մեծ ֆինանսական և տեխնիկական ներդրումների: Այս մոդելի դեպքում ծրագրային ապահովումը սովորաբար տրամադրվում է բաժանորդագրության սկզբունքով, որտեղ կազմակերպությունը վճարում է ամսական կամ տարեկան վճար՝ կախված օգտագործողների քանակից կամ ծառայության ծավալից:

SaaS մոդելի հիմնական առավելությունն օգտագործման պարզությունն է: Չկա տեղադրման կամ բարդ կարգաբերման անհրաժեշտություն, քանի որ համակարգը պատրաստ է օգտագործման հենց գրանցումից հետո: Թարմացումները կատարվում են ավտոմատ կերպով՝ առանց օգտվողի միջամտության, ինչը նշանակում է, որ ծրագրային ապահովումը միշտ աշխատում է վերջին տարբերակով և համապատասխանում է անվտանգության արդիական պահանջներին:

Մեկ այլ կարևոր առավելություն հասանելիությունն է: Քանի որ SaaS լուծումները աշխատում են ամպային միջավայրում, օգտվողները կարող են մուտք գործել համակարգ աշխարհի ցանկացած կետից՝ օգտագործելով համակարգիչ, պլանշետ կամ բջջային սարք: Սա հատկապես կարևոր է հեռավար աշխատանքի, միջազգային թիմերի և բազմաճյուղ կազմակերպությունների համար:

SaaS մոդելը նաև ապահովում է արագ մասշտաբելիություն: Եթե կազմակերպությունում ավելանում է օգտվողների քանակը, հնարավոր է հեշտությամբ ավելացնել նոր հաշիվներ՝ առանց լրացուցիչ տեխնիկական միջամտության: Նույն կերպ, անհրաժեշտության դեպքում կարելի է նվազեցնել օգտագործողների թիվը և համապատասխանաբար նվազեցնել ծախսերը:

Բացի այդ, SaaS համակարգերը հաճախ ներառում են ինտեգրման հնարավորություններ այլ ծառայությունների և հարթակների հետ: Դրանք կարող են միացվել հաշվապահական համակարգերին, հաճախորդների կառավարման հարթակներին կամ վերլուծական գործիքներին, ինչը բարձրացնում է բիզնես գործընթացների արդյունավետությունը:

Այնուամենայնիվ, SaaS մոդելը ունի նաև որոշ սահմանափակումներ: Հարմարեցման հնարավորությունները սովորաբար սահմանափակ են այն ֆունկցիոնալությամբ, որը տրամադրում է մատակարարը: Եթե կազմակերպությունը ունի հատուկ կամ եզակի պահանջներ, հնարավոր է, որ SaaS լուծումը չկարողանա լիովին բավարարել դրանք:

Տվյալների վերահսկողությունը ևս կարևոր հարց է: Քանի որ տվյալները պահվում են մատակարարի տվյալների կենտրոններում, կազմակերպությունը չի ունենում ֆիզիկական վերահսկողություն դրանց նկատմամբ: Սա կարող է առաջացնել անվտանգության կամ իրավական մտահոգություններ, հատկապես այն ոլորտներում, որտեղ տվյալների գաղտնիությունը և պահպանման կանոնները խիստ կարգավորվում են:

Բացի այդ, SaaS մոդելը կախված է ինտերնետ կապից: Առանց կայուն կապի հնարավոր չէ օգտվել ծառայությունից, ինչը կարող է սահմանափակում լինել որոշ իրավիճակներում: Երկարաժամկետ հեռանկարում բաժանորդագրության վճարները կարող են դառնալ զգալի ծախս, հատկապես մեծ կազմակերպությունների համար, որտեղ օգտագործողների թիվը բարձր է:

Ընդհանուր առմամբ, SaaS մոդելը հանդիսանում է ժամանակակից և արդյունավետ լուծում այն կազմակերպությունների համար, որոնք ցանկանում են արագ, պարզ և նվազագույն տեխնիկական բարդությամբ ներդնել ծրագրային համակարգեր: Այն ապահովում է հասանելիություն, ավտոմատացում և մասշտաբելիություն, սակայն պահանջում է վստահություն մատակարարի նկատմամբ և ռազմավարական մոտեցում տվյալների կառավարման հարցում:

## 1.5: Ամպային Տեխնոլոգիաների Մատակարարները

Ամպային տեխնոլոգիաների զարգացումը վերջին տասնամյակներում արմատապես փոխել է տեղեկատվական տեխնոլոգիաների ոլորտը՝ կազմակերպություններին հնարավորություն տալով հրաժարվել միայն տեղային ենթակառուցվածքներից և օգտվել մասշտաբելի, ճկուն և հեռավար կառավարվող հաշվարկային ռեսուրսներից: Ամպային ծառայությունների մատակարարները ձևավորել են համաշխարհային ենթակառուցվածքային հարթակներ, որոնք ապահովում են տվյալների պահպանում, հաշվարկային հզորություններ, արհեստական բանականության գործիքներ, վերլուծական համակարգեր և բազմազան բիզնես ծառայություններ:

Ամպային շուկայի առաջատարներից է Microsoft ընկերության կողմից մշակված Microsoft Azure հարթակը: Azure-ը առաջարկում է լայնածավալ ծառայությունների փաթեթ՝ ներառյալ վիրտուալ մեքենաներ, տվյալների բազաների կառավարման համակարգեր, արհեստական բանականության և մեքենայական ուսուցման գործիքներ, DevOps միջավայրեր և կիբերանվտանգության լուծումներ: Azure-ը հատկապես լայն կիրառություն ունի ֆինանսական, պետական և կորպորատիվ ոլորտներում՝ ապահովելով բարձր հասանելիություն, գլոբալ տվյալային կենտրոնների ցանց և համապատասխանություն միջազգային ստանդարտներին:

Ամպային ծառայությունների մեկ այլ խոշոր մատակարար է Amazon ընկերության ամպային ստորաբաժանումը՝ Amazon Web Services: AWS-ը համարվում է շուկայի առաջին խոշորամասշտաբ ամպային հարթակներից մեկը և առաջարկում է հարյուրավոր ծառայություններ՝ հաշվողական ռեսուրսներից և պահեստավորումից մինչև տվյալների վերլուծություն, IoT լուծումներ և քվանտային հաշվարկման գործիքներ: AWS-ի հիմնական առավելություններից է ծառայությունների լայն ընտրանին, գլոբալ հասանելիությունը և բարձր ճկունությունը տարբեր բիզնես մոդելների համար:

Oracle Corporation ընկերությունը ևս հանդես է գալիս որպես ամպային ծառայությունների մատակարար՝ իր Oracle Cloud հարթակի միջոցով: Oracle-ը ավանդաբար հայտնի է տվյալների բազաների կառավարման համակարգերով, և դրա ամպային լուծումները հիմնականում կենտրոնացած են ձեռնարկությունների մակարդակի բիզնես համակարգերի, ERP և տվյալների բազաների բարձր արդյունավետության ապահովման վրա: Oracle Cloud-ը հաճախ ընտրվում է այն կազմակերպությունների կողմից, որոնք արդեն օգտագործում են Oracle տեխնոլոգիաները և ցանկանում են անցում կատարել ամպային միջավայրի:

Ամպային տեխնոլոգիաների շուկայում կարևոր դեր ունի նաև Google ընկերության Google Cloud Platform հարթակը: Google Cloud-ը առանձնանում է տվյալների վերլուծության, մեծ տվյալների մշակման և արհեստական բանականության ոլորտներում առաջադեմ լուծումներով: Այն լայնորեն կիրառվում է տեխնոլոգիական ստարտափների, հետազոտական կազմակերպությունների և այն բիզնեսների կողմից, որոնք պահանջում են բարձր արտադրողականություն և տվյալահեն որոշումների ընդունման գործիքներ:

IBM ընկերությունը ևս հանդիսանում է ամպային ծառայությունների մատակարար՝ իր IBM Cloud հարթակի միջոցով: IBM Cloud-ը կենտրոնանում է հիբրիդային ամպային լուծումների վրա՝ համադրելով տեղային և ամպային ենթակառուցվածքները: Այն հատկապես կիրառվում է խոշոր կորպորացիաների և ֆինանսական հաստատությունների կողմից, որտեղ կարևոր են անվտանգությունը, տվյալների գաղտնիությունը և կարգավորող պահանջներին համապատասխանությունը:

Այս մատակարարները ձևավորում են գլոբալ ամպային էկոհամակարգ, որտեղ կազմակերպությունները կարող են ընտրել իրենց պահանջներին առավել համապատասխան ենթակառուցվածքային, հարթակային կամ ծրագրային ծառայությունները: Ամպային տեխնոլոգիաների մատակարարների միջև մրցակցությունը նպաստում է նորարարության զարգացմանը, ծառայությունների որակի բարձրացմանը և ծախսերի օպտիմալացմանը՝ ապահովելով թվային տրանսֆորմացիայի շարունակական առաջընթաց:

## 1.6: Microsoft Azure Ամպային Հարթակը

Microsoft Azure-ը Microsoft ընկերության ստեղծած լայնածավալ և բազմաֆունկցիոնալ ամպային հարթակն է, որը առաջարկում է ավելի քան 200 ծառայություն և համապատասխանում է ինչպես փոքր ընկերությունների, այնպես էլ մեծ ձեռնարկությունների պահանջներին: Azure-ը հնարավորություն է տալիս կառուցել, փորձարկել, տեղակայել և կառավարել ծրագրեր՝ առանց ֆիզիկական ենթակառուցվածքներ ունենալու անհրաժեշտության:

Azure-ի հիմնական ծառայությունները ներառում են հաշվողական հզորություն, ինչպիսիք են Virtual Machines (VMs), որոնք տրամադրում են տարբեր օպերացիոն համակարգերով վիրտուալ սերվերներ, Azure Functions՝ առանձ սերվերների հաշվարկ, որտեղ կոդը աշխատում է իրադարձությունների հիման վրա, և App Services՝ վեբ ծրագրերի հոստինգի համար: Տվյալների պահեստավորման ոլորտում Azure-ն առաջարկում է Blob Storage, որը նախատեսված է մեծ չստրուկտուրավորված տվյալների պահպանման համար, Azure Files՝ կիսվող ֆայլային համակարգ, ինչպես նաև Data Lake Storage՝ մեծ չափի պահեստ տարբեր տիպի տվյալների համար:

Տվյալների բազաների ոլորտում ծառայությունների շարքում են Azure SQL Database, որը հանդիսանում է կառավարվող տվյալների բազա, Cosmos DB՝ գլոբալ բաշխված և բարձր աշխատանքային կարողություններով NoSQL տիպի տվյալների բազա, և PostgreSQL/MySQL ծառայություններ: Մեքենայական ուսուցման և արհեստական բանականության համար Azure-ը տրամադրում է Azure Machine Learning ծառայությունը՝ մեքենայական ուսուցման մոդելների մշակման, ուսուցման և տեղակայման ամբողջական միջավայր, ինչպես նաև Cognitive Services՝ տեսողության, խոսքի, լեզվի, որոնման և այլ տիպերի API-ների համախումբ:

Տվյալների պրոցեսավորման և ինտեգրման ոլորտում Azure-ի ծառայությունները ներառում են Azure Data Factory-ն՝ տվյալների տեղափոխման և փոխակերպման համար, և Azure Synapse Analytics՝ մեծածավալ տվյալների վերլուծության և բիզնես ինտելեկտի ապահովման համար: Ցանցային ծառայությունների շարքում ընդգրկված են Virtual Network, Load Balancer, VPN Gateway, Firewall, ինչպես նաև CDN, DDoS հարձակումներից պաշտպանություն և այլ ցանցային գործիքներ:

Azure-ի հիմնական առավելությունն այն է, որ այն ապահովում է ճկունություն, գլոբալ հասանելիություն և անվտանգություն, միաժամանակ նվազեցնելով կազմակերպությունների տեխնիկական և ֆինանսական բեռնվածությունը:

# ԳԼՈՒԽ 2: ՕԳՏԱԳՈՐԾՎԱԾ ՏՎՅԱԼՆԵՐԻ ՃԱՐՏԱՐԱՊԵՏՈՒԹՅՈՒՆ

## 2.1: ETL/ELT Տվյալային Խողովակաշարեր (Data Pipelines)

ETL-ը տվյալների ինտեգրման դասական եղանակ է, որի նպատակը տարբեր աղբյուրներից ստացված տվյալները մաքրելն, փոխակերպելն ու պահպանելն է տվյալների պահեստում: ETL-ի գործընթացը բաղկացած է երեք փուլից՝ Extract, Transform և Load:

Առաջին փուլը՝ Extract, որի ընթացքում տվյալները վերցվում են տարբեր աղբյուրներից, օրինակ՝ տվյալների բազաներից, ինչպիսիք են SQL database կամ Oracle, API-ներից և վեբ ծառայություններից, CSV, JSON, Excel ֆայլերից, ինչպես նաև օպերացիոն համակարգերից կամ լոգ ֆայլերից: Այս փուլում տվյալները հիմնականում վերցվում են իրենց սկզբնական՝ հում վիճակում (raw):

Երկրորդ փուլը՝ ձևափոխում (transform), որտեղ տվյալները ձևափոխվում են միջանկյալ պրոցեսավորման միջավայրերում, օրինակ՝ ETL սերվերի վրա կամ հատուկ ETL գործիքի միջոցով: Ձևափոխումը ընդգրկում է տվյալների մաքրում, ֆորմատների փոխակերպում, աղյուսակների միավորում, ագրեգացիաների և հաշվարկների ընդգրկում:

Վերջնին փուլը՝ Load, որը ապահովում է ձևափոխված տվյալների պահպանումը նպատակային տվյալների պահեստում, սովորաբար Data Warehouse-ում, ինչպիսիք են Azure SQL Data Warehouse կամ Teradata: ETL ինտեգրման եղանակը արդյունավետ է, երբ անհրաժեշտ է ապահովել ծանր և բարդ հաշվարկներ ձևափոխման փուլում, և երբ նպատակային պահեստը չունի մեծ հաշվարկային հզորություն, երբ անհրաժեշտ է նախապես մաքրել և հետո միայն պահել վավերացված տվյալներ, ինչպես նաև երբ տվյալները անկանոն կառուցվածքով են:

ELT-ն (Extract - Load - Transform) մոտեցումը տարբերվում է ETL-ից նրանով, որ գործընթացի փուլերի հերթականությունը փոխված է, և վերափոխումները կատարվում են հենց նպատակային տվյալների պահեստում: Սա դարձել է հնարավոր ժամանակակից ամպային տվյալների պահեստների մեծ հաշվարկային հզորության շնորհիվ: ELT-ում առաջին փուլը Extract է, որի ընթացքում աղբյուրներից ստացվում են տվյալները՝ առանց մեծ վերափոխումների: Երկրորդ փուլը՝ Load, ենթադրում է raw ֆորմատի տվյալների անմիջական պահպանումը տվյալների պահեստում, օրինակ՝ Azure Synapse Analytics, Snowflake, BigQuery կամ Databricks Delta Lake: Երրորդ փուլը՝ Transform, իրականացվում է հենց պահեստի ներսում՝ օգտագործելով SQL-ի, Spark-ի կամ MPP (Massively Parallel Processing) հաշվարկային մեխանիզմները:

ELT մոտեցման առավելությունն այն է, որ ժամանակակից պահեստներն ունեն մեծ հաշվարկային հզորություն և կարող են արագ մշակել հսկայական ծավալի տվյալներ: ELT-ն հատկապես օգտակար է, երբ աշխատում ենք մեծ ծավալի տվյալների հետ, երբ պահեստը ունի բարձր հաշվարկային հզորություն, երբ վերափոխումները կարելի է իրականացնել SQL կամ Spark պահեստի ներսում, ինչպես նաև երբ անհրաժեշտ է արագ բեռնել տվյալները և միայն հետո մշակել դրանք: Դրանց համեմատության աղյուսակը բերված է Աղյուսակ 1-ում:

Աղյուսակ 1

| Բնութագիր | ETL | ELT |
|---|---|---|
| Զնափոխման տեղը | Միջանկյալ համակարգ | Տվյալների պահեստ |
| Առավել հարմար է | Փոքր և միջին տվյալների համակարգերի համար | Մեծ տվյալների, ամպային պահեստների համար |
| Հաշվարկային ծանրաբեռնվածություն | ETL սերվերի վրա | Cloud / Data Warehouse-ի վրա |
| Տվյալների պահպանում | Պահպանվում են միայն վերափոխված տվյալները | Պահպանվում են ինչպես վերափոխված տվյալները, այնպես էլ հում տվյալները |
| Գործիքներ | SSIS, Informatica, Talend | Azure Synapse, Databricks, Snowflake, BigQuery |

## 2.2: «Մեդալիոն» Ճարտարապետություն

Վերջին տարիներին տվյալային համակարգերի զարգացման մեջ լայնորեն կիրառվող մեդալիոնային ճարտարապետությունը ներկայացվում է որպես հստակ կառուցվածք, որի նպատակն է ստեղծել հասկանալի, վերահսկելի և երկարաժամկետ վստահելի տվյալային միջավայր։ Այդ մոտեցումը հիմնված է այն գաղափարի վրա, որ տվյալները պետք է անցնեն հաջորդական փուլերով, որտեղ յուրաքանչյուր փուլ ապահովում է ավելի բարձր որակ և մաքրություն։ Այս պատճառով էլ ամբողջ գործընթացը իրենց անվանումը ստացել է «մեդալիոն»՝ շերտերով կառուցված համակարգի գաղափարով։

Տվյալների առաջին կանգառը համարվում է բրոնզե շերտը, որտեղ դրանք պահվում են հում տեսքով՝ այնպես, ինչպես ստացվում են տարբեր աղբյուրներից։ Այստեղ կարող են գտնվել տարբեր ձևաչափերով տվյալներ՝ լոգեր, սենսորների հոսքեր, բազաների արտահանումներ կամ այլ չմշակված ֆայլեր։ Այս փուլում տվյալների վրա որևէ փոփոխություն չի կատարվում, քանի որ նպատակն է պահպանել դրանց ամբողջականությունը և ապահովել հետագա քայլերի համար անհրաժեշտ հուսալի հիմք։ Բրոնզե շերտը նաև պահպանում է տվյալների ծագումնաբանությունը, ինչը կարևոր է հետագա վերլուծությունների և աուդիտի համար։

Հաջորդ փուլը արծաթե շերտն է, որտեղ տվյալները ենթարկվում են մաքրումի և կառուցվածքային ընդհանրացման։ Այս փուլում վերացվում են կրկնօրինակները, շտկվում են սխալ կամ անհամապատասխան ձևաչափերը, լրացվում են բացակայող արժեքները, և տարբեր աղբյուրներից ստացված տվյալները համադրվում են միմյանց հետ։ Արծաթե շերտը դարձնում է տվյալները կանոնավոր, միատեսակ և տրամաբանորեն կապված։ Սա այն միջին մակարդակն է, որտեղ արդեն կարող է կիրառվել բիզնես տրամաբանության մի մասը, սակայն տվյալները դեռ չեն հասել իրենց վերջնական մոդելին։

Ճարտարապետության ամենավերջին և ամենահաստատուն փուլը ոսկե շերտն է։ Այստեղ տվյալները դառնում են առավել որակյալ, ամբողջապես մաքրված և պատրաստ բիզնես վերլուծության համար։ Այս փուլում դրանք խմբագրվում և ագրեգացվում են՝ համապատասխանեցված կազմակերպության պահանջներին։ Ոսկե շերտից առաջացած տվյալները օգտագործվում են հաշվետվությունների, վերլուծական մոդելների, ցուցանիշների հաշվարկների և կառավարման որոշումների համար։ Շատ կազմակերպություններ այս շերտը դիտարկում են որպես իրենց միավորային ճշմարտության աղբյուր, քանի որ այստեղ գտնվող տվյալները ունեն առավելագույն վստահելիություն։

Մեդալիոնային ճարտարապետությունը գնահատվում է իր պարզությամբ և բարձր արդյունավետությամբ։ Այն թույլ է տալիս կազմակերպություններին ունենալ պատշաճ տվյալային համակարգ, որտեղ տվյալների որակը բարձրանում է աստիճանաբար, իսկ ամբողջ գործընթացը դառնում է կանխատեսելի և թափանցիկ

## 2.3: OLTP/OLAP Համակարգեր

OLTP (Online Transaction Processing) համակարգերը նախատեսված են օպերացիոն աշխատանքների համար, որտեղ առաջնահերթ են արագությունն ու կայունությունը, ինչպես նաև տվյալների մանրամասն վերահսկումը: Դրանք զբաղվում են առօրյա գործարքներով, որոնք փոքր ծավալով են, բայց տեղի են ունենում հաճախակի: Այս համակարգերը կարող են միաժամանակ սպասարկել հազարավոր կամ միլիոնավոր կարճ տևողությամբ տրանզակցիաներ՝ ապահովելով բարձր արագությունը և տվյալների ամբողջականությունը՝ պահպանելով ACID սկզբունքները, որոնցում ընդգրկված են Atomicity, Consistency, Isolation և Durability: Տվյալները սովորաբար պահվում են նորմալիզացված բազաներում՝ բազմաթիվ աղյուսակների բաժանված, որպեսզի նվազեցնեն կրկնօրինակումները և բարձրացնեն ամբողջականությունը: Օրինակների շարքում կարելի է նշել բանկային համակարգերը, որոնք ապահովում են հաշվիների միջև փոխանցումները և քարտային վճարումները, առցանց խանութները, որոնք իրականացնում են պատվերների գրանցում, վճարումներ և պահեստային փոփոխություններ, ինչպես նաև CRM համակարգերը, որոնք թույլ են տալիս օպերացիոն կառավարում հաճախորդների տվյալների:

OLAP (Online Analytical Processing) համակարգերը նախատեսված են վերլուծական և բիզնես-վերլուծական խնդիրների համար, երբ անհրաժեշտ է աշխատել մեծ ծավալի պատմական տվյալների հետ, կատարել բարդ հարցումներ և ստանալ խորքային վերլուծություն: Այս համակարգերը ապահովում են բարդ վերլուծական հարցումներ, որոնք կարող են ներառել խմբավորումներ, ագրեգացիաներ և բազմաչափ վերլուծություններ: Տրանզակցիոն հաճախականությունը սովորաբար ցածր է, և հարցումները կարող են տևել վայրկյաններ կամ նույնիսկ րոպեներ: Տվյալները պահվում են դենորմալիզացված կառուցվածքով՝ օգտագործելով Star կամ Snowflake Schema, ինչը ապահովում է վերլուծական հաշվարկների արագագործությունը: Այս համակարգերը հաճախ օգտագործվում են BI և Dashboard-ների ստեղծման համար, օրինակ՝ Power BI, Tableau և reporting համակարգերում: Օրինակներ են հանդիսանում Azure Synapse Analytics՝ ամպային մեծ տվյալների և վերլուծության հարթակը, ինչպես նաև Data Warehouse համակարգերը, ինչպիսիք են Snowflake, Google BigQuery և Amazon Redshift:

# ԳԼՈՒԽ 3: ՏՎՅԱԼՆԵՐԻ ՃԱՐՏԱՐԱՊԵՏՈՒԹՅԱՆ ԳՈՐԾԻՔԱԿԱՑՄԵՐԸ MICROSOFT AZURE-ՈՒՄ

## 3.1: Microsoft Azure Data Factory Մեծ Տվյալների ինտեգրման գործիքակազմ

Azure Data Factory-ն Microsoft Azure-ի ամպային տվյալների ինտեգրման ծառայությունն է, որը թույլ է տալիս կառուցել ամբողջական տվյալային հոսքեր՝ սկսած տվյալների հավաքագրումից մինչև դրանց մշակում, փոխակերպում և պահպանում տարբեր նպատակային համակարգեր: Այն հանդիսանում է որպես կապող օղակ տարբեր տվյալների աղբյուրների միջև՝ ապահովելով ավտոմատացված, վերահսկվող և մասշտաբավորվող տվյալային գործընթացներ: Azure Data Factory-ն լայնորեն կիրառվում է ETL և ELT գործընթացների իրականացման, Data Pipeline-ների ստեղծման ու կառավարման, բազմաթիվ աղբյուրներից տվյալների տեղափոխելը դեպի պահեստներ, ինչպես նաև տարբեր քայլերի հաջորդական կառավարման, ժամանակացույցի և սխալների մշակման համար: Ծառայությունը հնարավորություն է տալիս աշխատել ինչպես Azure-ի ներքին, այնպես էլ արտաքին կամ տեղային տվյալների աղբյուրների հետ, ապահովելով ճկուն ինտեգրում:

Azure Data Factory-ի հիմնական բաղադրիչներն են Pipelines, Activities, Linked Services, Datasets և Integration Runtime: Pipelines-ը ADF-ի հիմնական կառուցվածքային միավորն է, որը ներկայացնում է գործողությունների տրամաբանական հավաքածու՝ միաժամանակ կատարելով գործընթացներ տվյալների հետ, օրինակ՝ տվյալների ստացում, մաքրում և պահեստավորում: Pipeline-ները կարող են աշխատել ժամանակացույցով, արձագանքել տրիգերներին, պարունակել կախվածություններ և լինել մասշտաբավորվող ու վերահսկվող:

Activities-ը Pipeline-ի մեջ գործող քայլերն են, որտեղ ամեն activity կատարում է կոնկրետ առաջադրանք, ինչպիսիք են տվյալների պատճենումը, SQL սքրիպտի գործարկումը կամ API կանչը: Հիմնական activity-ներն են Copy Activity, որը իրականացնում է տվյալների փոխանցում աղբյուրից դեպի նպատակային պահեստ, Data Flow, որը ապահովում է տվյալների գրաֆիկական ձևափոխում Spark-ին նման parallel engines-ի վրա, Stored Procedure Activity, որը գործարկում է SQL stored procedure տվյալների բազայում, Web/HTTP Activity, որը կատարում է վեբ API-ների կանչ տվյալներ ստանալու կամ գործողություն անելու համար, և Execute Pipeline, որը թույլ է տալիս մեկ pipeline-ի կանչը մյուսից՝ բարդ workflows կառուցելու ժամանակ:

Linked Services-ը կապ է, որը սահմանում է, թե ինչպես է ստեղծվում կապը տվյալների աղբյուրի և նպատակային սերվիսի հետ: Այն պարունակում է connection string, authentication տվյալներ և endpoint հասցե: Օրինակներ են Azure Blob Storage, Azure SQL Database, On-premises SQL Server, Amazon S3, Salesforce և Oracle: Linked Services-ը ADF-ի օբյեկտների միջև կապերի հաստատման գործիքն է:

Dataset-ը ներկայացնում է այն տվյալային օբյեկտը, որի վրա աշխատում են activity-ները: Այն նկարագրում է տվյալների տեսակը, սխեման, ֆայլի ձևաչափը (CSV, JSON, Parquet): Dataset-ը տվյալներն ինքնին չեն, այլ դրանց ներկայացումն է:

Integration Runtime-ը ADF-ի հաշվարկային ենթակառուցվածքն է, որը իրականացնում է տվյալների փոխանցումն ու ձևափոխումը: Այն է engine-ը, որը ֆիզիկապես կատարում է Copy Activity-ը, Data Flow-ը և այլ transform-ներ: IR-ի տեսակներն են Azure IR, որը ամբողջությամբ կառավարվում է Azure-ի կողմից և օգտագործվում է cloud-to-cloud տվյալների շարժի համար, աշխատելով առանձ սերվեր, Self-hosted IR, որը տեղակայվում է օգտագործողի սեփական on-premises կամ VM միջավայրում և թույլ է տալիս աշխատել firewalled միջավայրերում On-premises ↔ Cloud տվյալների շարժի համար, և Azure SSIS IR, որը նախատեսված է SSIS (SQL Server Integration Services) packages-ները փոխադրել Azure և աշխատում է որպես լիարժեք SSIS կատարման միջավայր ամպում:

## 3.2: Azure Databricks Վերլուծական Համակարգ

Ժամանակակից թվային միջավայրում, որտեղ տվյալների ծավալը հասնում է տերաբայթների և պետաբայթների, մեծ տվյալների արդյունավետ մշակումը դարձել է կազմակերպությունների ռազմավարական առաջնահերթություն: Microsoft ընկերության ամպային հարթակում գործող Azure Databricks ծառայությունը ստեղծվել է որպես համատեղ լուծում Databricks ընկերության հետ և հիմնված է Apache Spark բաշխված հաշվարկային տեխնոլոգիայի վրա:

Azure Databricks-ը նախատեսված է մեծ տվյալների բաշխված մշակման, տվյալների ճարտարագիտության և մեքենայական ուսուցման խնդիրների լուծման համար: Apache Spark-ի հիմքով այն թույլ է տալիս տվյալները բաժանել փոքր հատվածների և մշակել զուգահեռ հաշվարկային հանգույցներում, ինչի արդյունքում զգալիորեն բարձրանում է կատարողականությունը և կրճատվում մշակման ժամանակը: Ծառայությունը տրամադրում է ամբողջությամբ կառավարվող միջավայր, որտեղ հնարավոր է ստեղծել ավտոմատ մասշտաբավորվող հաշվարկային կլաստերներ, վերահսկել ռեսուրսների օգտագործումը և օպտիմալացնել ծախսերը՝ կախված ծանրաբեռնվածությունից:

Databricks միջավայրը ապահովում է համագործակցային notebook-ներ, որոնք աջակցում են մի քանի ծրագրավորման լեզուների, մասնավորապես Python, SQL, Scala և R: Սա թույլ է տալիս տվյալների ինժեներներին, վերլուծաբաններին և տվյալագետներին աշխատել նույն նախագծի վրա՝ միևնույն միջավայրում: Notebook-ները հնարավորություն են տալիս համատեղել կոդը, վիզուալիզացիան և բացատրական տեքստը, ինչը կարևոր է ինչպես հետազոտական, այնպես էլ արտադրական նախագծերի համար:

Databricks-ը լայնորեն կիրառվում է տվյալների ներմուծման, մաքրման և վերափոխման գործընթացներում: Այն աջակցում է ինչպես batch, այնպես էլ streaming մշակում, ինչը թույլ է տալիս աշխատել ինչպես կուտակված, այնպես էլ իրական ժամանակում հոսող տվյալների հետ: Structured Streaming տեխնոլոգիան ապահովում է միասնական ծրագրավորման մոդել՝ պարզեցնելով տվյալների հոսքային մշակումը և ապահովելով բարձր հուսալիություն նույնիսկ մեծ բեռնվածության պայմաններում: Այս մոտեցումը հատկապես կարևոր է ֆինանսական գործարքների մշակումում, առցանց ծառայություններում և IoT միջավայրերում, որտեղ տվյալների ուշացումը կարող է հանգեցնել ռիսկերի կամ տնտեսական կորուստների:

Հատուկ կարևորություն ունի Delta Lake տեխնոլոգիան, որը տվյալների համար ապահովում է տրանզակցիոն հատկություններ և տվյալների տարբերակավորում: Delta Lake-ը ներդնում է ACID հատկություններ, ինչը նշանակում է, որ տվյալների գրառումները կատարվում են հուսալի և վերահսկվող եղանակով: Բացի այդ, այն ապահովում է schema enforcement և schema evolution հնարավորություններ, որոնք կարևոր են տվյալների կառուցվածքի փոփոխությունների կառավարման համար: Այս

մեխանիզմները զգալիորեն բարձրացնում են տվյալների որակը և նվազեցնում սխալների հավանականությունը արտադրական համակարգերում:

Azure Databricks-ը նաև հզոր գործիք է մեքենայական ուսուցման և առաջադեմ վերլուծության համար: Տվյալագիտության թիմերը կարող են կիրառել տարբեր գրադարաններ և շրջանակներ՝ ներառյալ խորը ուսուցման և դասական մեքենայական ուսուցման մեթոդները: Spark-ի բաշխված բնույթը թույլ է տալիս մոդելները ուսուցանել մեծածավալ տվյալների վրա՝ օգտագործելով զուգահեռ հաշվարկներ: Ծառայությունը տրամադրում է գործիքներ փորձարկումների կառավարման, մոդելների վերսիանավորման և արդյունքների վերահսկման համար, ինչը կարևոր է արտադրական միջավայրում մոդելների տեղակայման ժամանակ:

Բացի տվյալների մշակման և մեքենայական ուսուցման հնարավորություններից, Azure Databricks-ը ինտեգրվում է ամպային տվյալների պահեստավորման ծառայությունների և տվյալների ներմուծման գործիքների հետ: Սա հնարավորություն է տալիս կառուցել ամբողջական տվյալային ճարտարապետություն՝ տվյալների հավաքագրումից մինչև վերլուծություն և մոդելների տեղակայում: Ինտեգրված անվտանգության մեխանիզմները, ներառյալ նույնականացումը և մուտքի վերահսկումը, ապահովում են տվյալների պաշտպանությունը և համապատասխանությունը կազմակերպության ներքին քաղաքականություններին:

Այսպիսով, Azure Databricks-ը հանդիսանում է ժամանակակից մեծ տվյալների հարթակ, որը միավորում է բաշխված հաշվարկը, տվյալների ինժեներիան և մեքենայական ուսուցումը մեկ միասնական և մասշտաբելի միջավայրում: Այն հնարավորություն է տալիս կազմակերպություններին արագ մշակել մեծածավալ տվյալներ, ստեղծել կանխատեսողական մոդելներ և վերածել տվյալները բիզնես արժեքի՝ ապահովելով բարձր արտադրողականություն և ճկունություն թվային փոխակերպման գործընթացում:

## 3.3: Azure Synapse Վերլուծական Համակարգ

Azure Synapse Analytics ծառայությունը հանդիսանում է համալիր անալիտիկ հարթակ, որը համատեղում է տվյալների պահեստավորումը և մեծ տվյալների մշակումը մեկ միասնական միջավայրում: Այն մշակվել է Microsoft ընկերության կողմից և նախատեսված է հատկապես enterprise մակարդակի կազմակերպությունների համար, որոնք աշխատում են մեծ քանակի կառուցվածքային տվյալների հետ և իրականացնում են բարդ բիզնես վերլուծություններ, ֆինանսական հաշվարկներ և ռազմավարական պլանավորում:

Synapse-ի հիմնական գաղափարախոսությունը տվյալների տարբեր աշխարհների միավորումն է մեկ ընդհանուր միջավայրում: Ավանդաբար կազմակերպությունները առանձնացնում էին տվյալների պահեստը (Data Warehouse) և մեծ տվյալների մշակման հարթակները: Synapse-ը միավորում է այս մոտեցումները՝ թույլ տալով աշխատել ինչպես դասական SQL հարցումների, այնպես էլ բաշխված հաշվարկային մեխանիզմների միջոցով:

Synapse-ը տրամադրում է dedicated SQL pool, որը բաշխված տվյալների պահեստ է բարձր կատարողականությամբ հարցումների համար: Այս ճարտարապետությունը հիմնված է տվյալների հորիզոնական բաժանման վրա, ինչը թույլ է տալիս մեծ ծավալի տվյալների վրա իրականացնել բարդ հարցումներ կարճ ժամանակահատվածում: Dedicated SQL pool-ը հատկապես արդյունավետ է ֆինանսական հաշվետվությունների, բազմաչափ վերլուծությունների, KPI-ների հաշվարկման և գործադիր մակարդակի հաշվետվությունների ձևավորման համար: Այն ապահովում է բարձր հասանելիություն և կայուն կատարողականություն նույնիսկ ծանրաբեռնվածության պայմաններում:

Բացի dedicated ռեժիմից, Synapse-ն առաջարկում է նաև serverless SQL հնարավորություններ: Այս մոտեցման դեպքում օգտատերը կարող է անմիջապես հարցումներ կատարել տվյալների լճում պահվող ֆայլերի վրա՝ առանց դրանք նախապես բեռնելու տվյալների պահեստ: Սա էապես նվազեցնում է ենթակառուցվածքային բարդությունը և թույլ է տալիս իրականացնել արագ փորձարկումներ կամ ադ հոկ վերլուծություններ: Serverless մոդելը նաև նպաստում է ծախսերի օպտիմալացմանը, քանի որ վճարումը կատարվում է ըստ հարցումների իրական կատարման ծավալի, այլ ոչ թե մշտապես գործող հաշվարկային ռեսուրսների համար:

Synapse-ը ներառում է նաև Spark pool, որը հնարավորություն է տալիս իրականացնել բաշխված տվյալների մշակում նույն միջավայրում: Spark pool-ի միջոցով հնարավոր է աշխատել կիսակառուցվածքային և չկառուցվածքային տվյալների հետ, իրականացնել տվյալների նախնական մշակում, վերափոխում և ինտեգրում մինչև դրանց ներմուծումը տվյալների պահեստ: Այսպիսով, Synapse-ը համադրում է ETL գործընթացները, մեծ տվյալների մշակումն ու ավանդական տվյալների պահեստավորումը մեկ միասնական հարթակում:

Հարթակը տրամադրում է նաև ինտեգրված աշխատանքային միջավայր՝ Synapse Studio, որտեղ օգտատերերը կարող են կառավարել SQL հարցումները, Spark աշխատանքները, տվյալների ներմուծման գործընթացները և մոնիթորինգը մեկ վեբ միջերեսից: Սա բարձրացնում է թիմային համագործակցության արդյունավետությունը և նվազեցնում տարբեր գործիքների միջև անցումների անհրաժեշտությունը:

Synapse-ը լայնորեն կիրառվում է բիզնես վերլուծության, ֆինանսական մոդելավորման, մատակարարման շղթայի կառավարման, հաճախորդների վարքագծի վերլուծության և ռիսկերի գնահատման ոլորտներում: Այն թույլ է տալիս միավորել պատմական տվյալները և իրական ժամանակում մուտք գործող տեղեկատվությունը՝ ստեղծելով ամբողջական վերլուծական պատկեր:

Ծառայությունը ինտեգրված է Azure-ի այլ տվյալային և վիզուալիզացիոն լուծումների հետ, ինչը հնարավորություն է տալիս կառուցել ամբողջական տվյալային ճարտարապետություն՝ տվյալների հավաքագրումից և մաքրումից մինչև խորացված վերլուծություն և արդյունքների ներկայացում բիզնես օգտատերերին: Այս ինտեգրված մոտեցումը ապահովում է բարձր մասշտաբելիություն, տվյալների անվտանգություն և կազմակերպության մակարդակով կենտրոնացված կառավարում:

Այսպիսով, Azure Synapse Analytics-ը հանդիսանում է ժամանակակից ձեռնարկությունների համար համապարփակ անալիտիկ հարթակ, որը միավորում է տվյալների պահեստավորման հզորությունը և մեծ տվյալների մշակման ճկունությունը մեկ կառավարվող և մասշտաբելի միջավայրում:

## 3.4: Գործիքների Համեմատականները

Azure Databricks և Azure Synapse Analytics ծառայությունները նախատեսված են մեծ տվյալների և անալիտիկ խնդիրների լուծման համար, սակայն ունեն տարբեր առաջնահերթություններ, կիրառման ոլորտներ և թիրախային օգտատերերի խմբեր: Երկուսն էլ հանդիսանում են Microsoft ընկերության ամպային տեխնոլոգիաների կարևոր բաղադրիչները, սակայն նախագծված են տարբեր սցենարների և աշխատանքային հոսքերի համար:

Databricks-ը առավելապես ուղղված է տվյալների ինժեներներին և տվյալագետների կողմից օգտագործելու համար: Այն առանձնանում է ճկունությամբ, բաց էկոհամակարգով և առաջադեմ մեքենայական ուսուցման հնարավորություններով: Apache Spark-ի վրա հիմնված ճարտարապետությունը ապահովում է բարձր կատարողականություն մեծածավալ և չկառուցվածքային տվյալների մշակման ժամանակ: Այն հատկապես արդյունավետ է տվյալների նախնական մշակումի, բարդ փոխակերպումների, հոսքային տվյալների մշակման և փորձարարական վերլուծությունների դեպքում: Databricks միջավայրում հնարավոր է արագ կառուցել տվյալային pipeline-ներ, փորձարկել տարբեր ալգորիթմներ և կիրառել խորը ուսուցման մոդելներ: Դրա առավելությունն է արագ զարգացումը, կոդային միջավայրի հարմարավետությունը, համագործակցային notebook-ների աջակցությունը և ML նախագծերի ամբողջական կյանքի ցիկլի կառավարումը: Սակայն այն պահանջում է ավելի խորը տեխնիկական գիտելիքներ, Spark ճարտարապետության ըմբռնում և ծրագրավորման հմտություններ, ինչի պատճառով հիմնականում օգտագործվում է տեխնիկական թիմերի կողմից:

Synapse-ը, մյուս կողմից, ավելի կառավարվող և կենտրոնացված միջավայր է, որը հարմար է բիզնես վերլուծաբանների, տվյալների ճարտարապետների և հաշվետվությունների մշակմամբ զբաղվող թիմերի համար: Այն ուժեղ է կառուցվածքային տվյալների պահեստավորման և SQL հիմքով վերլուծությունների մեջ: Dedicated SQL pool-ը ապահովում է բարձր արտադրողականություն մեծ հաշվետվությունների և բազմաչափ հարցումների համար, ինչը կարևոր է ֆինանսական, կառավարչական և օպերացիոն վերլուծությունների իրականացման ժամանակ: Serverless հնարավորությունները թույլ են տալիս կատարել ճկուն հարցումներ տվյալների լճում պահվող ֆայլերի վրա՝ առանց մշտական ենթակառուցվածքային ծախսերի: Synapse-ը նաև տրամադրում է միասնական կառավարման միջավայր, որտեղ հնարավոր է վերահսկել տվյալների ներմուծումը, մշակումը և հարցումների կատարողականությունը: Սակայն Synapse-ի մեքենայական ուսուցման հնարավորությունները սովորաբար ավելի սահմանափակ են Databricks-ի համեմատ, և այն պակաս ճկուն է բարդ տվյալագիտական և հետազոտական նախագծերի համար:

Կարևոր տարբերություններից մեկը վերաբերում է աշխատանքային ոճին: Databricks-ը առավելապես կենտրոնացած է կոդային, ճկուն և փորձարարական միջավայրի վրա, որտեղ օգտատերը կարող է արագ փորձարկել գաղափարներ և փոխել տվյալների մշակման տրամաբանությունը: Synapse-ը ավելի շատ կառուցվածքային և արտադրական միջավայր է, որտեղ առաջնային են կայունությունը, կառավարելիությունը և կանխատեսելի կատարողականությունը:

Գործնականում այս երկու հարթակները հաճախ չեն դիտարկվում որպես մրցակիցներ: Շատ կազմակերպություններ կիրառում են համակցված կամ հիբրիդային մոտեցում, որտեղ Databricks-ը օգտագործվում է տվյալների նախնական մշակումի, բարդ վերափոխումների և մեքենայական ուսուցման մոդելների ստեղծման համար, իսկ Synapse-ը՝ տվյալների պահեստավորման, ագրեգացման և բիզնես վերլուծությունների իրականացման համար: Այս համադրությունը հնարավորություն է տալիս առանձնացնել տեխնիկական և վերլուծական շերտերը՝ պահպանելով համակարգի մասշտաբելիությունն ու արդյունավետությունը:

Այդպիսի ինտեգրված մոտեցումը թույլ է տալիս կառուցել ամբողջական տվյալային էկոհամակարգ, որտեղ տվյալները անցնում են ներմուծման, մաքրման, վերափոխման, պահեստավորման և վերլուծության փուլերով՝ առանց միջավայրերի միջև բարդ ինտեգրացիաների: Արդյունքում կազմակերպությունները ստանում են ճկուն, մասշտաբելի և արդյունավետ լուծում, որը կարող է միաժամանակ բավարարել ինչպես տվյալագիտության, այնպես էլ բիզնես վերլուծության պահանջները:

## 3.5: Գլխի ամփոփում

Azure-ը ապահովում է միասնական միջավայր, որտեղ տվյալների հավաքագրումը, փոխանցումը, պահպանումը և վերլուծությունը իրականացվում են նույն հարթակի վրա՝ բարձր արդյունավետության և ավտոմատացման մակարդակով: Այս մոդելը թույլ է տալիս կազմակերպություններին արագ կառուցել տեխնոլոգիական լուծումներ՝ առանց բարդ ենթակառուցվածք կազմակերպելու:

Տվյալների շարժի և կառավարման միասնական մոտեցումը ապահովվում է Azure Data Factory-ի միջոցով, որը կարգավորում է տվյալների հոսքերի ամբողջական ցիկլը՝ թույլ տալով կապել տարբեր բիզնես համակարգեր, ավտոմատացնել ժամանակացույցով գործընթացներ և ապահովել տվյալների մշտական թարմացում: Սա դարձնում է տվյալային ճարտարապետությունը կանխատեսելի, վերահսկվող և ճկուն:

Azure-ի տվյալային ծառայությունները համակցված աշխատելով ապահովում են տվյալների ճշգրտությունը, վերահսկվող շարժ, բռնկումների և սխալների ավտոմատ մշակելիություն, ինչպես նաև տվյալների հասանելիություն տարբեր թիմերի և գործիքների համար:

Վերլուծության և որոշումների արագացման համար Azure-ի վերլուծական ծառայությունները անմիջապես օգտագործում են Data Factory-ի միջոցով բեռնված և մշակված տվյալները, ինչը թույլ է տալիս ստեղծել իրական ժամանակի dashboard-ներ, կատարել պատմական տվյալների խորքային վերլուծություն, արագ պատրաստել մեքենայական ուսուցման մոդելներ և ընդունել բիզնես որոշումներ:

Բիզնեսի պահանջներին համապատասխան Azure-ը ապահովում է ճկունություն՝ թույլ տալով տարբեր աշխատանքաներ տեղափոխել ամպ, ընդլայնել կամ նվազեցնել ռեսուրսները ըստ պահանջի: Սա հատկապես կարևոր է այն կազմակերպությունների համար, որոնք աշխատում են մեծ տվյալների ծավալներով կամ ունեն փոփոխական բեռնվածություն:

# Գլուխ 4: ECL Գործակցի Հաշվումը

## 4.1: PD Գործակցի Հաշվումը, Մեքենայական Ուսուցումը և Լոգիստիկ Ռեգրեսիան

PD գործակիցը (Probability of Default) հանդիսանում է առանցքային ցուցանիշներից մեկը, որը արտացոլում է տվյալ վարկառուի կամ պարտապանի դեֆոլտի հավանականությունը որոշակի ժամանակահատվածում: Դեֆոլտ ասելով սովորաբար հասկանում են այն իրավիճակը, երբ վարկառուն չի կարողանում կատարել իր պարտավորությունները՝ համաձայն պայմանագրի, օրինակ՝ չի կատարում վճարումները սահմանված ժամկետներում: PD-ն արտահայտվում է հավանականության տեսքով և ցույց է տալիս, թե ինչ տոկոս հավանականությամբ է սպասվում, որ տվյալ սուբյեկտը կդառնա դեֆոլտային մեկ տարվա կամ այլ կանխորոշված հորիզոնի ընթացքում:

PD գործակիցը կարևոր դեր է խաղում վարկային պորտֆելի գնահատման, գնագոյացման և կապիտալի պահանջների հաշվարկման գործընթացներում: Այն օգտագործվում է ինչպես առանձին վարկերի ռիսկայնությունը գնահատելու, այնպես էլ ամբողջ պորտֆելի ռիսկային կառուցվածքը հասկանալու համար: Որքան բարձր է PD-ն, այնքան բարձր է տվյալ վարկառուի ռիսկայնությունը և, համապատասխանաբար, բանկը կարող է կիրառել ավելի խիստ պայմաններ կամ բարձր տոկոսադրույք՝ ռիսկը փոխհատուցելու նպատակով: PD-ն նաև հանդիսանում է Expected Credit Loss մոտեցման կարևոր բաղադրիչներից մեկը, քանի որ սպասվող վարկային կորուստների գնահատման համար անհրաժեշտ է իմանալ դեֆոլտի հավանականությունը:

Ժամանակակից ֆինանսական կազմակերպություններում PD-ի գնահատումը հաճախ իրականացվում է մեքենայական ուսուցման մոդելների միջոցով: Մեքենայական ուսուցումը հնարավորություն է տալիս մեծ ծավալի պատմական տվյալների հիման վրա հայտնաբերել օրինաչափություններ և կապեր, որոնք կարող են կանխատեսել վարկառուի վարքագիծը: Տվյալների շարքում կարող են ներառվել ֆինանսական ցուցանիշներ, եկամուտներ, ծախսեր, վարկային պատմություն, սոցիալ-դեմոգրաֆիկ հատկանիշներ և այլ գործոններ: Մոդելները սովորում են պատմական դեպքերից՝ տարբերակելով դեֆոլտային և ոչ դեֆոլտային հաճախորդներին, և արդյունքում յուրաքանչյուր նոր հաճախորդի համար հաշվարկում են դեֆոլտի հավանականություն:

Մեքենայական ուսուցման ոլորտում կիրառվում են ինչպես դասական վիճակագրական մեթոդներ, այնպես էլ ավելի բարդ ալգորիթմներ, օրինակ՝ որոշման ծառեր, անտառային մեթոդներ, նեյրոնային ցանցեր և գրաֆային մոդելներ: Այս մոդելների առավելությունն այն է, որ կարողանում են հաշվի առնել ոչ գծային կապեր և փոխազդեցություններ տարբեր հատկանիշների միջև: Սակայն ֆինանսական ոլորտում կարևոր է նաև մոդելի թափանցիկությունն ու բացատրելիությունը, քանի որ

կարգավորող մարմինները պահանջում են հասկանալ, թե ինչու է մոդելը տվյալ հաճախորդին գնահատել բարձր կամ ցածր ռիսկային։

PD-ի գնահատման համար առավել լայնորեն կիրառվող մեթոդներից մեկը լոգիստիկ ռեգրեսիան է։ Լոգիստիկ ռեգրեսիան դասակարգման մոդել է, որը նախատեսված է երկու հնարավոր արդյունք ունեցող խնդիրների համար, օրինակ՝ դեֆոլտ և ոչ դեֆոլտ։ Այն գնահատում է, թե ինչպես են տարբեր անկախ փոփոխականները ազդում դեֆոլտի հավանականության վրա։ Մոդելը յուրաքանչյուր հաճախորդի համար վերադարձնում է հավանականություն, որը գտնվում է զրոյից մեկ միջակայքում, և այդ արժեքը մեկնաբանվում է որպես PD։

Լոգիստիկ ռեգրեսիայի կարևոր առավելություններից մեկը դրա պարզությունն ու մեկնաբանելիությունն է։ Յուրաքանչյուր փոփոխականի ազդեցությունը կարելի է առանձին գնահատել և հասկանալ՝ արդյոք տվյալ գործոնը մեծացնում է, թե նվազեցնում դեֆոլտի հավանականությունը։ Սա հատկապես կարևոր է բանկային միջավայրում, որտեղ անհրաժեշտ է հիմնավորել վարկային որոշումները։ Բացի այդ, լոգիստիկ ռեգրեսիան համեմատաբար կայուն է, արագ է ուսուցանվում և լավ է աշխատում, երբ տվյալների միջև հարաբերությունները մոտավորապես գծային են լոգ-հավանականության տարածքում։

Միևնույն ժամանակ, եթե տվյալներում առկա են բարդ, ոչ գծային կախվածություններ, լոգիստիկ ռեգրեսիան կարող է զիջել ավելի բարդ մեքենայական ուսուցման մեթոդներին։ Այդ պատճառով հաճախ կիրառվում է համակցված մոտեցում, երբ լոգիստիկ ռեգրեսիան օգտագործվում է որպես բազային մոդել կամ բենչմարկ, իսկ ավելի առաջադեմ ալգորիթմները՝ որպես համեմատական կամ լրացուցիչ գործիք։

Ընդհանուր առմամբ, PD գործակիցը վարկային ռիսկի կառավարման հիմնարար ցուցանիշ է, որի ճշգրիտ գնահատումը կարևոր է ինչպես ֆինանսական կայունության, այնպես էլ շահութաբերության տեսանկյունից։ Մեքենայական ուսուցման մեթոդները, հատկապես լոգիստիկ ռեգրեսիան, ապահովում են արդյունավետ և գործնական գործիքակազմ՝ դեֆոլտի հավանականության գնահատման և ռիսկերի կանխատեսման համար ժամանակակից ֆինանսական համակարգում։

Լոգիստիկ ռեգրեսիան հիմնվում է լոգիստիկ (կամ սիգմոիդային) ֆունկցիայի վրա՝ որը հանդիսանում է ակտիվացման ֆունկցիա, և նախատեսված է դիտարկվող օբյեկտի որևէ դասին պատկանելու հավանականությունը մոդելավորելու համար։ Այդ ֆունկցիան ունի հետևյալ տեսքը.

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

որտեղ x-ը մուտքային փոփոխականների գծային կոմբինացիա է։ Սիգմոիդային ֆունկցիան ընդունում է ցանկացած իրական թիվ, բայց այն փոխակերպում է 0–1

տիրույթի արժեքների, ինչը հարմար է արդյունքը հավանականության տեսանկյունից մեկնաբանելու համար: Սիգմոիդային ֆունկցիան բերված է գծագիր 1-ում:

Գծագիր 4.1:

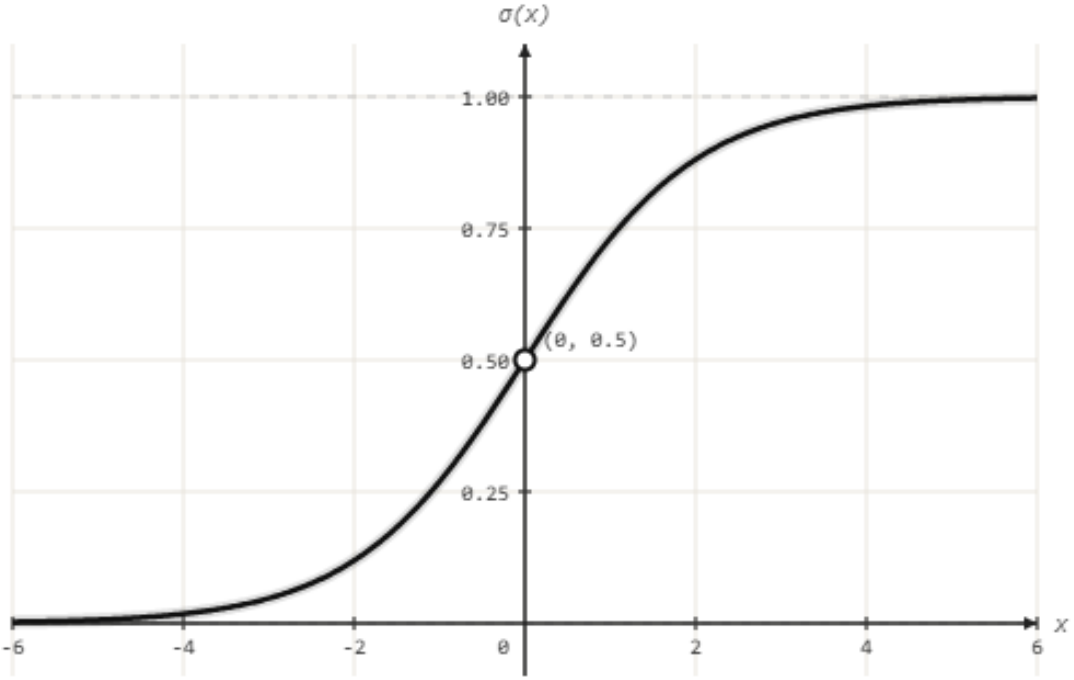


Դիպլոմայինի շրջանակներում նաև ուսումնասիրվել և թեստավորվել է Հիպերբոլիկ տանգենս ֆունկցիան, որն ունի հետևյալ բանաձևը՝

$$tahn(\mathrm{x}) = \frac{\mathrm{e}^{\mathrm{x}} - \mathrm{e}^{-\mathrm{x}}}{\mathrm{e}^{\mathrm{x}} + \mathrm{e}^{-\mathrm{x}}}$$

Սակայն նրա արժեքների տիրույթը ընկած է (-1;1) միջակայքում, և որպեսի հնարավոր լինի այս ֆունկցիայով ստանանք հավանականություն, կսահմանենք հետևյալ ֆունկցիան՝

$$new_tahn(\mathrm{x}) = (tahn(\mathrm{x}) + 1)/2$$

Որն ունի հետևյալ գրաֆիկը (Գծագիր 4.2):

Գծագիր 4.2:

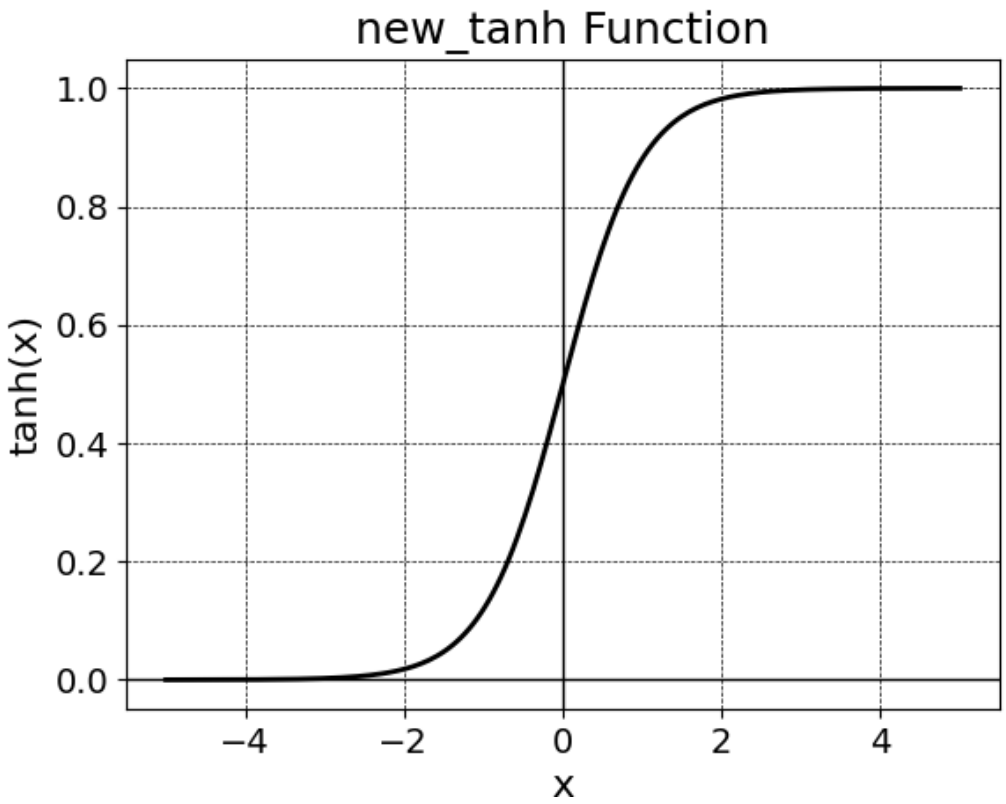


Սակայն փորձարկման արդյունքներից հետևում է, որ սիգմոիդ ֆունկցիան ավելի արդյունավետ է (Գծագիր 3):

Գծագիր 3:

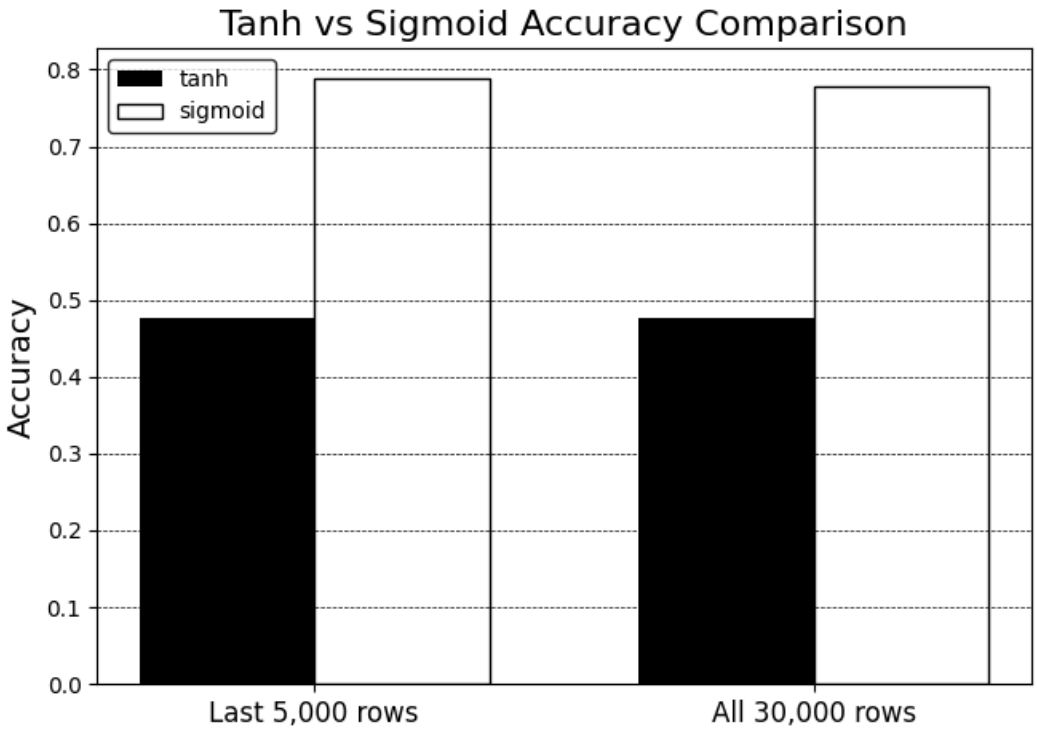

Բինար դասակարգման դեպքում թիրախային փոփոխականը y ընդունում է 0 կամ 1 արժեքներ, և խնդիրն է կանխատեսել հավանականությունը՝

$$P(y = 1|X)$$

որտեղ X-ը հատկանիշների վեկտորն է:

Լոգիստիկ ռեգրեսիայի մոդելը՝

$$P(y = 1|X) =$$

որտեղ $\beta_0$-ը ազատ անդամն է, իսկ $\beta_1 \ldots \beta_n$-ը՝ մոդելի պարամետրերը, որոնք որոշում են անկախ փոփոխականների ներդրումը արդյունքի կանխատեսման գործում:

Հավանականության առավելագույնացում (Maximum Likelihood Estimation) ՝լոգիստիկ ռեգրեսիայի պարամետրերը գնահատվում են առավելագույն հավանականության մեթոդով: Ընտրվում են այնպիսի β արժեքներ, որոնք առավելագույնի են հասցնում դիտարկված տվյալների ստացման հավանականությունը:

Հավանականության ֆունկցիան ներկայացվում է այսպես՝

$$L(\beta) = \prod_{i=1}^{m} P(y_i|X_i;\beta)^{y_i}(1 - P(y_i|X_i;\beta))^{1-y_i}$$

որտեղ m-ը դիտարկումների քանակն է:

Հաճախ օգտագործում են նաև լոգ-հավանականությունը՝ հաշվարկները պարզեցնելու համար.

$$LogL(\beta) = \sum_{i=1}^{m} [y_i logP(y_i|X_i;\beta) + (1 - y_i)log(1 - P(y_i|X_i;\beta))]$$

Լոգ-հավանականության առավելագույնացումը թույլ է տալիս գտնել β-ի օպտիմալ արժեքները՝ օգտագործելով թվային մեթոդներ, օրինակ՝ գրադիենտային իջեցում կամ Նյուտոն–Ռաֆսոնի մեթոդ:

Լոգիստիկ ռեգրեսիայի համակցությունների մեկնաբանություն՝ գծային ռեգրեսիայի դեպքում համակցությունները ցույց են տալիս, թե որքանով է փոխվում ելքային արժեքը անկախ փոփոխականի մեկ միավորով փոփոխման դեպքում: Սակայն լոգիստիկ ռեգրեսիայում $\beta_i$-ի մեկնաբանությունն այլ է:

Լոգիստիկ ռեգրեսիայի համակցությունները ցույց են տալիս, թե ինչպես է փոփոխականը ազդում շանսերի լոգարիթմի վրա.

$$log\left(\frac{P(y=1|X)}{1-P(y=1|X)}\right)=\beta_0+\beta_1x_1+\beta_2x_2+\cdots+\beta_nx_n$$

Այսպիսով, $\beta_i$-ն ցույց է տալիս՝ որքանով է փոխվում շանսերի լոգարիթմը $x_i$-ի մեկ միավորով փոփոխման դեպքում: Սա հնարավորություն է տալիս գնահատել հատկանիշների կարևորությունը մոդելի մեջ:

Մոդելի որակի գնահատում՝ քանի որ լոգիստիկ ռեգրեսիան կանխատեսում է հավանականություն, այլ ոչ թե կոնկրետ արժեք, դրա որակի գնահատման համար օգտագործվում են հատուկ մեթրիկաներ.

Խառնումների մատրիցա (Confusion Matrix) - ցույց է տալիս ճիշտ և սխալ կանխատեսումների քանակը:

$$\text{ճշտություն } (Accuracy): \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{Լրիվություն } (Recall): \frac{TP}{TP+TN}$$

$$\text{ճշգրտություն } (Precision): \frac{TP}{TP+FP}$$

$$F_1-\text{մետրիկա}: \frac{2\times Precision\times Recall}{Precision+Recall}$$

ROC կոր և AUC - մոդելի արդյունավետության գնահատում տարբեր շեմերի դեպքում:

Բազմադասային լոգիստիկ ռեգրեսիա՝ լոգիստիկ ռեգրեսիան կարող է ընդլայնվել բազմադասային խնդրի համար: Ամենատարածված մոտեցումները հետևյալն են՝ One-vs-Rest (OvR) - յուրաքանչյուր դասի համար կառուցվում է առանձին դասակարգիչ, One-vs-One (OvO) - դասակարգիչ ամեն զույգ դասերի համար, ապա ընտրություն՝ քվեարկությամբ:

Այս մոտեցումը օգտակար է, օրինակ, պատկերների կատեգորիաների կամ ձեռագիր թվանշանների ճանաչման խնդիրներում:

Լոգիստիկ ռեգրեսիայի կիրառումը՝ լոգիստիկ ռեգրեսիան լայնորեն կիրառվում է ինչպես բինար, այնպես էլ բազմադասային խնդիրներում, բժշկություն - հիվանդության առկայության հավանականության գնահատում, մարկետինգ հաճախորդի արձագանքի հավանականության կանխատեսում, ֆինանսներ - վարկի չվճարման կամ այլ ռիսկային իրադարձությունների կանխատեսում, հասարակագիտություն - սոցիալական խմբերին կամ վարքագծային կատեգորիաներին պատկանելու հավանականություն:

Լոգիստիկ ռեգրեսիայի սահմանափակումները՝ չնայած իր լայն կիրառությանը՝ լոգիստիկ ռեգրեսիան ունի մի շարք սահմանափակումներ՝ գծայնության ենթադրություն - ենթադրում է գծային կապ անկախ փոփոխականների և շանսերի լոգարիթմի միջև, ինչը միշտ չէ, որ համապատասխանում է իրականությանը, զգայունություն արտախմբային արժեքների նկատմամբ - տվյալների արտառոց կետերը կարող են էապես խաթարել արդյունքները, բազմակոլլինեարության խնդիրներ - բարձրորեն փոխկապակցված հատկանիշները հանգեցնում են անկայուն և դժվար մեկնաբանվող հակցությունների։

## 4.2: LGD Գործակցի Հաշվումը

Կորուստը չվճարման դեպքում (Loss Given Default – LGD): LGD ցուցանիշը ցույց է տալիս այն կորուստների մասնաբաժինը, որը ֆինանսական հաստատությունը կրում է դեֆոլտի դեպքում: Այլ կերպ ասած՝ LGD-ն արտացոլում է դեֆոլտի պայմաններում կորցվող գումարի մասնաբաժինը ընդհանուր պարտավորությունից: Եթե դեֆոլտը տեղի է ունեցել, LGD-ն գնահատում է, թե տվյալ վարկից որքան մասն է հնարավոր վերականգնել և որքանն է փաստացի կորուստ դառնում բանկի կամ վարկատուի համար:

LGD-ի էությունը կապված է վերականգնման գործընթացի հետ: Երբ վարկառուն չի կատարում իր պարտավորությունները, ֆինանսական կազմակերպությունը սկսում է վերականգնման քայլեր՝ ապահովագրական մեխանիզմների, գրավի իրացման, երաշխավորների ներգրավման կամ իրավական գործընթացների միջոցով: Սակայն շատ դեպքերում ամբողջ պարտքը հնարավոր չէ վերադարձնել: LGD-ն հենց այդ բացը բնութագրող ցուցանիշն է: Այն ցույց է տալիս, թե դեֆոլտից հետո մնացած պարտքի որ մասն է վերջնականապես կորուստ դառնում՝ հաշվի առնելով վերականգնված գումարները:

LGD-ն մեծապես կախված է վարկի տեսակից և ապահովվածության մակարդակից: Օրինակ՝ գրավով ապահովված վարկերի դեպքում կորուստները սովորաբար ավելի ցածր են, քանի որ բանկը կարող է իրացնել գրավը և վերադարձնել պարտքի մի մասը: Ի տարբերություն դրա, չապահովված սպառողական վարկերի դեպքում LGD-ն սովորաբար ավելի բարձր է, քանի որ վերականգնման հնարավորությունները սահմանափակ են: Հետևաբար, նույն վարկառուի դեպքում անգամ տարբեր վարկային պրոդուկտների համար LGD-ն կարող է զգալիորեն տարբերվել:

LGD-ի վրա ազդում են նաև տնտեսական պայմանները: Տնտեսական անկման ժամանակաշրջաններում ակտիվների շուկայական արժեքը կարող է նվազել, ինչի հետևանքով գրավի իրացումից ստացվող գումարները պակասում են: Այդպիսի պայմաններում LGD-ն հակված է աճելու: Ընդհակառակը, տնտեսական աճի պայմաններում վերականգնման մակարդակները կարող են լինել ավելի բարձր, և LGD-ն՝ ավելի ցածր: Այս պատճառով ֆինանսական հաստատությունները հաճախ գնահատում են LGD-ն ոչ միայն միջին պատմական մակարդակով, այլ նաև սթրեսային սցենարներով:

LGD-ն կարևոր բաղադրիչ է սպասվող վարկային կորուստների գնահատման գործընթացում: Դեֆոլտի հավանականությունը միայն ցույց է տալիս, թե որքան հավանական է պարտավորության չկատարումը, սակայն չի ասում, թե որքան մեծ կլինի իրական ֆինանսական վնասը: LGD-ն լրացնում է այդ բացը՝ թույլ տալով հաշվարկել, թե դեֆոլտի դեպքում որքան կորուստ է սպասվում: Այսպիսով, այն հանդիսանում է ռիսկի քանակականացման հիմնական գործիքներից մեկը և անմիջական ազդեցություն ունի կապիտալի պահանջների, ռեզերվների ձևավորման և գնագոյացման քաղաքականության վրա:

Վարկային պորտֆելի կառավարման տեսանկյունից LGD-ն օգտագործվում է ռիսկերի տարբերակման նպատակով: Բանկերը կարող են ունենալ երկու վարկային պորտֆել՝ նույն PD մակարդակով, սակայն տարբեր LGD ցուցանիշներով: Այդ դեպքում պորտֆելը, որի LGD-ն բարձր է, կհամարվի ավելի ռիսկային, քանի որ դեֆոլտի դեպքում սպասվող կորուստները կլինեն ավելի մեծ: Հետևաբար, ռիսկի գնահատման ժամանակ անհրաժեշտ է համադրել ինչպես դեֆոլտի հավանականությունը, այնպես էլ դեֆոլտի պայմաններում կորուստների չափը:

LGD-ի գնահատումը բարդ գործընթաց է, քանի որ այն կախված է բազմաթիվ գործոններից՝ իրավական միջավայրից, սնանկության ընթացակարգերի արդյունավետությունից, գրավի իրացման ժամկետներից, ծախսերից և նույնիսկ տարածաշրջանային առանձնահատկություններից: Օրինակ՝ երկրներում, որտեղ իրավական համակարգը արագ և արդյունավետ է, վերականգնման մակարդակները կարող են լինել ավելի բարձր, հետևաբար LGD-ն՝ ավելի ցածր: Իսկ այն երկրներում, որտեղ դատական գործընթացները երկարատև են և ծախսատար, կորուստները կարող են մեծանալ:

Կարևոր է նաև ժամանակային գործոնը: Դեֆոլտից հետո վերականգնումը հաճախ տեղի է ունենում երկար ժամանակահատվածում, և այդ ընթացքում գումարների արժեքը կարող է փոփոխվել: Բանկերը հաշվի են առնում ոչ միայն վերականգնված գումարի չափը, այլ նաև վերականգնման ժամկետը և ծախսերը: Վերականգնման գործընթացում կարող են առաջանալ իրավաբանական, վարչական և գործառնական ծախսեր, որոնք ևս նվազեցնում են վերջնական վերականգնվող գումարը և մեծացնում իրական կորուստը:

Ժամանակակից վարկային ռիսկի կառավարման համակարգերում LGD-ն գնահատվում է պատմական տվյալների հիման վրա՝ վերլուծելով նախորդ դեֆոլտային դեպքերը և դրանց վերականգնման արդյունքները: Որոշ դեպքերում կիրառվում են նաև վիճակագրական և մեքենայական ուսուցման մեթոդներ՝ վերականգնման մակարդակները կանխատեսելու համար՝ կախված վարկառուի հատկանիշներից, վարկի կառուցվածքից և տնտեսական միջավայրից: Սակայն անկախ կիրառվող մեթոդից, LGD-ի հիմնական իմաստը մնում է նույնը՝ այն ցույց է տալիս դեֆոլտի պայմաններում կրած ֆինանսական վնասի չափը:

Ընդհանուր առմամբ, LGD գործակիցը հանդիսանում է վարկային ռիսկի գնահատման հիմնարար տարրերից մեկը: Այն ապահովում է պատկերացում ոչ միայն այն մասին, թե արդյոք վարկառուն կարող է չկատարել իր պարտավորությունները, այլ նաև այն մասին, թե այդ իրավիճակում որքան մեծ կլինի իրական կորուստը: Առանց LGD-ի գնահատման հնարավոր չէ ամբողջական պատկերացում կազմել վարկային ռիսկի մասին, քանի որ ռիսկը ձևավորվում է ինչպես դեֆոլտի հավանականությամբ, այնպես էլ դեֆոլտի պայմաններում կորուստների ծավալով:

Ձեր տրամադրած տվյալների հիման վրա հնարավոր է կառուցել ամբողջական, ինքնաբավ մաթեմատիկական համակարգ, որը չի պահանջում արտաքին

փոփոխականներ՝ բացառությամբ գլոբալ գնահատվող գործակիցների և դիսկոնտավորման տոկոսադրույքի։ LGD-ի բանաձը.

$$LGD = 1 - Recovery\ Rate$$

որտեղ Recovery Rate-ը այն գումարի մասնաբաժինն է, որը հնարավոր է վերականգնել դեֆոլտից հետո (գրավի իրացում, ապահովագրություն, դատական գործընթացներ կամ վարկառուի հետ համաձայնագրով վերադարձ)։

LGD-ի արժեքը կախված է մի շարք գործոններից.

- Վարկի տեսակից (սպառողական վարկերի LGD-ն սովորաբար ավելի բարձր է, քան հիփոթեքայինի),
- Ապահովագրության առկայությունից և որակից (գրավի արժեք, իրացվելիություն և գնահատում),
- Իրավական գործընթացների արդյունավետությունից և տևողությունից (Հայաստանում դատական գործընթացները կարող են տևել 1–3 տարի),
- Տնտեսական պայմաններից (ճգնաժամի ժամանակ LGD-ն աճում է գրավի արժեքի անկման պատճառով)։

Հայաստանում LGD-ի միջին արժեքը սպառողական վարկերի համար կազմում է մոտ 45–55%, իսկ գրավով ապահովված վարկերի համար՝ 30–40%։

## 4.3: EAD Գործակցի Հաշվումը և ECL Գործակցի Բանաձևը

EAD գործակիցը (Exposure at Default) վարկային ռիսկի կառավարման կարևորագույն ցուցանիշներից մեկն է, որը ցույց է տալիս, թե դեֆոլտի պահին ինչ չափի պարտավորություն է առկա վարկատուի նկատմամբ։ Այլ կերպ ասած՝ EAD-ն արտացոլում է այն ընդհանուր գումարը, որի նկատմամբ ֆինանսական կազմակերպությունը կրում է ռիսկ այն պահին, երբ վարկառուն դառնում է դեֆոլտային։ Եթե PD-ն ցույց է տալիս դեֆոլտի հավանականությունը, իսկ LGD-ն՝ դեֆոլտի դեպքում կորուստների մասնաբաժինը, ապա EAD-ն սահմանում է այն բազային գումարը, որի վրա այդ կորուստը կիրառվում է։

EAD-ի էությունը կայանում է նրանում, որ վարկային ռիսկը չի սահմանափակվում միայն տվյալ պահին հաշվեկշռում առկա մնացորդով։ Շատ վարկային գործիքներ ունեն չօգտագործված լիմիտներ կամ պայմանական պարտավորություններ, որոնք կարող են ակտիվացվել մինչև դեֆոլտի պահը։ Օրինակ՝ վարկային քարտերի, օվերդրաֆտների կամ վերականգնվող վարկային գծերի դեպքում հաճախորդը կարող է ունենալ հաստատված, բայց դեռ չօգտագործված սահմանաչափ։ Դեֆոլտին նախորդող փուլում հաճախորդը կարող է ամբողջությամբ կամ մասնակիորեն օգտագործել այդ սահմանաչափը, ինչի հետևանքով իրական ռիսկային ազդեցությունը մեծանում է։ EAD-ն հենց այս ամբողջ ազդեցությունն է ներառում իր մեջ։

Տարբեր վարկային պրոդուկտների դեպքում EAD-ի վարքագիծը տարբեր է։ Սպառողական կամ հիփոթեքային դասական վարկերի դեպքում EAD-ն սովորաբար մոտ է դեֆոլտի պահին առկա հիմնական պարտքի մնացորդին, քանի որ այդպիսի վարկերում լրացուցիչ չօգտագործված լիմիտներ սովորաբար չկան։ Սակայն վարկային գծերի, կորպորատիվ ֆինանսավորման պայմանական պարտավորությունների, բանկային երաշխիքների կամ ակրեդիտիվների դեպքում EAD-ն կարող է զգալիորեն տարբերվել հաշվեկշռային մնացորդից։ Այս դեպքում անհրաժեշտ է գնահատել, թե դեֆոլտից առաջ ինչ չափով կարող է աճել պարտավորությունը։

EAD-ի գնահատումը կարևոր է, որովհետև այն անմիջական ազդեցություն ունի ռիսկի ընդհանուր չափի վրա։ Նույն PD և LGD մակարդակների դեպքում ավելի բարձր EAD ունեցող վարկը կնշանակի ավելի մեծ ակնկալվող կորուստ։ Այդ պատճառով ֆինանսական կազմակերպությունները մեծ ուշադրություն են դարձնում ոչ միայն վարկառուի վարքագծին, այլ նաև վարկային պրոդուկտի կառուցվածքին և պայմաններին։ Վարկային քաղաքականության ձևավորման ժամանակ սահմանվում են լիմիտներ և պայմաններ, որոնք նպատակ ունեն վերահսկելու հնարավոր ռիսկային ազդեցությունը դեֆոլտի պահին։

EAD-ի վրա ազդում են ինչպես պայմանագրային, այնպես էլ վարքագծային գործոններ։ Պայմանագրային գործոնների շարքում են վարկի տեսակը, մարման գրաֆիկը, տոկոսադրույքը, լիմիտների առկայությունը և դրանց փոփոխման

մեխանիզմները: Վարքագծային գործոնները կապված են հաճախորդի ֆինանսական վարքագծի հետ՝ օրինակ՝ արդյոք հաճախորդը հակված է ամբողջությամբ օգտագործել իր վարկային սահմանաչափը ֆինանսական դժվարությունների ժամանակ: Պատմական տվյալների վերլուծությունը ցույց է տալիս, որ որոշ հաճախորդներ դեֆոլտին նախորդող ժամանակահատվածում արագորեն ավելացնում են իրենց պարտավորությունները, ինչը մեծացնում է բանկի ռիսկային ազդեցությունը:

Կորպորատիվ հատվածում EAD-ի գնահատումը կարող է ավելի բարդ լինել, քանի որ ընկերությունները հաճախ ունենում են բազմատեսակ ֆինանսական գործիքներ՝ վարկային գծեր, երաշխիքներ, դերիատիվներ և այլ պայմանական պարտավորություններ: Այդպիսի դեպքերում անհրաժեշտ է համապարփակ գնահատել բոլոր հնարավոր պարտավորությունները, որոնք կարող են իրական դառնալ դեֆոլտի պահին: Սա պահանջում է խորքային վերլուծություն և հաճախ կիրառվում են վիճակագրական կամ սցենարային մեթոդներ՝ տարբեր հնարավոր զարգացումները գնահատելու համար:

Տնտեսական միջավայրն ևս կարող է ազդել EAD-ի վրա: Տնտեսական անկման պայմաններում ընկերությունները կարող են ավելի ակտիվորեն օգտագործել իրենց վարկային գծերը՝ ֆինանսական ճնշումները հաղթահարելու նպատակով: Նման իրավիճակներում դեֆոլտի պահին պարտավորության չափը կարող է լինել ավելի բարձր, քան կայուն տնտեսական պայմաններում: Հետևաբար, ռիսկի կառավարման ժամանակ անհրաժեշտ է հաշվի առնել ոչ միայն պատմական միջին ցուցանիշները, այլ նաև հնարավոր սթրեսային սցենարները:

EAD-ն կարևոր դեր է խաղում նաև կապիտալի պահանջների և ռեզերվների հաշվարկման գործընթացում: Քանի որ այն սահմանում է ռիսկի տակ գտնվող գումարի չափը, դրա փոփոխությունը կարող է զգալիորեն ազդել ֆինանսական հաստատության հաշվեկշռի վրա: Ավելի բարձր EAD-ն նշանակում է ավելի մեծ ռիսկային ակտիվներ և, համապատասխանաբար, ավելի բարձր կապիտալի պահանջներ կարգավորող մարմինների պահանջների համաձայն: Այդ պատճառով EAD-ի ճշգրիտ գնահատումը ռազմավարական նշանակություն ունի ֆինանսական կայունության տեսանկյունից:

Ժամանակակից վարկային ռիսկի կառավարման համակարգերում EAD-ի գնահատման համար օգտագործվում են ինչպես պատմական տվյալների վերլուծություն, այնպես էլ վարքագծային մոդելներ: Վերլուծվում են նախկին դեֆոլտային դեպքերը՝ հասկանալու համար, թե ինչ չափով է աճել պարտավորությունը դեֆոլտից առաջ: Այդ տեղեկատվությունը կիրառվում է ապագա ռիսկերի կանխատեսման համար: Որոշ դեպքերում կիրառվում են մեքենայական ուսուցման մեթոդներ՝ հաճախորդների վարքագծի օրինաչափությունները բացահայտելու նպատակով:

Ընդհանուր առմամբ EAD գործակիցը ներկայացնում է դեֆոլտի պահին առկա ընդհանուր ռիսկային ազդեցությունը և հանդիսանում է վարկային ռիսկի գնահատման հիմնարար տարրերից մեկը: Այն լրացնում է PD և LGD ցուցանիշներին՝ ապահովելով ամբողջական պատկերացում այն մասին, թե որքան գումար է գտնվում ռիսկի տակ և ինչ

չափի կորուստ կարող է կրել ֆինանսական կազմակերպությունը: Առանց EAD-ի գնահատման հնարավոր չէ իրական և ամբողջական կերպով հասկանալ վարկային ռիսկի ծավալը և արդյունավետորեն կառավարել ֆինանսական հաստատության պորտֆելը: EAD գործակցի բանաձևը.

Վարկային քարտերի և վարկային գծերի դեպքում EAD-ը հաշվարկվում է հետևյալ բանաձևով.

$$\text{EAD} = \text{Outstanding Balance} + (\text{Credit Limit x CCF})$$

որտեղ.

- Outstanding Balance - ընթացիկ պարտք,
- Credit Limit - վարկային սահմանաչափ,
- CCF (Credit Conversion Factor) - վարկային փոխակերպման գործակից (սովորաբար 0.5-0.75, կախված վարկի տեսակից և հաճախորդի վարքագծից):
- Գործնական նշանակությունը.

EAD-ի ճշգրիտ գնահատումը հատկապես կարևոր է revolving վարկերի (վարկային քարտեր, overdraft) դեպքում, որտեղ հաճախորդը կարող է օգտագործել լրացուցիչ գումարներ մինչև դեֆոլտը: Հայաստանի բանկերը (VTB Armenia, Converse Bank) այս պարամետրը հաշվարկում են պատմական տվյալների և վարքագծային մոդելների հիման վրա:

Այսպիսով, ECL հաշվարկը հանդիսանում է ինտեգրված վիճակագրական և ֆինանսական մոդել, որտեղ լոգիստիկ ռեգրեսիան գնահատում է դեֆոլտի հավանականությունը, գծային կամ ոչ գծային ռեգրեսիան գնահատում է պարտավորության չափը և կորուստի մակարդակը, իսկ վերջնական արդյունքը ներկայացնում է սպասվող կորուստը: Արդյունքում կարող ենք արտածել ECL գործակցի բանաձևը.

$$ECL = PD \times EAD \times LGD$$

Եթե հաշվի ենք առնում ժամանակային դիսկոնտավորումը, ապա բազմափուլ մոդելի դեպքում ընդհանուր ձևը կլինի

$$ECL = \sum_{t=0}^{T} PD_t \times EAD_t \times LGD_t$$

որտեղ $DF_t = \frac{1}{(1+\mathrm{r})^t}$ դիսկոնտավորման գործակիցն է, r-ը՝ արդյունավետ տոկոսադրույքը, իսկ T-ը՝ դիտարկվող ժամանակահատվածը:

# Գլուխ 5: ECL ԳՈՐԾԱԿՑԻ ՀԱՇՎՄԱՆ ԱԼԳՈՐԻԹՄԸ MICROSOFT AZURE ԱՄՊԱՅԻՆ ՏԵԽՆՈԼՈԳԻԱՆԵՐԻ ՄԻՋՈՑՈՎ

ECL գործակցի հաշվարկման ալգորիթմը սկսվում է Microsoft Azure ենթակառուցվածքի հիման վրա կառուցված տվյալների մշակման համակարգից, որը ներկայացված է որպես ամբողջական pipeline: Այս համակարգը միավորում է տվյալների պահեստավորումը, մշակումը և վերլուծությունը մեկ միասնական հոսքի մեջ՝ ապահովելով գործընթացի ավտոմատացում, վերահսկելիություն և կրկնելիություն: Ամբողջ ճարտարապետությունը կառուցված է Microsoft Azure հարթակի վրա, որը տրամադրում է հաշվարկային և պահեստային հիմնական ռեսուրսները:

Համակարգի կենտրոնական բաղադրիչը տվյալների բազան է, որը իրականացված է Azure SQL Database ծառայության միջոցով: Այս բազան հանդիսանում է ամբողջ համակարգի տվյալների կառավարման հիմքը և ապահովում է ինչպես տվյալների երկարաժամկետ պահպանումը, այնպես էլ դրանց արդյունավետ հասանելիությունը տարբեր փուլերից: Բազայում պահվում են ինչպես սկզբնական տվյալները, այնպես էլ pipeline-ի ընթացքում ստեղծվող միջանկյալ և վերջնական արդյունքները: Տվյալները կազմակերպված են մի քանի առանձին աղյուսակների տեսքով՝ հիմնական տվյալների աղյուսակ, ուսուցման տվյալների աղյուսակ, թեստավորման տվյալների աղյուսակ, մոդելի պարամետրերի աղյուսակ և արդյունքների պահպանման աղյուսակ: Այս կառուցվածքը թույլ է տալիս յուրաքանչյուր փուլին աշխատել հստակ սահմանված տվյալների հետ՝ ապահովելով համակարգի մոդուլայնությունը և տվյալների ամբողջականությունը:

Տվյալների բազայի աշխատանքի հիմքում գտնվում է SQL լեզուն (Structured Query Language), որը հանդիսանում է հարաբերական տվյալների բազաների կառավարման հիմնական գործիքը: SQL-ը հնարավորություն է տալիս ոչ միայն պահել և ստանալ տվյալներ, այլ նաև իրականացնել դրանց վրա տարբեր գործողություններ՝ ֆիլտրում, դասավորում, խմբավորում, ագրեգացիա և վերափոխում, օգտագործելով SSMS (SQL Server Management Studio) ծրագիրը (նկար 5.1): Այս հատկությունների շնորհիվ հնարավոր է իրականացնել տվյալների նախապատրաստման մի մասը անմիջապես բազայի մակարդակում՝ առանց հավելյալ հաշվարկային ծանրաբեռնվածության Python միջավայրում:

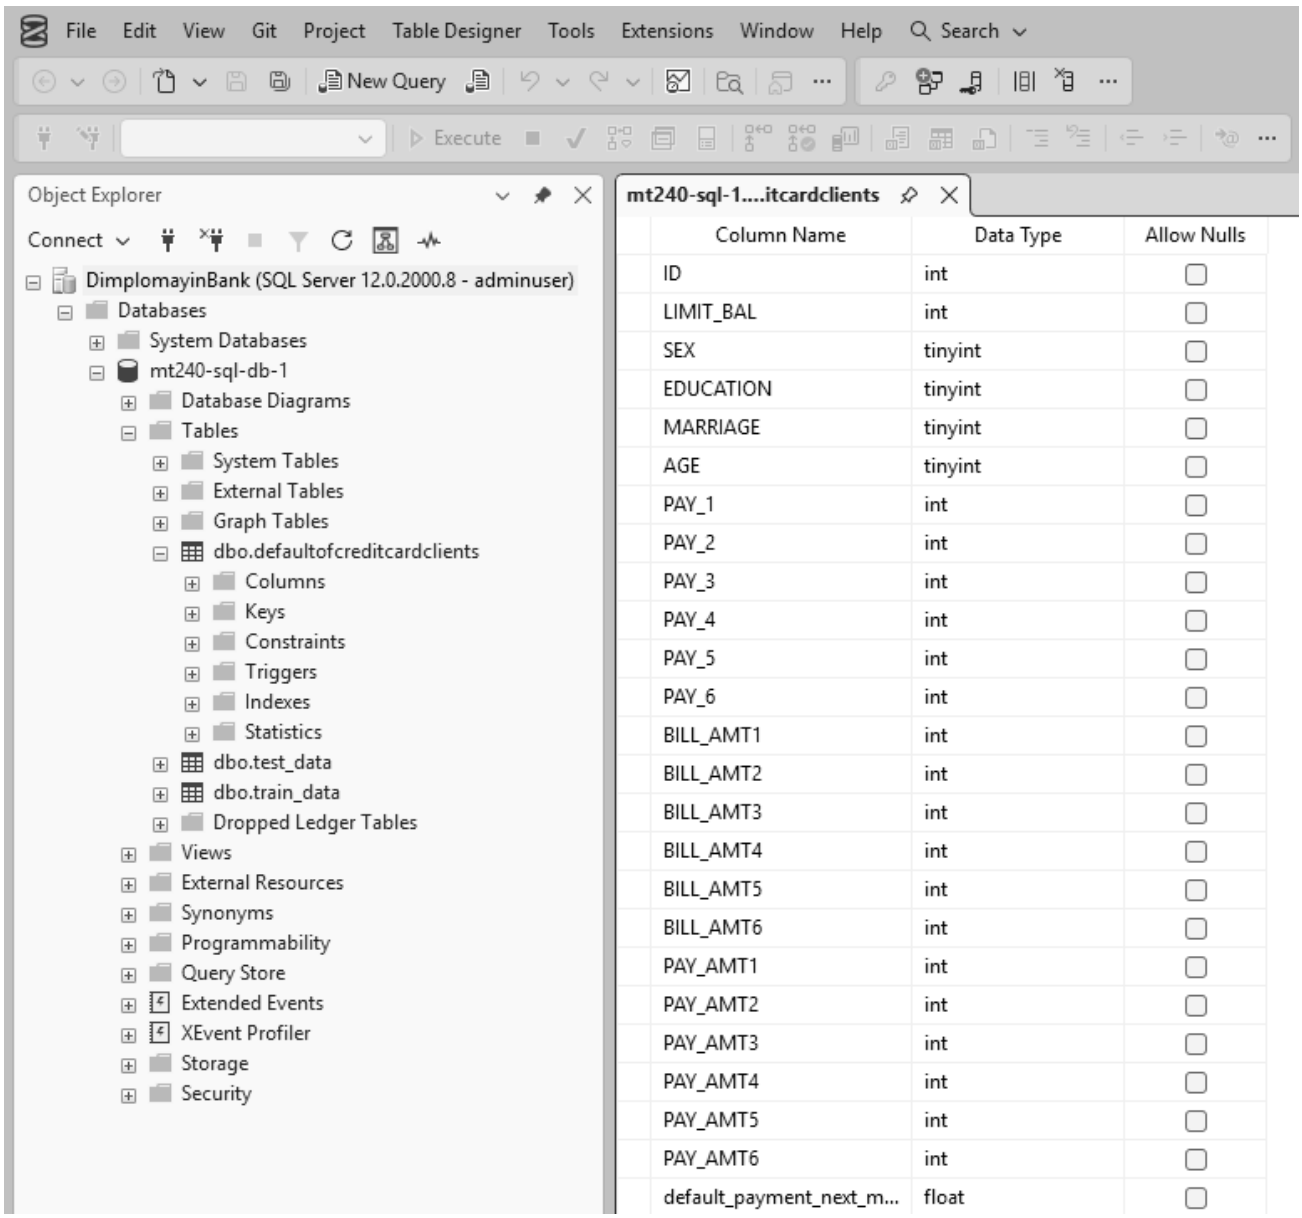


Նկար 5.1

SQL-ի կարևոր առանձնահատկություններից մեկը տվյալների կառուցվածքային կառավարումն է: Տվյալները պահվում են աղյուսակների ձևով, որտեղ յուրաքանչյուր տող ներկայացնում է առանձին դիտարկում, իսկ սյունակները՝ համապատասխան հատկանիշներ: Այս կառուցվածքը թույլ է տալիս հեշտությամբ իրականացնել տվյալների ընտրություն (SELECT), զտում (WHERE), դասավորում (ORDER BY) և միավորում (JOIN) տարբեր աղյուսակների միջև: Օրինակ, pipeline-ի ընթացքում տվյալների բաժանման փուլում օգտագործվում են SQL հարցումներ, որոնք հնարավորություն են տալիս պատահական կամ կանոնավոր հիմքով առանձնացնել ուսուցման և թեստավորման տվյալները:

Բացի տվյալների ընտրությունից, SQL-ը նաև ապահովում է տվյալների մանիպուլյացիայի հնարավորություններ: INSERT, UPDATE և DELETE գործողությունների միջոցով հնարավոր է ավելացնել նոր տվյալներ, փոփոխել առկա

արժեքները կամ հեռացնել ավելորդ գրառումները: Տվյալային խողովակաշարի կոնտեքստում այս գործողությունները օգտագործվում են միջանկյալ աղյուսակների ստեղծման, տվյալների թարմացման և արդյունքների պահպանման համար:

SQL-ի մեկ այլ կարևոր ֆունկցիոնալ հնարավորություն է տվյալների ագրեգացիան և խմբավորումը: GROUP BY և ագրեգացիոն ֆունկցիաների միջոցով հնարավոր է հաշվարկել միջին արժեքներ, գումարներ, քանակներ և այլ վիճակագրական ցուցանիշներ: Սա հատկապես օգտակար է տվյալների նախնական վերլուծության փուլում, երբ անհրաժեշտ է հասկանալ տվյալների բաշխումը և հիմնական օրինաչափությունները:

Տվյալների բազայի մակարդակում իրականացվող այս գործողությունները զգալիորեն նվազեցնում են հաշվարկային ծանրաբեռնվածությունը Python միջավայրում և բարձրացնում համակարգի արդյունավետությունը: SQL-ի միջոցով տվյալների նախնական մշակում կատարելը թույլ է տալիս տվյալային խողովակաշարին աշխատել ավելի արագ և կայուն, քանի որ միայն արդեն մշակված և պատրաստ տվյալներն են փոխանցվում հաջորդ փուլերին:

Ամբողջ տվյալային խողովակաշարի կառավարումը իրականացվում է Azure Data Factory միջոցով, որը սահմանում և վերահսկում է փուլերի հաջորդական կատարումը: Յուրաքանչյուր քայլ կախված է նախորդի ավարտից, ինչը ապահովում է գործընթացի ճիշտ հերթականություն և կանխում սխալների առաջացումը: Բացի այդ, համակարգը կարող է գործարկվել ավտոմատ կերպով՝ ըստ սահմանված ժամանակացույցի կամ արտաքին ազդակների (Գծագիր 5.1):

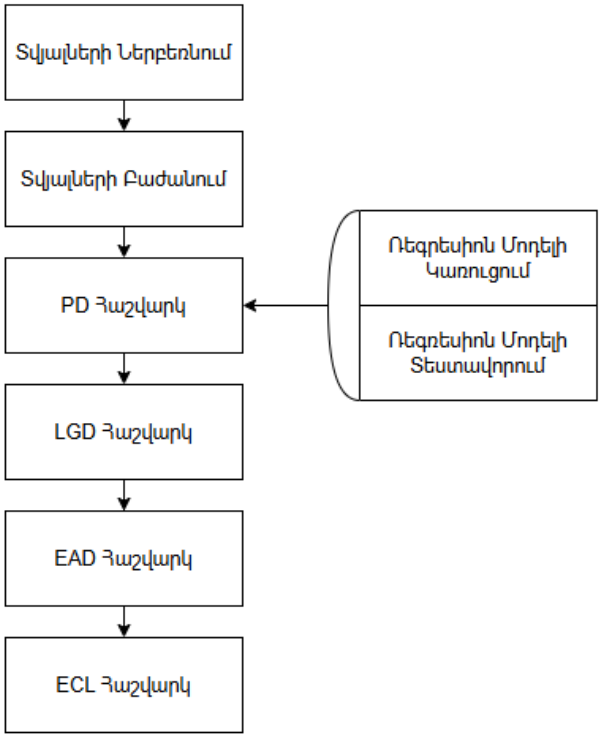


Գծագիր 5.1

Տվյալային խողովակաշարի առաջին փուլում իրականացվում է տվյալների պատրաստում և բաժանում: Սկզբնական տվյալները վերցվում են հիմնական աղյուսակից և յուրաքանչյուր գործարկման ժամանակ պատահականորեն խառնվում են՝ ապահովելով տարբեր բաշխումներ յուրաքանչյուր աշխատացման ժամանակ: Այս պատահականացումը կատարվում է SQL մակարդակում՝ առանց հիմնական տվյալների փոփոխման: Խառնված տվյալների հիման վրա ձևավորվում են երկու ենթաբազմություններ՝ ուսուցման տվյալներ և թեստավորման տվյալներ, որոնք պահպանվում են առանձին աղյուսակներում: Այս մոտեցումը ապահովում է, որ յուրաքանչյուր փորձարկման ժամանակ մոդելը աշխատի տարբեր տվյալային բաշխումների վրա՝ բարձրացնելով գնահատման օբյեկտիվությունը:

Հաջորդ փուլում իրականացվում է մոդելի ուսուցումը: Այս փուլում Python լեզվով գրված ծրագիրը տվյալների բազայից կարդում է ուսուցման համար առանձնացված տվյալները և կիրառում է լոգիստիկ ռեգրեսիայի ալգորիթմի միջոցով մշակում է մոդելը: Ալգորիթմի նպատակն է գտնել կապ մուտքային հատկանիշների և նպատակային փոփոխականի միջև՝ հաշվարկելով համապատասխան կշռային գործակիցները: Հաշվարկները իրականացվում են իտեռացիոն գործընթացով, որտեղ յուրաքանչյուր իտեռացիայի ժամանակ մոդելի պարամետրերը աստիճանաբար ճշգրտվում են՝ նվազեցնելով կանխատեսման սխալը: Հաշվարկային գործընթացում օգտագործվում են NumPy գրադարանը՝ վեկտորային հաշվարկների համար, և pandas գրադարանը՝ տվյալների կառավարման համար:

Ուսուցման ավարտից հետո ստացված մոդելի պարամետրերը պահպանվում են տվյալների բազայում՝ առանձին աղյուսակում: Սա թույլ է տալիս հետագայում օգտագործել արդեն մշակված մոդելը առանց կրկնակի հաշվարկների և ապահովում է արդյունքների վերարտադրելիությունը: Պարամետրերի պահպանումը նաև հնարավորություն է տալիս հետևել տարբեր մոդելներին և համեմատել դրանց արդյունավետությունը:

Հաջորդ փուլում իրականացվում է մոդելի թեստավորմը նախօրոք առանձնացված տվյալների բազայի վրա: Այս փուլում համակարգը բազայից կարդում է թե՛ թեստային տվյալները, թե՛ մոդելի պարամետրերը: Յուրաքանչյուր դիտարկման համար հաշվարկվում է հավանականություն, որը ներկայացնում է տվյալ դեպքի պատկանելությունը որոշակի դասին: Այդ հավանականության հիման վրա կատարվում է դասակարգում՝ օգտագործելով սահմանված շեմային արժեք: Ստացված արդյունքները համեմատվում են իրական արժեքների հետ, և հաշվարկվում է մոդելի ճշտությունը: Բացի այդ, յուրաքանչյուր դիտարկման համար ստացված հավանականությունները պահպանվում են տվյալների բազայում՝ հետագա վերլուծությունների համար:

Տվյալային խողովակաշարի կառուցվածքը հիմնված է մոդուլային մոտեցման վրա, որտեղ յուրաքանչյուր փուլ ունի հստակ սահմանված գործառույթ: Սա թույլ է տալիս հեշտությամբ փոփոխել կամ ընդլայնել համակարգը՝ առանց ամբողջ կառուցվածքը

վերափոխելու։ Բոլոր փուլերը փոխկապակցված են, սակայն միաժամանակ կարող են դիտարկվել որպես անկախ մոդուլներ, ինչը կարևոր է համակարգի կայունության և մասշտաբայնության տեսանկյունից։

PD արժեքների հաշվարկումից հետո համակարգը անցնում է հաջորդ փուլ, որտեղ հիմք ընդունելով արդեն ստացված դեֆոլտի հավանականությունները՝ իրականացվում է LGD (Loss Given Default) ցուցանիշի գնահատմանը։ Այս փուլում համակարգը կենտրոնանում է այն բանի վրա, թե որքան մասն է հնարավոր կորուստի ենթակա լինելու, եթե դեֆոլտ տեղի ունենա։ LGD-ն արտահայտում է այն տոկոսային կամ հարաբերական չափը, որը ցույց է տալիս պարտքի չվերականգնվող մասը։ Հաշվարկը կարող է իրականացվել ինչպես պատմական տվյալների հիման վրա կառուցված մոդելներով, այնպես էլ պարզեցված մոտեցմամբ՝ օգտագործելով հաստատուն կամ կիսադինամիկ գործակիցներ։ Այս փուլում հաճախ հաշվի են առնվում լրացուցիչ գործոններ, ինչպիսիք են ապահովվածությունը, գրավի առկայությունը կամ հաճախորդի ռիսկային պրոֆիլը։ Ստացված LGD արժեքները նույնպես պահպանվում են տվյալների բազայում՝ որպես յուրաքանչյուր հաճախորդի ռիսկային բնութագրի բաղադրիչ։

LGD հաշվարկից հետո Տվյալային խողովակաշարը անցնում է EAD (Exposure at Default) ցուցանիշի հաշվարկը։ Այս փուլում յուրաքանչյուր հաճախորդի համար գնահատվում է այն հնարավոր ֆինանսական պարտավորության չափը, որը կարող է գոյություն ունենալ դեֆոլտի պահին։ Հաշվարկը իրականացվում է տվյալների բազայում պահվող հաճախորդների վարկային տեղեկատվության հիման վրա՝ հաշվի առնելով առկա մնացորդները, օգտագործված վարկային սահմանաչափերը և ընդհանուր պարտավորությունների կառուցվածքը։ Այս գործընթացը թույլ է տալիս յուրաքանչյուր դիտարկման համար ստանալ անհատականացված EAD արժեք, որը արտացոլում է տվյալ հաճախորդի հնարավոր ազդեցությունը ռիսկի տեսանկյունից։ Ստացված արդյունքները պահպանվում են տվյալների բազայում և հետագայում օգտագործվում են ընդհանուր ECL հաշվարկի մեջ։

EAD հաշվարկի ավարտից հետո համակարգը անցնում է վերջնական փուլին, որտեղ համադրվում են արդեն ստացված բոլոր բաղադրիչները՝ PD, LGD և EAD։ Այս փուլում իրականացվում է վերջնական ECL (Expected Credit Loss) արժեքի հաշվարկը, որը ներկայացնում է յուրաքանչյուր հաճախորդի համար սպասվող ֆինանսական կորուստը։ Այս հաշվարկը կատարվում է յուրաքանչյուր դիտարկման համար առանձին՝ ապահովելով անհատական գնահատում։ Ստացված ECL արժեքները պահվում են տվյալների բազայում և օգտագործվում են հետագա վերլուծությունների, հաշվետվությունների և ռիսկերի կառավարման գործընթացներում։

Այս հաշվարկի արդյունքում ստացվում է հավանականություն, որը օգտագործվում է որպես հիմք Expected Credit Loss (ECL) արժեքի հաշվարկման համար։ ECL-ը հաշվարկվում է մի քանի գործակիցների համադրությամբ, որոնցից հիմնականներն են դեֆոլտի հավանականությունը, կորուստը դեֆոլտի դեպքում և ազդեցության չափը։

Յուրաքանչյուր հաճախորդի համար հաշվարկվում է այս գործակիցների համակցված արժեքը, որը ներկայացնում է սպասվող ֆինանսական կորուստը:

Բացի հիմնական տվյալային խողովակաշարից, համակարգում իրականացվում է նաև երկրորդ՝ ավելի պարզեցված գործընթաց, որը նախատեսված է հաճախորդների ռիսկի գնահատման համար: Այս դեպքում մուտքային տվյալները ներկայացնում են հաճախորդների բնութագրերը, որոնք պահվում են տվյալների բազայում: Գործընթացի սկզբում բազայից կարդացվում են արդեն ուսուցված մոդելի պարամետրերը, այնուհետև այդ մոդելը կիրառվում է նոր հաճախորդների տվյալների վրա (Գծագիր 5.2):

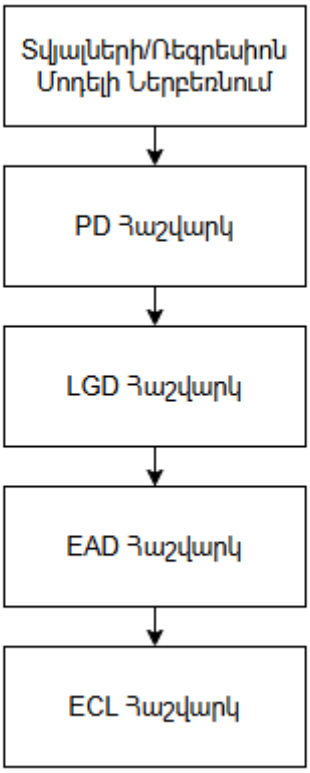


Գծագիր 5.2

Այս երկրորդ տվյալային խողովակաշարը ավելի պարզ կառուցվածք ունի, քանի որ չի ներառում տվյալների բաժանում կամ մոդելի ուսուցում: Այն կենտրոնացած է միայն արդեն պատրաստ մոդելի կիրառման վրա և կարող է գործարկվել հաճախակի՝ նոր տվյալների մուտքագրման դեպքում: Ստացված արդյունքները կարող են պահպանվել տվյալների բազայում կամ օգտագործվել հաշվետվությունների և ռիսկերի վերլուծության համար:

# Եզրակացություն

Եզրափակելով կարելի է նշել, որ վարկային ռիսկի գնահատման ժամանակակից համակարգը հանդիսանում է բազմաշերտ և փոխկապակցված մոդուլներից կազմված ամբողջական ինֆորմացիոն միջավայր, որտեղ յուրաքանչյուր բաղադրիչ ունի հստակ գործառույթ և ռազմավարական նշանակություն։ Համակարգի մոդուլային կառուցվածքը թույլ է տալիս տարանջատել տվյալների հավաքագրման, նախնական մշակման, մոդելավորման, սցենարային վերլուծության, հաշվարկային և հաշվետվությունների ձևավորման գործընթացները՝ ապահովելով ճկունություն, վերահսկելիություն և ընդլայնման հնարավորություն։ Այսպիսի ճարտարապետությունը հատկապես կարևոր է ՖՀՄՍ 9 պահանջներին համապատասխան ECL հաշվարկի համար, որտեղ անհրաժեշտ է միաժամանակ ապահովել ճշգրտություն, թափանցիկություն և կրկնելիություն։

Microsoft Azure ամպային հարթակը այս համատեքստում հանդես է գալիս որպես տեխնոլոգիական հիմք, որը միավորում է տվյալների պահպանումը, հաշվարկային հզորությունները և մեքենայական ուսուցման գործիքակազմը մեկ միասնական միջավայրում։ Azure-ի օգտագործումը հնարավորություն է տալիս կառուցել մասշտաբավորվող համակարգ, որը կարող է մշակել մեծ ծավալի պատմական և ընթացիկ տվյալներ՝ առանց ենթակառուցվածքային սահմանափակումների։ Ամպային ճարտարապետությունը նաև ապահովում է բարձր հասանելիություն, անվտանգություն և տվյալների պաշտպանության մեխանիզմներ, ինչը հատկապես կարևոր է ֆինանսական ոլորտում։ Բացի այդ, Azure միջավայրում հնարավոր է իրականացնել ավտոմատացված տվյալահոսքեր, մոդելների պարբերական վերաուսուցում և սցենարային հաշվարկներ՝ նվազեցնելով մարդկային գործոնի ազդեցությունը և բարձրացնելով հաշվարկների օպերատիվությունը։

ECL հաշվարկի գործընթացը, հիմնված PD, LGD և EAD բաղադրիչների վրա, համակարգում իրականացվում է փուլային և տրամաբանական հաջորդականությամբ։ Staging մոդուլը ապահովում է ակտիվների ճիշտ դասակարգում՝ ըստ վարկային ռիսկի փոփոխության աստիճանի, ինչը որոշում է հաշվարկի հորիզոնը։ PD մոդուլը գնահատում է դեֆոլտի հավանականությունը՝ օգտագործելով պատմական տվյալներ և վարքագծային օրինաչափություններ։ EAD մոդուլը սահմանում է դեֆոլտի պահին ակնկալվող ռիսկային ազդեցությունը՝ ներառելով ինչպես հաշվեկշռային, այնպես էլ օֆ-բալանսային պարտավորությունները։ LGD մոդուլը գնահատում է դեֆոլտի դեպքում հնարավոր կորուստների չափը՝ համադրելով վիճակագրական և մակրոտնտեսական գործոնները։ Այս բոլոր մոդուլների ինտեգրման արդյունքում ձևավորվում է վերջնական ECL ցուցանիշը, որը ներկայացնում է սպասվող վարկային կորուստը և հանդիսանում է ռեզերվների ձևավորման հիմք։

Ձեր մշակած ալգորիթմը, որը կառուցված է staging, CCF, MPD, PD, EAD, LGD-Stat, LGD-Econ և վերջնական ECL փուլերի տրամաբանական հաջորդականության վրա, կարելի է գնահատել որպես համակարգային և ամբողջական մոտեցում։ Այն ապահովում է ռիսկի գնահատման ոչ միայն մեխանիկական, այլև վերլուծական խորություն՝ հաշվի առնելով ինչպես վարքագծային, այնպես էլ մակրոտնտեսական ազդեցությունները։ Ալգորիթմի ուժեղ կողմերից է փուլային կառուցվածքը, որը թույլ է տալիս յուրաքանչյուր բաղադրիչ առանձին վավերացնել, թեստավորել և բարելավել՝ առանց ամբողջ համակարգը վերակառուցելու անհրաժեշտության։ Սա բարձրացնում է մոդելի

կայունությունն ու վերահսկելիությունը, ինչպես նաև հեշտացնում է կարգավորող պահանջներին համապատասխանության ապահովումը։

Ընդհանուր առմամբ, համակարգի մոդուլային ճարտարապետությունը, Microsoft Azure ամպային միջավայրի տեխնոլոգիական հնարավորությունները և ձեր կողմից մշակված փուլային ալգորիթմը միասին ձևավորում են արդյունավետ, մասշտաբավորվող և ժամանակակից ECL հաշվարկման լուծում։ Այս մոտեցումը հնարավորություն է տալիս ապահովել ճշգրիտ ռիսկի գնահատում, օպերատիվ հաշվարկներ և ռազմավարական որոշումների ընդունման համար անհրաժեշտ տեղեկատվություն։ Արդյունքում ձևավորվում է կայուն վարկային ռիսկի կառավարման համակարգ, որը համատեղում է տեսական հիմքերը, տեխնոլոգիական նորարարությունը և գործնական կիրառելիությունը՝ ապահովելով ֆինանսական կազմակերպության երկարաժամկետ կայունությունն ու մրցունակությունը։

# Օգտագործված Գրականություն


1. Christopher M. Bishop - Pattern Recognition and Machine Learning [2006]
2. Darrell Duffie - Credit Risk: Pricing, Measurement, and Management [2001]
3. David Lando - Credit Risk Modeling: Theory and Applications [2004]
4. Gareth James et al. - An Introduction to Statistical Learning (2nd ed.) [2021]
5. John C. Hull - Risk Management and Financial Institutions [2018]
6. Kevin P. Murphy - Probabilistic Machine Learning: An Introduction [2022]
7. Linda Allen - Credit Risk Measurement [2004]
8. Paul Glasserman - Monte Carlo Methods in Financial Engineering [2003]
9. Trevor Hastie, Robert Tibshirani, Jerome Friedman - The Elements of Statistical Learning [2009]
10. https://en.wikipedia.org/wiki/Machine_learning
11. https://learn.microsoft.com/en-us/azure/databricks/
12. https://learn.microsoft.com/en-us/azure/data-factory/
13. https://learn.microsoft.com/en-us/azure/synapse-analytics/
14. https://learn.microsoft.com/en-us/training/modules/introduction-azure-synapse-analytics/
15. https://www.databricks.com/learn/training